

分类号 : \_\_\_\_\_  
密级 : \_\_\_\_\_

学校代码 : 10426  
学号 : 2020190012



**青岛科技大学**  
Qingdao University of Science & Technology

# 硕士学位论文

## 基于人工智能的声音事件检测

作者 : 李康豪  
指导教师 : 杨树国  
学科专业 : 数学  
专业代码 : 070100  
研究方向 : 声音事件检测

2024 年 5 月 30 日

# 基于人工智能的声音事件检测

## 摘 要

计算机听觉是人工智能和机器学习领域的一个重要分支，它致力于使计算机能够感知、理解和处理声音信号。声音是一种波动，其在计算机听觉中被视为一种重要的信息载体，通常以数字信号的形式进行处理，因此声音处理技术的发展对于实现人机交互、智能音频分析和语音识别等应用具有重要研究意义。

声音事件检测是指利用计算机技术来识别和分类声音信号中的特定事件或活动，从而实现对声音环境的理解和分析。声音事件检测在现实生活中具有多种应用，可用于智能交通管理、医疗诊断和健康监测等多种领域中。近年来，随着深度学习不断发展，其在声音事件检测领域也取得了显著进展，卷积神经网络、注意力机制等深度学习模型被广泛用于声音事件检测任务，并取得了令人瞩目的性能。但在传统的声音事件检测任务中，存在着声音信号受时间不变性影响和特征信息冗余等问题亟待解决。

但在传统的声音事件检测任务中，存在着声音信号受时间不变性影响和特征冗余等问题。针对以上问题，本文研究了基于人工智能的弱标注多声音事件检测方法。胶囊网络作为近年来新兴的网络架构，可以用于识别环境中的不同声音事件，检测声音事件发生和结束时间，通过训练胶囊网络实现对声音事件的准确检测和标记。本文提出一种基于 Transformer 和改进胶囊网络的声音事件检测方法。因传统的胶囊网络在捕获音频全局信息方面的性能仍然有限，因此本文通过将胶囊网络与 Transformer 结合，利用 Transformer 能够更好地处理声音事件中的时序关系和上下文信息，同时使用改进胶囊网络架构，在门控卷积下通过动态路由减少特征信息冗余，并在 DCASE 2017 任务 4 弱标记数据集上对所提出的方法进行评估。与其他基线系统相比，本文方法实现显著改进的性能。

**关键词：**声音事件检测；音频标记；胶囊网络；Transformer

# **ARTIFICIAL INTELLIGENCE BASED SOUND EVENT DETECTION**

## **ABSTRACT**

Computer audition is an important branch of artificial intelligence and machine learning, which aims to enable computers to perceive, understand, and process audio signals. Sound, as a form of wave, is considered a significant information carrier in computer audition, typically processed in digital signal form. Therefore, the development of sound processing techniques holds crucial research significance for applications such as human-computer interaction, intelligent audio analysis, and speech recognition.

Sound event detection refers to the utilization of computer technology to identify and classify specific events or activities within audio signals, thereby achieving an understanding and analysis of the sound environment.

Sound event detection has various applications in real life, including intelligent traffic management, including intelligent traffic management, medical diagnosis, and health monitoring, among others. In recent years, with the continuous development of deep learning, significant progress has been made in the field of sound event detection. Deep learning models such as convolutional neural networks, recurrent neural networks, and attention mechanisms have been widely used for sound event detection tasks, achieving high performance. However, traditional sound event detection tasks face challenges such as the influence of time invariance on sound signals and redundant feature information.

To address these challenges, this paper studies weakly labeled multi-sound

event detection methods based on artificial intelligence. Capsule networks, as emerging network architectures in recent years, can be used to identify different sound events in the environment, detect the onset and end times of sound events, and accurately detect and label sound events by training capsule networks. In this paper, we propose a sound event detection method based on capsule networks. Since the performance of traditional capsule networks in capturing global audio information is still limited, this paper combines capsule networks with transformers, utilizing transformers to better handle temporal relationships and contextual information in sound events. Additionally, a multi-path capsule network architecture is used to reduce redundant feature information through dynamic routing under gated convolution. The proposed method is evaluated on the DCASE 2017 Task 4 weakly labeled dataset. Compared to other baseline systems, the proposed method achieves significantly improved performance.

**KEY WORDS :** Sound event detection; Audio tagging; Capsule networks; Transformer

## 目 录

|                                       |    |
|---------------------------------------|----|
| 1 绪论.....                             | 1  |
| 1.1 研究背景和意义.....                      | 1  |
| 1.2 国内外研究现状.....                      | 4  |
| 1.3 主要研究工作及章节安排 .....                 | 6  |
| 2 相关理论概述 .....                        | 9  |
| 2.1 声音事件检测基础理论.....                   | 9  |
| 2.1.1 声音事件检测基本架构.....                 | 10 |
| 2.1.2 特征选择与提取.....                    | 11 |
| 2.1.3 评价指标.....                       | 14 |
| 2.1.4 常用分类器.....                      | 16 |
| 2.2 弱标注数据下的声音事件检测 .....               | 20 |
| 2.2.1 基础理论.....                       | 20 |
| 2.2.2 多实例学习.....                      | 21 |
| 2.2.3 基于多实例学习的弱标注声音事件检测 .....         | 21 |
| 2.3 深度学习基础理论.....                     | 23 |
| 2.3.1 深度学习原理.....                     | 23 |
| 2.3.2 卷积神经网络.....                     | 25 |
| 2.3.3 循环神经网络.....                     | 27 |
| 2.3.4 常用激活函数和损失函数.....                | 29 |
| 2.4 本章小结.....                         | 31 |
| 3 基于胶囊网络模型的声音事件检测 .....               | 32 |
| 3.1 声音事件检测常用特征.....                   | 32 |
| 3.2 胶囊网络.....                         | 33 |
| 3.3 网络架构.....                         | 36 |
| 3.3.1 并行门控卷积.....                     | 36 |
| 3.3.2 改进胶囊网络.....                     | 37 |
| 3.3.3 基于改进胶囊网络的声音事件检测.....            | 38 |
| 3.4 实验及结果分析.....                      | 39 |
| 3.4.1 数据集及评价指标.....                   | 39 |
| 3.4.2 实验设置及结果.....                    | 40 |
| 3.5 本章小结.....                         | 41 |
| 4 基于 Transformer 和胶囊网络结合的声音事件检测 ..... | 42 |
| 4.1 Transformer 概述.....               | 42 |
| 4.1.1 Transformer 模型架构 .....          | 42 |

|                                            |    |
|--------------------------------------------|----|
| 4.1.2 基于 Transformer 的声音事件检测模型.....        | 44 |
| 4.2 网络架构.....                              | 45 |
| 4.2.1 基于声音事件检测的 Transformer 编码器.....       | 45 |
| 4.2.2 基于 Transformer 和改进胶囊网络的声音事件检测模型 .... | 46 |
| 4.3 实验及结果分析.....                           | 47 |
| 4.3.1 数据集及评价指标.....                        | 47 |
| 4.3.2 基线系统.....                            | 47 |
| 4.3.3 实验设置.....                            | 48 |
| 4.3.4 实验结果及分析.....                         | 49 |
| 4.4 本章小结.....                              | 54 |
| 5 总结与展望.....                               | 55 |
| 参考文献.....                                  | 57 |

# 1 绪论

## 1.1 研究背景和意义

声音是人类交流、感知和认知的重要媒介之一，具有丰富的信息量。随着科技的进步，声音已经在我们日常生活中扮演着越来越重要的角色，如何用机器感知自然界中的各类声音并进行检测、定位等一直是业界重点关注的问题。声音事件(Sound Event)是指在一段音频信号中所包含的所有声音内容。比如交通信号、车辆喇叭声、窗户破碎声皆统称为声音事件。声音事件检测(Sound Event Detection, SED)是利用计算机技术来识别和分类声音信号中的特定事件或活动，可以使系统能够感知和理解声音环境，为智能系统的智能化和人机交互提供了重要支持。

声音事件检测技术的研究始于上世纪，随着人工智能技术的发展和大数据的兴起，声音事件检测取得了显著的进展，并成为了研究的热点之一。同时在智能交通管理、医疗诊断、智能家居、安防监控<sup>[1]</sup>、娱乐游戏等领域都具有广泛的应用前景。例如，在智能交通管理系统中<sup>[2]</sup>，声音事件检测可以实时监测交通信号、车辆喇叭声、紧急车辆警报声等声音事件，从而提高交通管理的效率和安全性。在医疗诊断领域，声音事件检测可以识别心脏跳动声、呼吸声、腹部肠鸣声等声音事件，帮助医生进行疾病诊断和治疗<sup>[3]</sup>。

声音事件检测旨在通过声音信号的分析，自动辨识其中特定事件，以实现声音环境的理解和分析。通常，声音事件检测技术涉及音频信号采集、信号预处理、特征提取、事件检测与分类、结果输出等关键步骤。根据任务类型分类，声音事件检测可分为单声音事件检测(MSED)和多声音事件检测(PSED)<sup>[4]</sup>。单声音事件检测指的是从音频信号中检测出单一的声音事件；多声音事件检测则旨在检测出音频信号中的多个声音事件。在研究实践中，相对于单声音事件检测，多声音事件检测具有更广泛的研究价值。

根据不同的分类标准和研究对象，声音事件检测可以分为多种类型。基于事件类型可分为环境声音事件检测、人声事件检测和非语言声音事件检测。其中环境声音事件检测是指识别和分类环境中产生的各种声音事件。这些声音通常是自然界或城市环境中产生的，例如车辆噪音、交通信号声、鸟鸣声、风声等，该检测在城市规划、环境保护、生态学研究等领域具有重要意义。

人声事件检测是指识别和分类由人类发出的声音事件，包括语音、说话、咳嗽、

笑声等。这些声音通常用于语音识别<sup>[5][6]</sup>、情感分析、语音合成等应用，该检测在智能语音助手、语音识别系统、通信系统等领域具有广泛应用。非语言声音事件检测是指除了人类语音之外的声音事件。这些声音包括音乐、动物叫声、机械声、玻璃破碎声等，该检测在音乐识别、动物声音监测、生物场景分析<sup>[7][8]</sup>等方面具有重要应用。

声音事件检测可根据数据类型分类为有监督学习、弱监督学习和无监督学习等，具体地，

**(1)有监督学习**是利用已经标注好的训练数据进行模型训练和监督学习的方法。在有监督学习中，训练数据集通常包含声音信号及其对应的标签信息，标注信息是准确且完整的。训练过程中，模型通过学习输入声音信号与对应标签之间的关系来实现声音事件的检测和分类。

**(2)弱监督学习**是一种利用部分标注或弱标注数据进行模型训练的方法。在这种学习方式下，训练数据的标注信息可能不完整或不准确，但仍可为模型提供一定程度的监督信息。通过利用这些不完整标注数据，弱监督学习方法能够训练模型，实现声音事件的检测和分类任务。

**(3)无监督学习**是一种在缺乏标注数据的情况下，利用无监督学习方法自动发现数据结构和模式的方法。在无监督学习中，通常训练数据集不包含标签信息，模型需要自动学习数据中的潜在结构和规律。无监督学习方法可以通过发现数据之间的相似性和差异性来实现声音事件的聚类 and 分类。

基于数据标注的声音事件检测分类为研究者提供了不同的学习方法和策略，有助于在不同的数据情况下实现声音事件的有效检测和分类。在实际应用中，声音事件检测的性能往往受到标注数据不足的制约。获取大规模的标注数据往往是非常昂贵和耗时的，尤其对于多样性和复杂性较高的声音事件。因此基于弱监督学习的声音事件检测是近年来声音事件检测领域的研究热点之一。在弱监督学习框架下，研究人员尝试利用只有部分标注信息或标注信息不完整的数据进行模型训练，以提高声音事件检测的效果。基于弱监督学习的声音事件检测方法能够更好地适应实际应用中数据标注不足的情况，促进了声音事件检测技术的发展。通过解决标注数据不足的问题，研究人员可以更加专注于模型结构设计、特征提取、评估方法等方面的研究，推动声音事件检测技术的进步和创新。

目前，随着深度学习方法的普及和广泛应用<sup>[9-12]</sup>，许多用来识别和处理噪声的技术都依赖于深度学习模型，如基于卷积神经网络（Convolutional Neural Network, CNN）、基于循环神经网络（Recurrent Neural Network, RNN）、基于



注意力机制（Attention mechanism, AM）、基于胶囊网络（Capsule Network, CN）和变换器（Transformer）等模型的声音事件检测方法，典型的成果如下：

#### (1) 典型的基于 CNN 的声音事件检测方法

CNN 在声音事件检测中被广泛应用于声谱图特征的提取和声音事件分类<sup>[13]</sup>。可以直接对声谱图进行分类，将声谱图作为输入进行卷积和池化操作，然后经过全连接层进行声音事件的分类。这种方法能够较好地捕获声音事件的频域特征，适用于多种声音事件的分类任务。通过卷积层和池化层的组合，CNN 可以有效地捕获声音事件中的时频信息。Justin Salamon 等人在环境声音分类任务中<sup>[14]</sup>使用深度的卷积神经网络结构，并结合数据增强技术，取得了较好的环境声音分类性能。

#### (2) 典型的基于 RNN 的声音事件检测方法

RNN 及其变种（如长短期记忆网络和门控循环单元（GRU））适用于处理序列数据，因此在声音事件检测中常用于对时序特征进行建模。这些模型能够捕捉声音信号中的时间依赖性，提高声音事件检测的准确性<sup>[15]</sup>。同时 RNN 作为特征提取器，从初始音频信号中提取丰富的时序特征。通过逐帧处理声音信号序列，提取包含时序信息的高级特征，用于后续的声音事件分类或检测任务，Cao 等人提出了一种基于扩张卷积和 RNN 相结合的声音事件检测方法<sup>[16]</sup>，利用扩张卷积对长期依赖关系的建模能力，同时结合 RNN 对时序特征的良好处理特性，呈现了较好的检测效果。

#### (3) 典型的基于 AM 的声音事件检测方法

注意力机制可以使模型将注意力集中于音频信号中最主要的部分，提高模型对关键特征的关注意度。在声音事件检测中，注意力机制可以帮助模型自动学习并关注对分类决策最有帮助的声音片段，还可以对不同时间步或不同频率段的特征进行加权，使得模型更加关注对分类决策有帮助的特征。Hang Zhao 等人提出了一种基于注意力机制的声音事件检测方法<sup>[17]</sup>，利用注意力机制动态地调整模型对声音事件中不同频率和时间段的关注程度，从而提高了声音事件检测的性能。

#### (4) 典型的基于 CN 的声音事件检测方法

胶囊网络<sup>[18]</sup>是一种新型的深度学习结构，能够有效地捕捉输入数据的层级结构信息。在声音事件检测中，胶囊网络可以帮助模型更好地理解声音信号的层次结构特征，提高模型对声音事件的识别性能。同时胶囊网络通过动态路由机制，能够对不同特征之间的空间关系进行建模，从而更好地捕捉声音事件中的空间结构信息。这种特性有助于提高模型对声音事件的分类性能，尤其对于复杂多变的声音环境具有重要意义。Taejun Kim 等人提出了一种基于胶囊网络的弱监督学习

方法<sup>[19]</sup>，用于声音事件检测任务。他们利用胶囊网络的层级特征学习能力，通过迭代训练的方式实现了对声音事件的检测和分类。

#### (5) 典型的基于 Transformer 的声音事件检测方法

Transformer<sup>[20]</sup>是一种基于自注意力机制的深度学习模型，在自然语言处理等领域取得了显著的成果。近年来，Transformer 也开始在声音事件检测领域得到应用，能够有效地捕捉声音信号中的时序关系和上下文信息，提高了声音事件检测的性能。Transformer 模型具有处理变长序列的能力，能够灵活地适应不同长度的声音事件输入，可以结合声音信号的时序特征和其他传感器数据的空间信息，提升模型对声音事件的理解能力和识别分类性能。Vincent Lostanlen 等人提出了一种基于 Transformer 的声音信号处理方法<sup>[21]</sup>，利用局部-全局自注意力机制学习声音信号的特征表示，实现了一种类似小波变换的变换方法，适用于声音事件检测等任务。

声音事件检测技术可以应用于智能交通管理、环境监测、医疗诊断等领域，为社会提供智能化、便捷化的服务<sup>[22-26]</sup>。同时声音事件检测的研究可以推动计算机听觉技术的发展，丰富人工智能领域的技术手段和方法。通过不断改进和优化声音事件检测算法，可以提高计算机对环境声音的感知和理解能力，推动人工智能技术在实际应用中的进一步发展。

## 1.2 国内外研究现状

声音事件检测领域的发展历史可以追溯到数十年前，随着机器学习和人工智能技术的不断发展，声音事件检测的研究也在不断演进<sup>[27-29]</sup>。早期的声音事件检测主要依赖于手工设计的特征提取和传统的信号处理技术，如傅里叶变换、小波变换等。这些方法受限于特征的表达能力和对复杂环境的适应性。

随着机器学习技术的不断进步，声音事件检测逐渐开始采用机器学习算法，如支持向量机（Support Vector Machine, SVM）<sup>[30][31]</sup>、隐马尔可夫模型（Hidden Markov Model, HMM）<sup>[32][33]</sup>和高斯混合模型（Gaussian Mixture Model, GMM）<sup>[34]</sup>等。其中 S. Squartini 等人使用了来自智能家居环境的声音数据集<sup>[35]</sup>，提取了声音事件的特征，并使用了 SVM 和深度学习模型进行分类。从声音信号中使用基于时域和频域的特征，使用 MFCC（Mel-frequency cepstral coefficients）等声音特征作为输入，然后利用 SVM 对不同声音事件进行分类。在文献<sup>[36]</sup>中介绍了一种使用隐马尔可夫模型进行声音事件检测和分类的方法。将声音信号分为若干时间窗

口, 并使用频谱特征对每个时间窗口进行建模, 通过使用 HMM 对这些时间窗口的频谱特征序列进行建模, 并利用 HMM 的状态转移概率和观测概率对不同环境下的声音事件进行检测和分类。此外, 在文献<sup>[37]</sup>中作者提出了一种声音事件检测的方法, 通过利用高斯混合模型, 使用了声音信号的频谱特征, 并通过训练 GMM 模型对不同声音事件进行建模。在声音事件检测阶段, 通过计算每个时间窗口的声音特征与各个声音事件模型的后验概率, 然后选择具有最高后验概率的声音事件作为检测结果。

近年来, 深度学习的兴起极大地推动了声音事件检测技术的发展, 卷积神经网络、循环神经网络以及其变体等方法模型被广泛应用于音频识别、声音事件检测等任务中。深度学习模型通过多层次的非线性变换和表示学习, 能够更好地适应和建模声音信号的复杂关系, 从而提高声音事件检测的准确性和鲁棒性。以卷积神经网络为例, 一些研究利用迁移学习和微调的技术, 将在大规模数据集上预训练的 CNN 模型应用于声音事件检测任务中。这种方法可以显著减少在小规模数据集上的训练时间, 弥补机器学习应用于音频数据所存在的不足, 有效提高模型的性能和泛化能力。RNN 在近些年也被应用于 SED 任务中, 在文献<sup>[38]</sup>中, 作者使用长短期记忆网络和门控循环单元等 RNN 变体来进行声音事件检测。利用 RNN 能有效地捕捉时序信息并对其特性进行建模的优势, 通过将声音信号转换为时间序列, 然后使用 RNN 模型对序列进行建模。作者通过比较多个音频数据集上的实验结果, 验证了该方法的有效性。这些深度学习模型能够自动学习特征, 并且在大规模标记数据上表现出色, 使得声音事件检测的性能得到了显著提升。

胶囊网络在声音事件检测中首次被提出并被广泛报道。胶囊网络最初由 Geoffrey Hinton 等人于 2017 年提出的<sup>[18]</sup>, 主要用于图像识别领域。它的主要思想是在传统的卷积神经网络的基础上, 引入胶囊层, 以更好地捕捉物体的空间关系和层次结构。相对于传统神经网络, 胶囊网络通过动态路由能够更准确地捕捉句子中单词之间的上下文关系。解决 CNN 在表示特征角度、相对位置方面的限制, 并避免池化引起的信息丢失。此外, CN 自动调整胶囊以提取重叠特征, 从而增强模型识别目标的整体能力。胶囊网络具有向量输入、输出的特性, 通过其内部的动态路由算法, 使内部结构能识别和建立不同特征间的联系。最近的研究表明, 胶囊网络在声音事件检测中取得了较好的结果。在这项研究中, 门卷积网络被用于提取特征, 然后由 CN 模型用于声音事件检测和识别。动态路由算法作为 CN 的核心, 可被视为一个学习和训练多个属性(如目标形状和位置)的注意力机制, 同时保留关键特征。CN 还应用于弱标注声音事件检测任务, 表现出较好的结果。

声音事件检测的应用涵盖了安防监控、智能家居、环境监测等多个领域。然而，仍然存在一些挑战：

#### （1）类别不平衡和标签存在噪声

在多声音事件检测任务中，不同事件类别的样本数量可能存在不平衡，同时标签可能也存在噪声。这会导致模型倾向于识别常见事件而忽略罕见事件，同时降低模型的泛化能力。

#### （2）数据集规模较小且标注质量不高

目前可用于多声音事件检测的大规模数据集相对较少，而且部分数据集的标注质量可能不高，这会影响模型的训练和评估结果。此外，现有数据集可能无法涵盖所有的声音事件类别和真实场景。

#### （3）时空动态特征难建模

声音事件通常具有复杂的时空动态特征，而目前的模型可能无法有效地整合和利用这些信息。如何在深度学习模型中更好地建模时序和空间关系，以提高声音事件检测的性能仍然是一个挑战。

#### （4）实时性和检测性双重需求难实现

随着深度学习模型的复杂性不断增加，模型训练和推理过程对计算硬件设备提出了更高的要求，并且需要大量的计算时间。在实际应用中，特别是实时声音事件检测场景下，计算效率和检测性能的双重需求受计算资源和时间影响较大。

解决这些问题需要深入研究，并结合领域知识和工程实践进行综合考虑。通过改进数据集质量、开发新的模型结构、优化训练算法等方法，可以逐步解决多声音事件检测中的挑战，推动该领域的进一步发展。本文的主要研究旨在提高基于弱标签数据的声音事件检测模型性能。

### 1.3 主要研究工作及章节安排

本文首先分析目前较为流行的声音事件检测方法，研究基于传统胶囊网络的弱标注声音事件检测模型，对文献<sup>[1]</sup>中基于传统动态路由算法的胶囊网络进行了改进，引入了 Transformer 模型和胶囊模型的集成，优化传统的胶囊网络内部结构以及多层并行门控卷积结构，以提高所提出模型的计算效率和检测精度，最终提出了基于 Transformer 和改进的胶囊网络的声音事件检测模型。具体研究工作如下：

本文提出了一种声音事件检测方法，通过将改进的胶囊网络与 Transformer 相结合，使用 Transformer 在捕获全局特征时的优势以及胶囊网络在捕获局部特征

时的优势。在弱标注音频数据集上对所提出的方法进行了评估。获得的 F 得分和错误率相较于其他系统，本文得到模型性能更优。首先，通过 Log-Mel 谱图的方式将音频数据转化为音频特征；其次，将改进的并行门控卷积应用于特征提取，从而提高训练速度；同时改变传统胶囊网络中的路径导向，提高胶囊网络模型精度；最后，利用 Transformer 与胶囊网络模型相集成，并构建了基于 Transformer 和改进胶囊网络的声音事件检测模型，经过实验验证，检测效果良好。

本文的章节安排如下：

第一章——绪论，详细介绍声音事件检测的研究背景和意义，并对国内外发展历史和发展现状做详细分析，最后简单概括本文主要研究内容并给出章节安排。

第二章——相关理论概述，详细阐述声音事件检测的基本原理、通用架构和常用特征，并介绍音频特征的选择和提取方法、声音事件检测的常用评价指标以及常用声音事件检测分类器；随后介绍深度学习理论基础、卷积神经网络以及循环神经网络，并阐述基于多实例学习的多声音事件检测模型，最后介绍了弱标注下的多声音事件检测。

第三章——基于胶囊网络模型的声音事件检测，提出基于改进胶囊网络模型的多声音事件检测方法，并与目前相关性竞争性方法进行比较。

第四章——基于 Transformer 和胶囊网络结合的声音事件检测，提出基于 Transformer 与胶囊网络结合的多声音事件检测模型，进一步提升多声音事件检测性能。

第五章——总结与展望，总结本文的主要研究内容及创新点，并展望未来工作。




图 1-1 基于人工智能的声音事件检测论文框架

Fig.1-1 Artificial intelligence based sound event detection paper framework

## 2 相关理论概述

### 2.1 声音事件检测基础理论

声音是由物体振动产生的机械波在空气或其他介质中传播而产生的感觉，是一种能够被人类耳朵感知的声压波。在日常生活中，人们被各类声音包围，声音也各行各业得到了广泛应用。如在定位导航方面，声音导航系统广泛应用于汽车导航、航空航海、户外探险等领域。通过声音提示和语音指引，人们可以方便地获取行进方向和目的地信息。在医学领域，声音信号可以提供有关器官功能和病变情况的重要信息，利用声音可以进行诊断和治疗，如心脏听诊、肺部听诊、超声波检查等。因此，声音事件检测和声学场景分类（Acoustic Scene Classification, ASC）<sup>[39]</sup>研究就显得尤为重要。

声音事件检测的主要目的是检测连续的音频流之中有无出现目标声音事件，比如检测设备故障异常发出的声音，事故现场发出的声音，野生动物的声音等等。图 2-1 展示了音频在不同阶段的模块结构。




图 2-1 音频事件分析模块结构

Fig.2-1 Audio event analysis module structure

本章将详细阐述声音事件检测的基础理论和知识，包括系统架构、评价体系、常用特征、弱标注声音事件检测方法以及常见分类器举例。同时将通过具体案例

进行阐述。

### 2.1.1 声音事件检测基本架构

声音事件检测在各种应用场景中都发挥了重要作用。图 2-2 可视化介绍了声音事件检测系统基本架构。声音事件检测主要分为特征提取与分类（Feature Extraction and Classifier）、模型训练与优化（Model Training and Optimization）和模型测试与评估（Testing and Evaluation）三部分。同时整个系统分为训练和测试两阶段，通过两阶段的不断操作和迭代，可以使声音事件检测系统不断优化模型，并在真实外界环境中提供准确识别和分类。




图 2-2 基于音频事件检测和分类的通用系统框架

Fig.2-2 A general system framework based on audio event detection and classification

在训练阶段，首先需要准备用于训练的声音数据集。这些数据集通常包括已经标记好的声音事件，如 DCASE（Detection and Classification of Acoustic Scenes and Events）挑战赛的音频数据，是一个专门用于声音事件检测和场景分类的数据集系列，包含了多个子数据集，涵盖了不同场景和事件的音频数据。

其次，从训练数据中提取特征，用于表示声音事件的各种属性。再将提取的特征和标记好的训练数据转化为所需的二值矩阵，训练声音事件检测模型。训练过程中，模型通过学习输入数据的特征与标签之间的关系来调整自身参数，使得能够更准确地预测声音事件的类别。最后对模型进行调参等优化方法，以提高模型整体泛化能力。

在测试阶段，首先准备模型在训练阶段没有使用过的数据集，在该数据集上采取与训练阶段相同的特征提取方法进行特征提取。再使用训练好的声音事件检测模型对测试数据进行推断，预测声音事件的类别。最后为衡量模型在真实环境中的预测能力和准确性，使用评价指标（如准确率、召回率等）对模型在测试数据上的性能进行评估。



多声音事件检测可以大致分为弱监督和强监督声音事件检测。一方面，强监督包括用完全标记的数据训练模型，提供关于声音事件的时间和频谱属性的明确信息。这种显式标记允许模型直接学习声音事件的时频特征和上下文关系，从而实现更准确的声音事件检测。另一方面，在现有的公开的大规模数据集中，声音事件通常仅用类别信息进行弱标记，缺乏关于其在音频片段中的开始和偏移时间的精确信息。这主要是由于注释者难以准确定位声音事件的开始和结束时间。例如，街道上的口哨声和环境声音很容易被检测到，但确定这些声音事件的确切开始和偏移时间对注释者来说可能是一项挑战。为了预测强标签，已经进行了许多研究来利用弱标签数据进行模型训练。

### 2.1.2 特征选择与提取

在声音信号领域，特征是从声音信号中提取的数值表示，用于描述声音的各种属性和特征。特征的提取是声音信号处理和分析的关键步骤之一，它能够将复杂的声音信号转换为易于计算和分析的数学表示，为后续的模式识别、分类和分析提供基础。随着深度学习等技术的发展，各类高级特征和复杂特征被提出和应用于声音信号分析和处理中。特征的自动提取和学习方法也越来越受到关注<sup>[40]</sup>，为声音信号处理和分析提供了更加高效和准确的解决方案。常见的特征可分为以下四类：

#### (1) 时域特征

时域特征表示声音信号在时间轴上的变化情况，如振幅、过零率等。这些特征能够反映声音信号在不同时间点上的振幅和波形变化，是声音信号分析的基础。相关定义及计算公式如下：

振幅表示声波的振动强度，即声音的大小或音量。振幅越大，声音越响亮；振幅越小，声音越微弱。在声学中，振幅通常用于分析声音信号的强度和能量，并且与声音的感知特征密切相关。振幅表达式如下：

$$A = \frac{E_{\max}}{\sqrt{2}} \quad (2-1)$$

其中  $A$  表示振幅， $E_{\max}$  表示声波的最大振幅。

能量表示音频信号在一段时间内的总能量，能够方便地反映声音信号短时间内幅度的变化。在声学中，声音信号的能量可以通过对其波形进行积分得到。具体来说，能量可以通过对声波的振幅平方在时间上的积分得到，这表示声波在不同时间点上的能量总和。其计算公式如下所示：

$$E = \sum_{i=1}^N s_i^2 \quad (2-2)$$

其中， $E$  表示能量， $s_i$  表示音频信号在第  $i$  个时间点的幅度， $N$  表示信号的长度。

过零率通常用于声音信号的分析 and 特征提取。在语音识别和音频处理等应用中，过零率可以提供有关声音信号活跃度和频率的信息。过零率越高，表示信号的波形变化越频繁，信号活跃度越高。其计算公式如下：

$$ZCR = \frac{1}{N-1} \sum_{i=1}^{N-1} |\text{sgn}(s_i) - \text{sgn}(s_{i+1})| \quad (2-3)$$

其中， $ZCR$  表示过零率， $\text{sgn}(s_i)$  表示函数  $x$  的符号函数，当  $x$  大于 0 时返回 1，小于 0 时返回 -1，等于 0 时返回 0。

时域特征直接描述了声音信号在时间轴上的波形变化，由于计算简单，时域特征可以实时地从音频信号中提取，适用于需要快速响应的应用场景，如语音识别、实时通信等。这使得我们可以更容易理解声音的振幅、能量和波形形状，对于分析和处理音频信号具有重要意义。

## (2) 频域特征

频域特征描述声音信号在频率域上的频谱分布情况，如频谱图、梅尔频率倒谱系数（Mel-frequency Cepstral Coefficients, MFCC）、功率谱密度等。这些特征能够反映声音信号在不同频率上的能量分布和频谱特征，广泛应用于语音识别和音频处理领域。频域特征根据其提取方式和描述音频频谱特性的不同，有多种分类，其中较为常用的特征为基于傅里叶变换的特征和梅尔频率倒谱系数。

常见的基于傅里叶变换的特征包括频谱图和短时傅里叶变换。频谱图是将音频信号在频率和时间上进行可视化的图形表示，用于展示音频信号的频谱分布。短时傅里叶变换是对音频信号在时间上进行分段，并进行傅里叶变换的一种方法。它将音频信号分解成不同频率和时间上的振幅分量，从而可以提取音频信号的频域特征。STFT 的数学表示如下：

$$X(m, n) = \sum_{k=0}^{N-1} x(n+k) \cdot w(k) \cdot e^{-j \frac{2\pi m k}{N}} \quad (2-4)$$

其中， $X(m, n)$  表示在时间点  $n$  和频率点  $m$  处的 STFT 值， $x(n)$  表示音频信号的波形数据， $w(k)$  是窗函数， $N$  是窗口长度。

MFCC 是基于梅尔频率刻度对音频信号进行分析的一种系数，能够捕捉到人类听觉系统对音频频率的感知特性，主要用于音频信号的分析 and 识别。以下图 2-3 是提取 MFCC 的流程图。




图 2-3 MFCC 特征提取过程

Fig.2-3 MFCC feature extraction process

首先对音频信号进行预处理，通过将其转化为梅尔频率等特征信号，以突出高频部分并减少噪音；再将音频信号通过重叠等方式分成若干帧，其中每帧长度一般为 20-30ms，再通过加窗处理，将信号进行傅里叶变换得到频谱图；通过一组梅尔滤波器对频谱图进行滤波，然后对滤波后的特征进行对数变换以进行倒谱分析，从而得到能量谱；最后，对能量谱进行离散余弦变换，以得到梅尔频率倒谱系数，完成 MFCC 特征提取。

MFCC 的计算公式如下所示：

$$MFCC_i = \sum_{j=1}^M \log(\sum_{k=1}^N |X_k| H_{j,k} e^{-j2\pi f_k t}) \cdot \cos[\frac{\pi}{M} i(j-0.5)] \quad (2-5)$$

其中， $MFCC_i$  表示第  $i$  个 MFCC 系数， $M$  表示滤波器组的数量， $N$  表示频谱图的频率点数， $X_k$  表示频谱图的第  $k$  个频率点的幅度， $H_{j,k}$  表示第  $j$  个梅尔滤波器的频率响应， $f_k$  表示第  $k$  个频率点的频率， $t$  表示当前帧的时间位置， $j$  表示梅尔滤波器组的索引， $i$  表示离散余弦变换的系数。

### (3) 时频域特征

时频域特征融合了时域和频域特征，能够更全面地形容声音信号的特点。如短时傅里叶变换，其通过将音频信号分成多个短时段，在每个短时段上进行变换，得到时频图谱，其数学表达式为：

$$X(t, f) = \int_{-\infty}^{\infty} x(\tau) \omega(\tau - t) e^{-j2\pi f \tau} d\tau \quad (2-6)$$

其中， $x(t)$  是输入信号，在时域上随时间变化， $\omega(\tau - t)$  表示窗函数， $X(t, f)$  是信号在时频域上的表示，表示在时刻  $t$  和频率  $f$  处的信号幅度。

这些特征将声音信号的时域信息和频域信息结合起来，提取了声音信号的更高级别的语义信息和音乐特征。

#### (4) 高级特征

高级特征是基于以上三类特征的进一步抽象和提取的特征。常见的高级特征包括声谱图、色度特征等。这些特征通常用于音频分析和音频处理领域，提取了声音信号的更高级别的语义信息和音乐特征。

### 2.1.3 评价指标

根据声音类别可以将声音事件检测分为单声音事件检测和多声音事件检测。在单声音事件检测任务中，系统的目标是检测出音频中是否存在某单一特定类型的声音事件。而多声音事件检测任务更具挑战性，因为系统需要在复杂的环境中同时检测和识别多种声音事件，可能会出现声音的重叠或混叠情况。该任务不仅需要检测声音事件的存在与否，还需要对同时出现的多个声音事件进行准确的定位、分割和分类<sup>[41]</sup>。综上所述，多声音事件检测的评估指标大致可分为以下两大类。

#### (1) 分类指标

准确率(Accuracy)、灵敏度(Sensitivity)、召回率(Recall)、F 分数(F-Score)、错误率(Error Rate)和精确率(Precision)等这些指标可以帮助评估声音事件检测系统的性能，从不同的角度评估系统的准确性、鲁棒性和效率。其中准确率和精确率是我们用来进行音频事件检测和音频标注的常用指标，同时许多 DCASE 挑战任务中，使用了基于分段的 F 分数等指标作为研究领域的标准指标。常用分类指标的相关含义如下。

##### ①准确率

表示被正确检测的声音事件与所有声音事件的比例，用于评估分类器性能的一项重要指标。其公式如下：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-7)$$

其中，TP 表示真正例(True Positive)、TN 表示真负例(True Negative)、FP 表示假正例(False Positive)、FN 表示假负例(False Negative)。通常，准确率的值范围在 0 到 1 之间，可以转换为百分比表示。如如果一个分类器在 100 个样本中正确分类了 85 个样本，则其准确率为 0.85 或 85%。

##### ②灵敏度

精确率是用于评估模型分类器在所有被分类为正例的样本中，实际为正例的比例。它衡量了分类器的预测中有多少是正确的。精确率的相关公式如下：

$$Precision = \frac{TP}{TP + FP} \quad (2-8)$$

简单来说，精确率可以理解为分类器所做的“正例”预测中有多少是正确的。

### ③F 分数

F-Score 是一种综合性的评价指标，表示准确率和召回率的调和平均值，因此其取值区间为[0,1]，且其值越大，模型性能越好。其公式如下：

$$F = \frac{(1 + \beta^2) \times P \times R}{\beta^2 \times (P + R)} \quad (2-9)$$

其中 P 和 R 分别表示准确率和召回率。召回率的公式与准确率相似：

$$R = \frac{TP}{TP + FN} \quad (2-10)$$

### ④错误率

错误率主要用于评估系统在识别过程中的错误情况，在音频识别和检测中，为了使识别出来的和标准的词序列之间保持一致，需要进行插入、缺失或替换某些词等步骤，因此错误率也是衡量关于插入 (I)、缺失 (D) 和替换 (S) 的预测错误数。其定义式为：

$$ER = \frac{\sum_{A=1}^S I(A) + \sum_{A=1}^S D(A) + \sum_{A=1}^S S(A)}{N(A)} \quad (2-11)$$

其中  $I(A)$  表示系统错误的输出数量为插入的数量，即系统把真实标签为假的声音事件预测为真； $D(A)$  是指没有正确识别的数量为删除的数量； $S(A)$  表示和真实标签预测不同的声音事件的数量为替换的数量，即系统预测结果和真实标签相反； $N(A)$  表示声音片段  $A$  中被检测到的所有声音事件数量。三者计算公式如下：

$$\begin{cases} I(A) = \max(0, FP(A) - FN(A)) \\ D(A) = \max(0, FN(A) - FP(A)) \\ S(A) = \max(FN(A), FP(A)) \end{cases} \quad (2-12)$$

因此可得出，错误率的值与 F 值成反比，其值越接近于 0，模型的整体性能越好。

## (2) 回归指标

回归指标也是评估机器学习模型的重要指标，主要用于衡量模型预测值与真

实值之间的差异，这些指标大致可分为绝对误差指标和相对误差指标两大类：

#### ①绝对误差指标

常见的包括平均绝对误差（MAE）和均方根误差（RMSE）两大类。其中 MAE 是用来计算拟合数据与原始数据之间差值的绝对值的均值，用于衡量模型预测的平均误差大小，其值越小说明拟合效果越好。其计算公式如下：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2-13)$$

由于许多情况下，MSE 与目标变量的量纲不一致，为了解决这个问题，需要对 MSE 进行开方，即 RMSE。RMSE 是用于衡量模型预测值与真实值之间的标准差。标准误差的函数表达式如下：

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2-14)$$

上述两式中， $n$  表示样本数量， $y_i$  表示真实值， $\hat{y}_i$  表示模型预测值。

#### ②相对误差指标

常见的包括平均百分比误差（MPE）和平均绝对百分比误差（MAPE）两大类。这些相对误差指标通常以百分比的形式表示，可以更直观地了解模型预测的相对误差大小。MPE 表示预测值与真实值之间差值的百分比的均值，用于衡量模型预测的平均误差大小；MAPE 则表示预测值与真实值之间差值的百分比的绝对值的均值，用于衡量模型预测的平均绝对误差大小。上述计算公式如下：

$$MPE = \frac{1}{n} \sum_{i=1}^n \left( \frac{y_i - \hat{y}_i}{y_i} \right) \times 100\% \quad (2-15)$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\% \quad (2-16)$$

### 2.1.4 常用分类器

分类器在音频数据分析中有着广泛的应用，可以有助于处理各种类型的音频数据，并从中提取有用的音频特征信息。分类器的作用不仅限于数据分类和预测，还包括异常检测、特征提取等方面。音事件检测中常用的分类器包括传统机器学习方法和深度学习方法，其中较为常用的分类器有以下三类：

#### （1）支持向量机

SVM 最早在 1963 年由 Vladimir N. Vapnik 等人提出，其基本理论建立在几何

间隔最大化和核方法的基础上，具有很强的理论基础和广泛的应用。在面对线性可分类的问题和线性不可分类的问题上，SVM 分类器具有不同的处理途径。

#### ①线性可分类的 SVM 分类器

对于给定的训练数据集，若存在一个超平面能够将正负类样本完全分开，则称为线性可分问题。假设训练样本集为  $\{(x_i, y_i)\}$ ,  $i = 1, \dots, N$ ,  $x \in R^n$ ,  $y \in \{1, -1\}$ , 超平面决策函数的数学表达式如下：

$$f(x) = \text{sgn}(w^T x + b) \quad (2-17)$$

其中， $w$  为超平面法向量， $b$  为超平面截距； $w^T x + b = 0$  为分类的最优平面； $\frac{2}{\|w\|^2}$  为几何间隔。SVM 的优化目标是找到能够最大化间隔的超平面。因此将最大间隔分类器的优化问题表述其目标函数为：

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (2-18)$$

$$s.t. \quad y^{(i)}(w^T x^{(i)} + b) \geq 1, \text{ for } i = 1, 2, \dots, m \quad (2-19)$$

基于上述目标函数，可以找到一个  $\alpha$  进行缩放，使  $(w, b) \rightarrow (\alpha w, \alpha b)$ ，即将将上述问题转换为对偶问题，其表达式如下：

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x + b) - 1) \quad (2-20)$$

最终使得方程在支持向量  $x_0$  上有  $|w^T x_0 + b| = 1$ ，在非支持向量上有  $|w^T x_0 + b| > 1$ ，上述 min 函数的优化目标转化为符合 KKT 条件的函数表达式：

$$\min_{w,b} \max_{\alpha_i \geq 0} L(w, b, \alpha) \quad (2-21)$$

函数  $L(w, b, \alpha)$  关于  $w$  和  $b$  的偏导数如下：

$$\begin{cases} \frac{\partial L}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i \\ \frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0 \end{cases} \quad (2-22)$$

因此，min 函数中求最大几何间隔的优化问题可转化为：

$$L(w, b, \alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \quad (2-23)$$

$$s.t. \begin{cases} \alpha_i \geq 0 & i=1, \dots, n \\ \sum_{i=1}^n \alpha_i y_i = 0 \end{cases} \quad (2-24)$$

### ①线性不可分类的 SVD 分类器

在处理该类问题时，可以引入核函数将原始输入空间映射到更高维的特征空间。常用的核函数包括：

- 线性核函数：  $K(x_i, x_j) = x_i^T x_j$
- 多项式核函数：  $K(x_i, x_j) = (\gamma x_i^T x_j + r)^d$
- 高斯径向基函数（RBF）核函数：  $K(x_i, x_j) = \exp(-\frac{\|x_i - x_j\|^2}{2\sigma^2})$

再对 SVM 引入软间隔最大化概念，在函数式中引入松弛变量  $\xi_i$  和惩罚参数  $C$ ，使软间隔最大化的优化目标变为：

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i \quad (2-25)$$

$$s.t. \begin{cases} y^{(i)}(w^T x^{(i)} + b) \geq 1 - \xi_i, \text{ for } i=1, 2, \dots, m \\ \xi_i \geq 0, \text{ for } i=1, 2, \dots, m \end{cases} \quad (2-26)$$

同理可得其拉格朗日对偶函数关系式如下：

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \Phi(x_i)^T \Phi(x_j) - \sum_{j=1}^N \alpha_j \quad (2-27)$$

$$s.t. \begin{cases} \sum_{i=1}^N y_i \alpha_i \\ C \geq \alpha_i \geq 0, i=1, \dots, N \end{cases} \quad (2-28)$$

对于软间隔最大化问题，除拉格朗日对偶性外，也可以使用 KKT 条件等方法求解。通过求解优化问题，得到最优的超平面和对应的支持向量。

### （2）高斯混合模型

高斯混合模型是由多个高斯分布（也称为正态分布）组合而成的混合模型，每个高斯分布对应于数据集中的一个潜在的分布成分。

假设有  $K$  个高斯分布组成混合模型，每个高斯分布  $k$  具有其自己的均值  $\mu_k$  和协方差矩阵  $\Sigma_k$ ，以及混合系数  $\pi_k$ ，表示数据点属于第  $k$  个分布的概率。其概率密度函数如下：



$$p(x) = \sum_{k=1}^K \pi_k N(x | \mu_k, \Sigma_k), \quad (2-29)$$

其中  $N(x | \mu_k, \Sigma_k)$  表示多维高斯分布的概率密度函数。

在给定数据集  $\{x_1, x_2, \dots, x_N\}$  后，可以通过最大似然估计、期望最大化（EM）等方法来估算模型参数，包括每个高斯分布的均值  $\mu_k$ 、协方差矩阵  $\Sigma_k$  和混合系数  $\pi_k$ 。最大化对数似然函数表达式如下：

$$\log p(\{x_1, x_2, \dots, x_N\} | \theta) = \sum_{i=1}^N \log(\sum_{k=1}^K \pi_k N(x_i | \mu_k, \Sigma_k)), \quad (2-30)$$

其中， $\theta$  表示模型参数  $\{\mu_k, \Sigma_k, \pi_k\}_{k=1}^K$ 。

EM 算法则是一种迭代算法。在 E 步骤中，通过计算每个数据点属于每个高斯分布的后验概率来更新隐藏变量；在 M 步骤中，通过最大化完全数据的对数似然函数来更新模型参数，最后重复这两个步骤直到收敛。相关计算公式如下：

$$\begin{cases} \mu_k = \frac{\sum_{i=1}^N \gamma(i, k) x_i}{\sum_{i=1}^N \gamma(i, k)} \\ \Sigma_k = \frac{\sum_{i=1}^N \gamma(i, k) (x_i - \mu_k)(x_i - \mu_k)^T}{\sum_{i=1}^N \gamma(i, k)} \\ \pi_k = \frac{\sum_{i=1}^N \gamma(i, k)}{N} \end{cases} \quad (2-31)$$

在最后的模型评估阶段，通常使用负对数似然函数或信息准则（如 AIC 和 BIC）来评估模型的拟合优度。

### （3）隐马尔可夫模型

隐马尔可夫模型由两组随机变量组成，分别由观测序列  $O = \{o_1, o_2, \dots, o_t\}$  和隐藏序列  $Q = \{q_1, q_2, \dots, q_t\}$  组成，其中， $t$  表示序列的长度。

隐马尔可夫模型包含一个有限的状态空间，状态之间的转移由转移概率矩阵  $A$  描述，其中  $a_{ij}$  表示从状态  $i$  转移到状态  $j$  的概率：

$$a_{ij} = P(i_{t+1} = q_j | i_t = q_i), 1 \leq i, j \leq N \quad (2-32)$$

观测概率由观测概率矩阵  $B$  描述，其中  $b_j(o_t)$  表示在状态  $j$  下观测到观测值  $o_t$  的概率，函数表达如下：

$$b_j(k) = P(o_t = v_k | i_t = q_j), 1 \leq j \leq N, 1 \leq k \leq M \quad (2-33)$$

模型在初始状态下的概率分布由  $\Pi$  表示，其中  $\pi(i)$  表示初始时系统处于状态  $i$  的概率：

$$\pi(i) = P(i_1 = q_i) \quad (2-34)$$

隐马尔可夫模型的大多数应用最终归结为解决评估问题：给定一个隐马尔可夫模型  $\lambda = (A, B, \Pi)$  和观测序列  $O = o_1, o_2, \dots, o_t$ ，得到观测序列  $O$  在模型  $P(O|\lambda)$  出现的概率；给定一个隐马尔可夫模型  $\lambda = (A, B, \Pi)$  和观测序列  $O = \{o_1, o_2, \dots, o_t\}$ ，得到最可能的隐藏状态序列  $Q = \{q_1, q_2, \dots, q_t\}$ 。关于学习问题可归结为，给定模型  $\lambda$  和观测序列  $O = \{o_1, o_2, \dots, o_t\}$  的学习问题，通过调整模型参数  $\lambda = (A, B, \Pi)$  以使  $P(O|\lambda)$  最大化。

最后根据贝叶斯公式，可以通过前向算法、后向算法或者维特比算法来计算该概率。

## 2.2 弱标注数据下的声音事件检测

### 2.2.1 基础理论

随着人工智能和机器学习技术的不断发展，弱标注数据下的声音事件检测成为最近正在不断发展的研究领域。在声音事件检测领域，由于获取具有准确标记的大规模数据集通常需要专业的人员进行手动标注，而这不仅费时费力，而且可能受限于标注者主观因素，导致标注的不准确性或不完整性。随着声音事件检测在各领域内的研究不断发展，半监督学习、迁移学习、数据增强等方法被广泛引入到声音事件检测中。这些基础理论的研究和应用为解决弱标注数据下的声音事件检测问题提供了理论基础和方法支持，为模型的训练和应用提供了有效的技术手段。

同样，弱标注数据下的声音事件检测可以被看作是多实例学习（Multiple Instance Learning, MIL）的一种应用<sup>[42][43]</sup>。在多实例学习中，训练样本被组织成“袋（bag）”的形式，每个“袋”包含多个实例，而每个实例可能属于正类或负类，但“袋”的标签通常是不确定的。在声音事件检测中，每个“袋”可以代表一段音频数据片段，而每个实例则是这段音频数据片段的子片段。而这些“袋”的标签通常是不完整或不准确的，即只知道这段音频片段是否包含目标事件，而

不知道具体的事件位置或事件类型。因此，将弱标注数据下的声音事件检测视为多实例学习，会更有助于理解声音事件的本质，并得到更好的声音时间检测模型。

### 2.2.2 多实例学习

多实例学习是一种特殊的监督学习方法，用于处理数据集中标签不完整或不准确的情况。近些年，多实例学习被广泛应用于许多领域，如医学影像分析、文本分类、目标检测和声音事件检测等。在声音事件检测中，多实例学习可以用来处理标签不完整或不准确的情况，从而提高模型对于目标事件的检测性能。常见的多实例学习算法包括标准多实例学习（Standard MIL）、传统的多实例学习算法（Traditional MIL Algorithms）、深度多实例学习（Deep MIL）等。在文献<sup>[44]</sup>中，作者介绍了基于多实例学习的声音事件检测模型的设计和实现。通过使用卷积递归神经网络（CRNN）架构来预测强（即时变）标签，这些标签被聚合形成弱预测。使用软最大聚合从弱标记数据中学习强（时间局部化）预测因子，即从弱标记数据中训练模型，并通过时间聚合算子传播学习信号，以告知强预测。

多实例学习在面对不同问题时可以分标准多实例学习、传统多实例学习算法、深度多实例学习和部分标记多实例学习等范式。在面对传统问题时，使用传统的多实例学习算法，将多实例学习问题转化为标准监督学习问题，如通过将每个袋的特征进行聚合，然后使用传统的分类器进行预测。来直接处理袋级别的特征表示和标签预测，或者对实例进行聚合以获得袋级别的表示。在面对深度学习问题时，采用深度多实例学习，利用深度神经网络来学习袋的表示和标签预测。这些方法通常采用神经网络模型来对袋中的实例进行建模，并通过端到端的方式进行训练。

### 2.2.3 基于多实例学习的弱标注声音事件检测

弱标注数据为训练数据的标签可能不完整或不准确，而利用多实例学习去处理这类声音数据能有效地标记不完整的训练数据，从而实现对音频中目标时间的检测。图 2-4 介绍了基于多实例学习的弱标注声音事件检测模型的常见流程。




图 2-4 基于多实例学习的弱标注声音事件检测流程

Fig.2-4 Weak annotated sound event detection process based on MIL

该流程主要包括五个方面：

(1) 构建数据“袋”

首先将音频数据划分为  $N$  个音频袋，每个袋  $B_i$  代表  $M_i$  个音频实例，而每个实例则是这段音频的子片段。袋级别的标签  $y_i$  则表示整个音频是否包含目标事件，取值为 1（正类）或 0（负类）。

(2) 提取音频特征

在构建完袋后，对每个实例进行特征提取，得到实例的特征向量。这些特征向量可以是时频域特征（如梅尔频率倒谱系数、时域特征等）或深度学习模型提取的音频特征。模型的输出  $f_i$  可以表示为：

$$f_i = \text{sign}(\sum_{j=1}^{M_i} w^T x_{ij} + b) \quad (2-35)$$

其中  $\text{sign}(\cdot)$  是符号函数，用于将模型的输出映射到二分类标签 1 或 0。 $x_{ij}$  表示袋  $B_i$  中第  $j$  个实例的特征向量， $w$  表示模型的权重向量， $b$  表示模型的偏置项。

(3) 模型训练

使用多实例学习算法训练模型，以学习声音事件的特征表示。其中基于多实例学习的带有正则化项的损失函数表达式如下：

$$J = \min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i(w^T \phi(B_i) + b)) \quad (2-36)$$

其中， $w$  是模型的权重向量， $C$  是正则项系数， $\phi(B_i)$  是袋  $B_i$  的特征表示。损失函数的目标是最小化模型参数  $w$  和  $b$ ，同时保持模型的预测性能。

(4) 模型预测

对于每个测试袋  $Q_i$ ，模型输出一个预测概率  $f_i$ ，表示该袋中是否存在目标事

件。表达式如下：

$$\hat{y}_{ij} = f_i, \quad j = 1, 2, \dots, M_i \quad (2-37)$$

其中， $\hat{y}_{ij}$  表示测试音频袋  $Q_i$  中第  $j$  个实例的预测标签， $f_i$  表示袋级别的预测结果。

### (5) 后处理

根据实际需求对模型输出进行后处理，较常用的方法为二值化阈值，通过将模型输出的概率值与预定义的阈值进行比较，或使用后处理算法对事件进行后续处理和分析。

## 2.3 深度学习基础理论

深度学习 (deep learning) 是机器学习的一个分支，其核心思想是通过模仿人类大脑神经元之间的连接方式来学习和理解复杂的数据模式。深度学习为监督学习提供了一个强大的框架。

### 2.3.1 深度学习原理

深度学习的核心思想是通过多层次的神经网络结构来逐层提取数据的特征表示，并使用这些特征表示进行任务的学习和预测。深度学习模型通常由输入层、多个隐层和输出层组成，每一层都包含多个神经元（节点），神经元之间通过权重连接进行信息传递和处理。

较为常见的深度学习模型为深度前馈网络（deep feedforward network），下图为深度前馈网络的结构示意图。




图 2-5 深度前馈网络结构示意图

Fig.2-5 Schematic diagram of deep feedforward network structure

前馈网络的目标是近似某个函数  $f^*$ ，它通过定义了一个映射  $y = f(x; \theta)$ ，并且学习参数  $\theta$  的值，以获得最佳的函数近似。前馈网络可被视为一种高效的非线性函数近似器。该模型被称为前向的，因为信息从输入  $x$  流经用于定义  $f$  的中间计算过程，最终到达输出  $y$ 。在模型的输出和模型本身之间不存在反馈连接。

深度学习的原理大致可分为以下五步：

#### (1) 前向传播 (Forward Propagation)

深度学习所需的数据首先经过神经网络各层，通过加权和和激活函数得到每个神经元的输出向量：

$$\begin{cases} z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)} \\ a^{(l)} = \sigma(z^{(l)}) \end{cases} \quad (2-38)$$

其中， $l$  表示网络的层数， $W^{(l)}$  和  $b^{(l)}$  分别表示第  $l$  层的权重和偏置， $a^{(l-1)}$  是上一层的输出， $\sigma(\cdot)$  是激活函数。

#### (2) 计算损失 (Compute Loss)

通常情况下，损失函数（或成本函数）用于量化模型输出与真实标签之间的误差。常见的损失函数包括均方误差等。

#### (3) 反向传播 (Backward Propagation)

反向传播是基于链式法则的一种方法，是通过将损失函数的梯度从网络的输出层向输入层进行传播，以便计算每一层的参数梯度。第  $l$  层的权重  $W^{(l)}$  和偏置  $b^{(l)}$  的梯度计算如下：

$$\begin{cases} \frac{\partial L}{\partial W^{(l)}} = \frac{\partial L}{\partial z^{(l)}} \bullet \frac{\partial z^{(l)}}{\partial W^{(l)}} = \delta^{(l)} (a^{(l-1)})^T \\ \frac{\partial L}{\partial b^{(l)}} = \frac{\partial L}{\partial z^{(l)}} \bullet \frac{\partial z^{(l)}}{\partial b^{(l)}} = \delta^{(l)} \end{cases} \quad (2-39)$$

其中  $\delta^{(l)}$  表示第  $l$  层的误差项，可以通过上层的误差项与当前层的激活函数求得。

#### (4) 参数更新 (Update Parameters)

在深度学习中，参数学习是通过优化算法根据损失函数的梯度来调整神经网络模型的参数，以最小化损失函数。目前较为常用的优化算法包括梯度下降、随机梯度下降、动量法、Adam 等

#### (5) 重复迭代 (Iterate)

在不断重复以上深度学习步骤后，在达到最大设定迭代次数或损失函数收敛时停止迭代，并输出最终结果。

深度学习在多个领域都得到广泛应用，包括图像识别、语音识别、自然语言处理、医疗影像分析和智能驾驶等。例如，在图像识别方面，卷积神经网络等深度学习模型已经取得了显著进展。在语音识别领域，循环神经网络和 Transformer 等模型被广泛应用于语音识别和合成任务，取得了令人瞩目的成果。而在自然语言处理领域，诸如循环神经网络、长短期记忆网络和 Transformer 模型等深度学习方法已经成为文本生成、机器翻译和情感分析等任务的主流方法，且在这些任务上取得了最先进的效果。

### 2.3.2 卷积神经网络

相较于传统的神经网络，卷积神经网络的每一个子集都由宽带、高带和深带三方面组成。CNN 在计算机视觉领域取得了巨大成功，被广泛应用于音频事件分类、目标检测等任务。

CNN 通过前向传播，将输入的数据经过多层处理后，得到最终分类识别的结果。以 VGG 网络为例<sup>[45]</sup>，其输入的数据维度为  $224 \times 224$ ，不同层神经元的连接方式固定，经过两层卷积后，输入数据维度不变，但通道数增加至 64。再通过最大池化将输入数据维度变为  $112 \times 112$ ，通过不断重复前面步骤，直至数据变为 1 维向量后，经过全连接和 ReLU 激活函数，以及 softmax 处理后，得到输出层的维度为 1000 个数字特征向量。由上述可知，CNN 的模型架构可由下图表示：




图 2-6 卷积神经网络模型架构

Fig.2-6 Convolutional neural network model architecture

其中，传统的 CNN 主要由卷积层（Convolutional Layer）、池化层（Pooling Layer）和全连接层（Fully Connected Layer）组成。

#### （1）卷积层

卷积层可以用来提取声音数据中的时域或频域特征。可以将声音信号的频谱图作为输入，通过卷积操作来捕获频谱图中的局部模式。具体来说为使用一个权重矩阵用来覆盖输入数据，通过加权等操作后形成一个新矩阵。这里的权重矩阵为卷积核（convolution kernel）其通常会包含多个卷积核，利用不同卷积核提取

不同特征的特性，CNN 卷积层可以同时提取更丰富的音频特征。卷积层的运算如下：

$$H_p^l = \sigma \left( \sum_q [W_{pq}^l * H_q^{l-1}] + B_p^l \right) \quad (2-40)$$

其中， $H_p^l$  表示  $l$  层输出的第  $p$  个特征图， $W_{pq}^l$  和  $B_p^l$  是卷积核和偏置向量的二维切片， $\sigma$  表示非线性激活函数。

卷积网络的连通性大小由称为感受野的超参数控制。举例来说，假设声音检测任务中使用了一个 CNN 模型，其中的第一个卷积层的卷积核大小为  $3 \times 3$ ，步幅为 1，无填充。那么在输出特征图上的一个像素点的感受野大小为输入声音信号上的  $3 \times 3$  区域。通过调整卷积核的大小、步幅和填充等参数，可以控制感受野的大小。

一般来说，在声音事件检测中通常使用 1D 卷积层来处理声音数据。例如以音频采样率为 20kHz 的情况下，可以每秒采样 20000 个数据点，再将这些音频点传至卷积层进行后续操作。

## (2) 池化层

卷积层输出后的特征数据传至池化层。在声音数据中，可以使用时间上的池化操作来降低时间维度，例如对频谱图进行最大池化操作，选取每个时间窗口内的最大值作为池化后的值。其公式如下：

$$MaxPooling(x_{i,j}) = \max_{m,n} x_{m,n} \quad (2-41)$$

其中  $x_{i,j}$  表示输入特征图中位置  $(i, j)$  处的值， $x_{m,n}$  表示以位置  $(i, j)$  为中心的池化窗口中的值， $\max_{m,n}$  表示在池化窗口内取最大值。

## (3) 全连接层

全连接层通常位于网络的顶部，用于将卷积层提取的特征进行整合和分类。对于声音事件检测任务，可以将卷积层提取的特征映射到各种声音事件的类别标签上，获得分类模型并得到最终结果。全连接层中通常会应用激活函数，包括 ReLU (Rectified Linear Unit)、Tanh 等。

CNN 还具有平移不变性的特性。在声音检测的应用中，CNN 通常会接受声音信号的原始波形作为输入，由于 CNN 的平移不变性特性，即使声音信号的声音事件在时间轴上发生了平移，模型仍然能够准确地识别其中的声音事件。这使得 CNN 成为处理声音检测任务的有效工具，例如识别说话声、咳嗽声等。



### 2.3.3 循环神经网络

与传统的前馈神经网络不同，循环神经网络（RNN）具有反馈连接，允许信息在网络内部循环传递。其主要架构如图 2-7 所示：




图 2-7 循环神经网络模型架构

Fig.2-7 Architecture of recurrent neural network model

将输入序列用  $X = \{x^{(1)}, x^{(2)}, \dots, x^{(T)}\}$  表示，其中  $x^{(t)}$  是时间步长  $t$  的输入向量， $T$  是序列的长度。每个输入向量  $x^{(t)}$  可以是一个单词的词向量、一个时间步的特征向量等。RNN 的隐藏状态  $h^{(t)}$  在每个时间步长  $t$  的更新规则可以使用递归方式表示如下：

$$h^{(t)} = f(x^{(t)}, h^{(t-1)}) \quad (2-42)$$

其中  $h^{(t-1)}$  是上一个时间步  $t-1$  的隐藏状态， $f(\cdot)$  是一个非线性激活函数。这个更新规则还可以分为计算当前时间步的输入到隐藏层的加权和，以及激活函数计算隐藏状态两步。在时，可以通过下式进行求解：

$$\begin{cases} a^{(t)} = W_{xh}x^{(t)} + W_{hh}h^{(t-1)} + b_h \\ h^{(t)} = f(a^{(t)}) \end{cases} \quad (2-43)$$

其中， $W_{xh}$  是输入到隐藏层的权重矩阵， $W_{hh}$  是隐藏层到隐藏层的权重矩阵， $b_h$  是隐藏层的偏置向量。通过这个更新规则，RNN 可以在处理序列数据时利用过去的信息，并在每个时间步更新隐藏状态以适应新的输入。双向循环神经网络（Bidirectional RNN, BRNN）被设计为结合正向和反向两个方向的信息，在每个时间步都考虑了过去和未来的信息。它由两层 RNN 组成，通过正向循环层、反向循环层、连接层等神经网络结构将输入序列沿时间轴处理，生成综合隐藏状态

序列。BRNN 的计算公式如下：

$$\vec{h}_t^l = \sigma(\vec{U}^l \vec{h}_{t-1}^l + W^l h^{l-1} + \vec{b}^l) \quad (2-44)$$

$$\bar{h}_t^l = \sigma(\vec{U}^l \bar{h}_{t-1}^l + W^l h^{l-1} + \vec{b}^l) \quad (2-45)$$

其中正向递归参数为  $\vec{U}^l$ ，正向偏置项为  $\vec{b}^l$ ，反向偏置项为  $\vec{b}^l$ ，正向传播链第  $l$  层的时间步  $t$  的值为  $\vec{h}_t^l$ ， $\bar{h}_t^l$  为该隐藏层的反向传播的值。在文献<sup>[46]</sup>中，通过使用 BRNN 模型，利用其在序列数据建模方面的优势来处理语音信号，将其应用于语音识别任务。但由于 BRNN 存在内存消耗大、训练相对复杂等问题，使得模型在处理长序列数据时可能会出现梯度消失或爆炸的情况。为此，研究者们提出了优化算法以改进 RNN，如 LSTM 和 GRU。LSTM 的结构如图 2-8 所示。




图 2-8 长短时记忆网络模型架构

Fig.2-8 Architecture of long short term memory network model

LSTM 包括遗忘门、输入门、更新记忆细胞和输出门等架构。LSTM 通过记忆单元来过滤掉与任务无关的数据，同结合输出门更新隐藏状态。可通过如下公式计算出第  $l$  层的细胞状态候选值  $C_t$ ：

$$\begin{cases} f_t = \sigma(W_f \cdot x_t + U_f \cdot h_{t-1} + b_f) \\ i_t = \sigma(W_i \cdot x_t + U_i \cdot h_{t-1} + b_i) \\ \tilde{C}_t = \tanh(W_C \cdot x_t + U_C \cdot h_{t-1} + b_C) \\ o_t = \sigma(W_o \cdot x_t + U_o \cdot h_{t-1} + b_o) \\ C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \\ h_t = o_t \cdot \tanh(C_t) \end{cases} \quad (2-46)$$

其中,  $f_t$  是遗忘门的输出,  $x_t$  是当前时间步的输入序列,  $h_t$  是当前时间步的隐藏状态,  $C_t$  是当前时间步的记忆细胞。  $W$ 、 $U$  和  $b$  是待学习的权重参数,  $\tanh(\cdot)$  是双曲正切函数。

LSTM 和 GRU 都采用了门控机制来控制信息的流动, 从而有效地捕捉序列数据中的长期依赖关系。与 LSTM 不同, GRU 则简化其内部门控结构, 将遗忘门和输入门合并为一个更新门, 同时合并了记忆细胞和隐藏状态, 因此参数量较少, 无论是其泛化能力还是模型训练速度都要更好, 在实现部分大型音频数据任务时能够表现出更好的性能。其网络结构如下:




图 2-9 门控循环单元网络结构

Fig.2-9 Gated recurrent unit network structure

从上图可以看出, GRU 对 LSTM 的内部结构进行了微调, 其中更新门  $z_t$  的作用与遗忘门相似。同时将输入门和更新门两个门耦合在一起, 加入了重置门 (Reset Gate), 确定了上一个隐藏状态如何影响当前时间步的输入。最后通过不断更新并计算隐藏状态整合候选隐藏状态, 得到当前时间步的最终隐藏状态。其定义式如下:

$$\begin{cases} z_t = \sigma(W_z \cdot x_t + U_z \cdot h_{t-1} + b_z) \\ r_t = \sigma(W_r \cdot x_t + U_r \cdot h_{t-1} + b_r) \\ \tilde{h}_t = \tanh(W_h \cdot x_t + U_h \cdot (r_t \otimes h_{t-1} + b_h)) \\ h_t = (1 - z_t) \otimes h_{t-1} + z_t \otimes \tilde{h}_t \end{cases} \quad (2-47)$$

GRU 通过更新门和重置门来控制信息的流动, 从而有效地捕捉序列数据中的长期依赖关系。

#### 2.3.4 常用激活函数和损失函数

常用的激活函数在深度学习中起着决定性作用，它们用于引入非线性特征和评估模型的性能。

### ①ReLU

$$f(x) = \max(0, x) \quad (2-48)$$

ReLU 将负输入值置为 0，保持正值不变。解决了梯度消失问题，能够在训练过程中加速收敛。

### ②Sigmoid 函数

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-49)$$

Sigmoid 函数将输入值压缩到区间(0,1)内用于产生概率值，有助于梯度传播。

### ③Tanh 函数

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-50)$$

Tanh 函数将输入值压缩到区间(-1,1)内，相较于 Sigmoid 函数，Tanh 函数的输出范围更广，能够提供更多的非线性性。

### ④Leaky ReLU

$$f(x) = \begin{cases} x, & \text{if } x > 0 \\ \alpha x, & \text{otherwise} \end{cases} \quad (2-51)$$

Leaky ReLU 函数是对 ReLU 函数的改进，允许负输入值有一个小的斜率  $\alpha$ ，解决了 ReLU 死亡问题，既保证了负值区域也有梯度。

### ⑤Softmax 函数

$$f(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (2-52)$$

Softmax 函数通常用于多分类任务的输出层，将原始输出转换为概率分布，有助于进行梯度传播。

不同任务通常需要使用不同的损失函数来评估模型的性能，其中分类任务和回归任务较为常见。下表是针对这两类任务的损失函数及其表达式：

表 2-1 适用于分类任务和回归任务的损失函数

| Table 2-1 Loss function applicable to classification and regression tasks |                        |                                                                                                                                                                                                |
|---------------------------------------------------------------------------|------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 任务                                                                        | 损失函数                   | 损失函数表达式                                                                                                                                                                                        |
| 分类任务                                                                      | 用于二分类任务的交叉熵损失函数        | $L(y, \hat{y}) = -(y \log(\hat{y}) + (1 - y) \log(1 - \hat{y}))$                                                                                                                               |
|                                                                           | 用于多分类任务的交叉熵损失函数        | $L(y, \hat{y}) = -\sum_i y_i \log(\hat{y}_i)$                                                                                                                                                  |
|                                                                           | 用于二分类任务的对数损失函数         | $L(y, \hat{y}) = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y})$                                                                                                                                 |
|                                                                           | 用于 SVM 等任务的 Hinge 损失函数 | $L(y, \hat{y}) = \max(0, 1 - y \cdot \hat{y})$                                                                                                                                                 |
| 回归任务                                                                      | 交叉熵损失函数                | $L(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$                                                                                                                                 |
|                                                                           | 对数损失函数                 | $L(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n  y_i - \hat{y}_i $                                                                                                                                   |
|                                                                           | Hinge 损失函数             | $L(y, \hat{y}) = \begin{cases} \frac{1}{2} (y_i - \hat{y}_i)^2, & \text{if }  y_i - \hat{y}_i  \leq \delta \\ \delta ( y_i - \hat{y}_i  - \frac{1}{2} \delta), & \text{otherwise} \end{cases}$ |

## 2.4 本章小结

本文详细论述了多声音事件检测和神经网络的基础知识。首先对多声音事件检测的定义、分类、系统框架以及评价指标进行了详细讨论，包括特征选择与提取，以及常用的分类器，如高斯混合模型、支持向量机和隐马尔可夫模型。接着介绍了弱标注下的多声音事件检测，重点解释了多实例学习的基本原理，并探讨了其在弱标注的多声音事件检测方面的应用。此外介绍了目前常用的两个神经网络模型：卷积神经网络和循环神经网络；探讨了深度学习的基本原理、输入数据在神经网络中的传播过程以及优化方法，为后续研究做了准备。

### 3 基于胶囊网络模型的声音事件检测

声音事件检测在实际应用中得到了广泛的应用，涵盖了诸如环境监测、语音识别等多个领域。近年来，深度学习技术的发展为声音事件检测带来了新的机遇，有效解决了传统的声音事件检测方法受限于特征表达和模型结构的设计。其中，胶囊网络模型作为一种新兴的深度学习模型，具有对空间层级结构的更好建模能力，从而有望提高声音事件检测的性能和鲁棒性。

#### 3.1 声音事件检测常用特征

音频特征根据其提取方式不同，主要有过零率（ZCRs）、短时能量（STE）、时域包络、Log-Mel 谱图、语谱图和频谱图等等，这些特征提取方法常常用于训练声音事件检测模型或进行实时检测。其中 Log-Mel 谱图被广泛用于声音事件检测<sup>[40]</sup>，并取得了最优的单特征实验结果。

Log-Mel 频谱图结合了 Mel 频率滤波器组和对数变换，能够很好地模拟人耳的听觉特性，并将原始音频信号转换为更具有区分性和可区分性的特征表示。其经过梅尔滤波器处理后，能让输入特征更集中于人类语音和声音时间的重要范围。其特征的可视化如下图所示：




图 3-1 音频信号特征可视化图

Fig.3-1 Visual representation of audio signal features

由上图可知，Log-Mel 频谱图将原始音频信号转换为频谱图，其中横轴表示时间（Time），纵轴表示 Mel 频率（Hz），每个点的值表示在该时间点上对应频

率的能量。在预处理时,首先将音频信号分为短时窗口,通常采用窗口大小为 20ms 到 50ms 之间的长度,并且可以使用 50%至 75%的重叠。同时对每个窗口应用时域窗函数和傅里叶变换,以将其转为频域信号。将频域信号通过一组梅尔滤波器,这些滤波器的频率划分是非线性的,更符合人耳的感知。最后通过能量计算和对数变换得到每个滤波器的对数能量值,整合形成的特征向量,即为 Log-Mel 频谱图。

最终得到的特征表示是一个二维矩阵  $F_m^i$ , 其中  $i$  表示帧索引,  $m$  表示梅尔滤波器索引, 每一行表示一个时间窗口, 每一列表示一个梅尔滤波器的能量值。本文通过实验发现, 利用 Log-Mel 频谱图可以有效表示音频特征, 从而对后续声音事件检测模型的构建起到很好的导向。

本节还进行了过零率和短时能量的对比实验, 其中利用 Log-Mel 频谱图的特征实验精度最高, 具体结果如下:

表 3-1 特征对比实验

Table 3-1 Feature comparison experiment

| 特征            | F1-score     | Accuracy     |
|---------------|--------------|--------------|
| <b>Logmel</b> | <b>57.9%</b> | <b>91.8%</b> |
| ZCRs          | 35.8%        | 71.4%        |
| STE           | 42.6%        | 83.1%        |

## 3.2 胶囊网络

与传统神经网络相比, 胶囊网络通过动态路由准确捕获了句子中单词之间的上下文关系。这解决了 CNN 在表示特征角度、相对位置方面的局限性, 并避免了由于池化引起的信息丢失。此外, 胶囊网络自动调整胶囊以提取重叠特征, 从而增强了整体模型识别目标的能力。最近的研究显示, 胶囊网络用于声音事件检测取得了可喜的结果。在这项研究中, 门控卷积网络被用来提取特征, 然后被胶囊网络模型用于声音事件的检测和识别。作为胶囊网络核心的动态路由算法可以被视为一个注意力机制, 它学习和训练多个属性, 如目标形状和位置, 同时保留关键特征。胶囊网络还被应用于弱标记声音事件检测<sup>[47]</sup>, 通过构建胶囊网络模型训练一个可以隐式学习全局一致性的网络, 应用于 DCASE 2017 挑战赛中, 显示

出了较好的性能。因此，胶囊网络模型是本文的焦点。

胶囊网络旨在克服传统网络结构（如 CNN）的一些局限性。如下图所示，胶囊网络的整体框架可以分为两个部分：编码器（Encoder）和解码器（Decoder）。




图 3-2 胶囊网络整体框架结构

Fig.3-2 The overall framework of capsule network

编码部分由具有修正线性单元（ReLU）的卷积层（例如 ReLU Conv1）、主胶囊层和第二胶囊层组成；解码部分包括多个带有非线性激活函数 ReLU 和 Sigmoid 的全连接层（例如 FC ReLU 和 FC Sigmoid）。编码器旨在接收音频输入（例如 Log-Mel 频谱图）并生成更紧凑的嵌入。在第二胶囊层中，突出显示的框架是系统学习重建的遮罩框架。

传统神经网络中神经元的输入和输出只能表达提取特征的可能性，而不考虑它们的空间关系。相比之下，胶囊网络利用胶囊作为基本组件，由多个神经元组成，每个神经元由一个向量表示。值得注意的是，这些神经元的输入和输出都是向量，其中输出值表示实体存在的概率，范围在 0 到 1 之间。这些向量的大小和方向相应地指示了胶囊的可能性和属性。表 1 展示了向量神经元（VN）和标量神经元（SN）之间的差异。

表 3-2 矢量神经元(VN)和标量神经元(SN)间的区别

Table 3-2 Differences between vector neurons(VN) and scalar neurons(SN)

|             |                           | VN                                  | SN                         |
|-------------|---------------------------|-------------------------------------|----------------------------|
| 输入 (Input)  |                           | $u_i$                               | $x_i$                      |
| 操作          | 转型 (Transformation)       | $\hat{u}_{j i} = W_{ij} u_i$        | -                          |
| (Operation) | 加权求和 (Weighted summation) | $s_j = \sum_i c_{ij} \hat{u}_{j i}$ | $a_j = \sum_i w_i x_i + b$ |



|                              |                                                                 |                |
|------------------------------|-----------------------------------------------------------------|----------------|
| 非线性激活 (Nonlinear activation) | $v_j = \frac{\ s_j\ }{1 + \ s_j\ ^2} \cdot \frac{s_j}{\ s_j\ }$ | $h_j = g(a_j)$ |
| 输出 (Output)                  | $v_j$                                                           | $h_j$          |

在这个表格中,  $x_i, i=1,2,\dots,n$ , 表示标量神经元的输入,  $w_i, i=1,2,\dots,n$ , 表示相应的权重,  $b$  表示偏置。变量  $u_i, i=1,2,\dots,n$  表示较低层次的胶囊, 而  $\hat{u}_i, i=1,2,\dots,n$  表示较低层次胶囊对于较高层次胶囊的预测,  $\sum$  表示对输入进行求和运算,  $c_{ij}$  表示不同层次向量元素之间的耦合系数,  $s_j$  表示当前层胶囊向量的输入, 它是预测向量的加权和。在向量神经元的前向传播过程中, 不同的胶囊通过动态路由机制相互作用, 遵循表 3-2 中的算法过程。在标量神经元的前向传播过程中, 输入  $x_i$  和权重的乘积被求和形成标量  $a_j$ , 然后通过非线性函数转换成输出  $h_j$ 。

胶囊网络的动态路由算法计算过程如下所述:

$$\begin{cases} \hat{u}_{j|i} = W_{ij}u_i \\ s_j = \sum_i c_{ij}\hat{u}_{j|i} \\ v_j = \frac{\|s_j\|}{1 + \|s_j\|^2} \cdot \frac{s_j}{\|s_j\|} \end{cases} \quad (3-1)$$

其中,  $\hat{u}_{j|i}$  表示从  $u_i$  到  $v_j$  的预测,  $W_{ij}$  表示相应的权重矩阵,  $v_j$  表示胶囊  $j$  的输出向量。向量  $s_j$  经过压缩和归一化的压缩非线性函数处理, 得到单位范数的  $c_{ij}$ :

$$c_{ij} = \frac{\exp(b_{ij})}{\sum_k \exp(b_{ik})} \quad (3-2)$$

在这里, 参数  $b_{ij}$  用于更新耦合系数, 其初始值通常设置为 0, 如下所示的方程所示:

$$b_{ij} \leftarrow b_{ij} + \hat{u}_{j|i} \cdot v_j \quad (3-3)$$

在每次前向传播过程中, 根据  $b_{ij}$  计算  $v_j$  的值。通过对  $b_{ij}$  进行迭代更新以及随后对  $c_{ij}$  的更新, 最终获得最佳的耦合系数。

## 3.3 网络架构

### 3.3.1 并行门控卷积

门控卷积（Gated Convolution）是一种深度学习中的 CNN 结构，在语音处理和文本处理等领域中广泛应用。门控卷积通常由两部分组成：卷积操作和门控单元。其中，卷积操作用于捕捉输入序列中的局部特征，而门控单元用于控制信息的流动，有助于网络选择性地记忆和遗忘信息。门控卷积自动学习软掩码的公式如下：

$$\begin{cases} Gating_{y,x} = \sum \sum W_g \cdot I \\ Feature_{y,x} = \sum \sum W_f \cdot I \\ O_{y,x} = \Phi(Feature_{y,x}) \otimes (Gating_{y,x}) \end{cases} \quad (3-4)$$

其中，下标  $x$  和  $y$  表示输入特征中每个通道的坐标， $W_g$  表示作用于输入以生成软掩码的卷积核， $W_f$  表示作用于输入以生成特征图的卷积核，由此函数激活的软掩码的取值范围在 0 和 1 之间。最后， $\Phi$  表示卷积后应用的激活函数，在本文中我们使用 ReLU 作为激活函数。下图 3-3 展示了传统的部分卷积和门控卷积之间的比较。在部分卷积的情况下，ReLU 更新表示通过更新掩码对特征进行卷积。




图 3-3 传统的部分卷积与门控卷积间的比较

Fig.3-3 Comparison between traditional partial convolution and gated convolution

并行门控卷积（Parallel Gated Convolution, PGC）结合了门控机制（如门控循环单元或长短期记忆网络中的门控单元）和卷积操作，以提高模型对序列数据的建模能力。并行门控卷积通过在每个卷积核后面引入门控单元，以并行的方式

捕获不同位置的特征，并通过门控机制整合这些特征。这种结构使得并行门控卷积能够同时学习多个位置的特征。相较于传统门控卷积，并行的卷积核进行卷积操作时会涉及到更多的参数，因此能够捕获更多位置的特征，使声音事件检测模型性能更优。PGC 的应用于声音事件检测的方法一般包括特征提取、并行门控卷积处理、特征整合和池化、以及分类和训练几步。通过将音频信号转化为时频谱图，进行整合训练。本文假设输入序列为  $X$ ，卷积核为  $K_i$ ，其中  $i$  表示第  $i$  个卷积核。则并行门控卷积操作的输出表达式如下：

$$\begin{cases} Z_i = X * K_i \\ G_i = \sigma(W_g * Z_i + b_g) \\ H_i = \tanh(W_h * Z_i + b_h) \\ Y = \sum_i (G_i \otimes H_i) \end{cases} \quad (3-5)$$

其中， $*$  表示卷积操作， $\sigma$  表示 sigmoid 函数， $\odot$  表示逐元素相乘， $W_g$  和  $W_h$  是可学习的权重参数， $b_g$  和  $b_h$  是偏置参数。

### 3.3.2 改进胶囊网络

传统胶囊网络结构在声音事件检测方面仍存在训练不稳定、对输入变量敏感等弊端。因此我们对胶囊网络结构进行调整，使用的胶囊层的结构流程图如图 3-4 所示。




图 3-4 改进胶囊层网络结构图

Fig.3-4 Improved capsule layer network structure diagram

由上图可知，胶囊层的第一层是主胶囊层，实质上是一个 ReLU 卷积层。来

自上层的输出首先传递到主胶囊层。输出特征首先被重塑为大小为  $T_1 \times \dots \times U$  的张量并进行压缩<sup>[48]</sup>。这里， $T_1$  表示重塑前的时间维度， $U$  表示胶囊的大小，本文设置为 4。该层使用 64 个滤波器，卷积核宽度为 3，时间和频率维度分别设置为 1 和 2。

主胶囊层输出后的时间片段传递到第二胶囊层和时间注意力层（Temporal Attention layer, TA）。在胶囊层内部，输出是使用层间动态路由机制计算的，其中  $U = 8$ 。计算每个输出向量的长度，并使用  $o(t) \in R^T$  表示每个时间片段  $t$  的激活向量。TA 层连接到  $L$  个单元和一个 sigmoid 激活函数，产生输出  $z(t) \in R^T$ ，其中  $L$  表示类别数（声音事件）。最后，对于类别  $l$ ，将  $o(t)$  和  $z(t)$  组合如下：

$$y_l = \frac{\sum_{t=1}^T o_l(t) z_l(t)}{\sum_{t=1}^T z_l(t)} = E_{t \sim q_l(t)}[o_l(t)] \quad (3-6)$$

其中， $q_l(t) = \text{soft max}(\log Z_l)$ ,  $Z_l \in R^T$  且  $\{z_l(t)\}_{t=1,2,\dots,T}$ 。同时，为构建的时间片段选择一个概率阈值  $\tau_1$ 。如果最终预测  $y_l$  大于指定的阈值  $\tau_1$ ，则表示声音事件存在。否则，将被视为声音事件不存在。此外，我们针对  $o_l(t)$  设置了概率阈值  $\tau_2$ ，以计算起始和结束时间。为了减轻噪音，采用形态学闭运算，通过卷积处理感兴趣区域，利用其起始和结束点来确定起始和结束时间。

### 3.3.3 基于改进胶囊网络的声音事件检测

本节提出了基于改进胶囊网络的声音事件检测模型架构，并用其进行多声音事件检测，该模型由一个并行门控卷积层、一个主胶囊层、和一个多路径卷积层（包括一个第二胶囊层和一个时间注意力层），如图 3-5 所示：




图 3-5 基于改进胶囊网络的声音事件检测模型架构

Fig.3-5 Architecture of sound event detection model based on improved capsule network

首先,从声音信号中使用第三章中提到的 Log-Mel 频谱图计算出特征。logmel 特征在文献中被广泛用于声音事件检测,可提供很好的结果。

计算后的特征输入至卷积层,通过并行门控卷积层和最大池化层进行局部特征提取,提取的特征向量将被送到初级胶囊层。设  $T$  是样本中所含的帧数,  $F$  为输入特征的频点数,则由 Log-Mel 频谱图输出的特征向量形状为  $T \times F$ 。卷积层输出的形状为  $T' \times F' \times Q$ ,其中,  $Q$  为特征图的数量,  $T'$  和  $F'$  为通过池化层缩减维度后的帧数和频带数。

每个初级胶囊层包括 3 个胶囊单元,每个胶囊单元可以专门负责捕获数据中的不同类型的特征,不仅可以提高模型容错率,还能增强模型在处理多元化音频数据的表征能力。每个胶囊单元是一个含有 16 通道的卷积层,每个通道由 4 维胶囊组成。三个胶囊网络卷积层的迭代次数均设为 1。经过卷积和 *squashing* 函数压缩后,形成 3 维张量,形状为  $T' \times V \times U$ 。其中,  $V$  是由上一层维度输出而的,  $U$  是胶囊的维度,大小为 4。

再将胶囊的输出至多路径卷积层。在第二胶囊层中,由于前一层也是胶囊层,因此使用动态路由算法计算输出,得到每个输出胶囊的欧几里得长度以及每个时间片  $t$  的激活向量  $o(t)$ ;在 TA 层中,通过时间片的显著性来实现注意力机制。初级胶囊层中输出的特征表示序列中的一个时间步,通过学习每个时间步的重要性权重,得到不同权重输出  $z(t)$ 。最后将输出  $o(t)$  和  $z(t)$  合并输出。

### 3.4 实验及结果分析

#### 3.4.1 数据集及评价指标

由于本文提出的方法专注于弱标记的多声音事件检测,因此选取了 DCASE 2017 任务 4 数据集进行评估,该数据集标题为“用于智能车辆的大规模弱监督声音事件检测”。该数据集是 Google AudioSet 的子集,涵盖了 17 种声音事件,分为“警告”和“车辆”两类。选择了这个数据集,因为其具有广泛的性质,包括超过 140 小时的弱标记音频数据片段,涵盖了各种环境声音。该数据集分为三个子集:一个训练子集,包含 51,172 个音频剪辑;一个验证子集,包含 488 个音频剪辑;以及一个评估子集,包含 1,103 个音频剪辑。大多数音频片段的持续时间为 10 秒。表 3-3 列举了 DCASE 2017 任务 4 数据集的各声音事件片段数。

表 3-3 DCASE2017 task4 数据集各声音事件片段数

Table 3-3 The number of sound event clips in the DCASE2017 task4 dataset

| 警告声音(Warning sounds)                    |      | 车辆声音(Vehicle sounds)  |       |
|-----------------------------------------|------|-----------------------|-------|
| 声音事件                                    | 片段数  | 声音事件                  | 片段数   |
| 火车喇叭 (Train horn)                       | 441  | 汽车 (Car)              | 2020  |
| 汽笛/货车喇叭 (Air horn, Truck horn)          | 407  | 滑板 (Skateboard)       | 1617  |
| 汽车警报 (Car alarm)                        | 273  | 自行车 (Bicycle)         | 25744 |
| 倒车警报声 (Reversing beeps)                 | 337  | 汽车经过 (Car passing by) | 3724  |
| 救护车警笛 (Ambulance (siren))               | 624  | 巴士 (Bus)              | 3745  |
| 警车警笛 (Police car (siren))               | 2399 | 卡车 (Truck)            | 7090  |
| 消防车警笛 (Fire engine, fire truck (siren)) | 2399 | 摩托 (Motorcycle)       | 3291  |
| 防空警报 (Civil defense siren)              | 1506 | 火车 (Train)            | 2301  |
| 尖锐声 (Screaming)                         | 744  |                       |       |

为了评估这些任务的性能，本文利用了诸如精确率、召回率和宏平均 F 分数等指标。此外，对于声音事件检测任务，还计算了一秒钟时间分辨率下的帧级错误率。其中使用 *sed\_eval* 工具包<sup>[49]</sup>对声音事件检测任务进行评估。

### 3.4.2 实验设置及结果

在进行特征提取之前，使用梅尔频谱图作为输入特征。每个音频剪辑被重采样为 16kHz，并经过梅尔滤波器组和对数非线性操作。对每个音频样本计算了帧长度为 64 毫秒、20 毫秒重叠以及每帧的梅尔频率单位的对数梅尔特征。因此，为每个音频样本生成了大小为  $240 \times 64$  的特征向量。

在并行门控卷积部分，在每个路径中使用 128 个滤波器执行三次卷积操作，其中包括 64 个线性滤波器和 64 个 sigmoid 滤波器，步长为 1。使用尺寸为 3 的对称卷积核，在每个卷积块后，应用  $2 \times 2$  平均池化来提取高级特征。输入特征的形状为  $T \times F$ ，其中  $T$  表示时间帧数， $F$  表示输入特征的频率数量。卷积层的输出维度为  $T_1 \times F_1 \times M$ ，其中  $M$  表示输出特征图数量。值  $T_1$  和  $F_1$  分别对应于门控卷积层中特征提取后的时间帧数和频率的数量。

本文检验了所提出的基于改进胶囊网络的声音事件检测模型效果。以文献<sup>[50]</sup>提出的 GCCAPS 模型为基线系统，将其中的门控卷积更改为并行门控卷积；将其

中的胶囊网络结构更改为改进胶囊网络结构。分别对上面改进模型进行对比实验，具体结果如表 3-4 和 3-5 所示：

表 3-4 音频标注任务性能结果

Table 3-4 Audio tagging task performance results

| Method               | F1-score | Precision | Recall |
|----------------------|----------|-----------|--------|
| GCCaps               | 58.1%    | 58.8%     | 57.2%  |
| GCCaps-gated(conv=1) | 58.6%    | 59.3%     | 57.7%  |
| GCCaps-gated(conv=3) | 59.3%    | 60.1%     | 58.5%  |

表 3-5 声音事件检测任务性能结果

Table 3-5 Sound event detection task performance results

| Method               | Error Rate |
|----------------------|------------|
| GCCaps               | 0.76       |
| GCCaps-gated(conv=1) | 0.75       |
| GCCaps-gated(conv=3) | 0.73       |

从上表中可以看出，本节所提出的改进胶囊网络模型，无论是在音频标注任务还是声音事件检测任务中，都取得了更好的性能。在音频标注子任务中，本节所提出的模型在 F1-score 上的得分为 59.3%，比基线系统高 1.2%；在声音事件检测子任务中，本节所提出的模型的错误率为 0.73，比基线系统降低了 0.03。以上结果说明，相较于基线系统，本文提出的并行门控卷积和改进胶囊网络结构不仅能够在训练速度上有所提升，同时也极大的提高了模型的整体性能。

### 3.5 本章小结

本章主要介绍了基于弱标注数据下的改进胶囊网络模型。在第一节中，主要阐述了声音事件检测的常用特征，并详细介绍了 Log-Mel 频谱图；在第二节中，主要介绍了胶囊网络的架构和应用；第三节和第四节主要针对本文所提出的声音事件检测模型进行阐述和实验。实验结果表明，本文提出的并行门控卷积和改进胶囊网络结构能够使模型在不同子任务下均取得更好的性能，模型在音频标注子任务上的 F 分数为 59.3%，在声音事件检测子任务中错误率为 0.73。

## 4 基于Transformer和胶囊网络结合的声音事件检测

### 4.1 Transformer 概述

Transformer 最初是由 Google 团队在 2017 年提出的<sup>[51]</sup>，作为一种用于机器翻译的序列到序列模型。与 CNN 和 RNN 不同，它采用自注意力机制来建立全局上下文信息，并使用位置编码表示输入数据，能够有效地捕获序列数据中的长距离依赖关系。因此，Transformer 具有更多并行计算能力，相比传统的网络结构，可以带来更为显著的性能提升。

#### 4.1.1 Transformer模型架构

Transformer 由多个编码器和解码器层组成。这两部分都由  $N$  个相同的层组成，每个层都使用残差连接和层归一化。编码器接受输入特征并将其转换为高级嵌入，然后由解码器进行转换以生成输出。

每个编码器主要由一个多头自注意力（MSA）模块和一个位置感知前馈网络（FFN）组成。将各模块应用残差连接，再进行层归一化(LN)，以实现更深层次的模型。相反，解码器在 MSA 和 FFN 模块之间包含一个额外的交叉注意力（CA）模块。

在声音事件检测中，同一事件可能多次出现在一个音频片段中。例如，在交通环境中，汽车鸣笛声可能在音频录音中的任何时间出现。通过利用变压器的注意力机制（缩放点积注意力），可以有效地捕获音频剪辑中不同时间点的信息。对于声音事件检测，仅需要编码器。每个编码器由多个层次组成，并处理各层次的输入，通过一个多头自注意的机制。输入向量通过查询、键和值转换矩阵转换为输出。在这种情况下，我们遵循<sup>[52]</sup>中的符号格式，其中输入表示为一个  $T \times C$  矩阵，矩阵  $W^Q$  和  $W^K$  的形状为  $C \times d_k$ ，矩阵  $W^V$  的形状为  $C \times d_v$ 。这里， $d_k$  和  $d_v$  是整数， $Q$ 、 $K$  和  $V$  可以通过以下公式获得。

$$\begin{cases} Q = xW^Q \\ K = xW^K \\ V = xW^V \end{cases} \quad (4-1)$$

转换矩阵的结构图如下图所示，其中  $q_i$ 、 $k_i$ 、 $v_i$  分别表示查询向量、键向量



和值向量。




图 4-1 转换矩阵结构图

Fig.4-1 Transformation matrix structure diagram

注意力机制的公式定义如下：

$$Attention(Q, K, V) = \left( \frac{QK^T}{\sqrt{d_k}} \right) V \quad (4-2)$$

在  $Attention(Q, K, V)$  的形状为  $T \times d_k$  的情况下，表示注意力机制在向量  $Q$ 、 $K$  和  $V$  上计算  $\text{softmax}$  函数。这一步骤涉及将相关的向量组转换为沿时间步的概率。在上述方程中， $Q$ 、 $K$  和  $V$  表示不同时间步的特征相关性，形状为  $T \times T$ 。再利用  $\sqrt{d_k}$  进行缩放操作。操作流程如图 4-2 所示<sup>[51]</sup>。




图 4-2 多头注意力及缩放点积注意力流程结构

Fig.4-2 Multi-head attention and scaled dot product attention process structure

MSA 机制将  $Q$ 、 $K$  和  $V$  分成  $h$  个头部，使输入  $x$  及其与其他输入的相似度能够进行并行计算。接着连接输出，使模型的运算效率大大提高。在并行计算中，我们对输入  $x_i$  和权重矩阵  $W_i^Q$ 、 $W_i^K$  和  $W_i^V$  进行矩阵乘法。利用获得的  $Q$ 、 $K$  和  $V$

矩阵，计算注意力。得到的矩阵连接乘以权重矩阵  $W^O$ ，得到编码层的输出，如下所示：

$$MulHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O \quad (4-3)$$

$$head_i = Attention(xW_i^Q, xW_i^K, xW_i^V) \quad (4-4)$$

其中， $head_i$  表示第  $i$  个头的注意力。

Transformer 编码器部分中的前馈层主要由多层感知机（MLP）组成，具有线性结构和卷积结构。它利用高斯误差线性单元和线性激活函数，并可以通过以下公式获得：

$$GELU(x) = 0.5x(1 + \tanh(\sqrt{\frac{2}{\pi}}(x + 0.044715x^3))) \quad (4-5)$$

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (4-6)$$

其中  $x$  是前一层的输出， $W$  和  $b$  是学习参数。

#### 4.1.2 基于Transformer的声音事件检测模型

Transformer 在自然语言处理、声音事件检测等领域的应用非常广泛。研究者们根据 Transformer 提出了一系列声音事件检测模型。同时，Transformer 模型在音频分类方面表现出了出色的性能<sup>[53]</sup>。相对于基于卷积神经网络或循环神经网络的传统声音事件检测方法，Transformer 中的自注意力机制可以捕捉到较长距离的依赖关系，缓解梯度消失或爆发的问题。此外，Transformer 中的模型结构具有很高的适应性，可以灵活调整以适应特定任务。

在这种模型中，声音事件的音频数据首先被转换成特征表示，通常是梅尔频谱图等形式。随后，这些特征被输入包含编码器和解码器的 Transformer 模型中表示。编码器负责将输入特征映射到高级表示，并捕获输入序列中的全局信息和时间相关性。解码器则负责根据编码器的输出生成声音事件的预测。在文献<sup>[54]</sup>中，研究者提出了一种用于音频标记和 SED 的 CNN-Transformer 融合模型，其中 CNN 中的卷积层用于提取输入 Log-MEL 谱图的高级特征，并利用最后一张卷积层的特征图获得时间轴。嵌入可以被视为  $x$ ，其形状是时间帧的数量乘以通道的数量。最后在 Transformer 的输出上应用全连接层和是 S 形非线性，以预测声音类在时间步长上的存在概率。

## 4.2 网络架构

胶囊模型在音频领域引起了极大关注。为了处理重叠的声音事件，胶囊网络利用其动态路由机制收集与音频特征的时间和空间方面相关的多样信息。这些网络在从有限数据中学习表示方面表现良好，弥补了传统神经网络结构在训练过程中发生的信息丢失。然而，单独使用胶囊网络模型也存在一些限制，例如训练速度较慢以及在处理复杂音频数据集时性能下降。Transformer 中的自注意力机制对于从复杂数据集（例如多音频事件数据集）中进行特征提取非常有用。

因此在本节中提出 Transformer-胶囊网络融合模型，通过利用 Transformer 的编码器提取特征，并将其与胶囊网络模型进行集成。首先，采用门控卷积从输入的对数梅尔频谱图中提取特征，通过卷积中的特征映射沿时间轴生成嵌入向量。然后将这些向量传递给 Transformer，以改善全局信息的精细特征表示。最后，将上述胶囊网络应用于 Transformer 的输出，结合了改进的动态路由机制来预测声音类别的存在概率。这种方法有助于音频特征提取，从而提高了声音事件检测的性能。

### 4.2.1 基于声音事件检测的Transformer编码器

Transformer 编码器在声音事件检测任务中的应用有很大潜力。它可以利用自注意力机制，在处理不定长的输入序列的同时，捕捉音频数据中的长程依赖关系。Transformer 编码器在声音事件检测中，学习输入序列中不同位置之间的关系，是通过自注意机制实现的。然后对序列数据进行处理，通过残差连接，层叠归一化，位置编码等方式实现。本文采用的 Transformer 架构如下图所示：




图 4-3 Transformer 编码器结构

Fig.4-3 Transformer encoder structure

在这个结构中，本文采用 3 层编码器。在卷积层进行特征提取后，数据首先传递到编码器结构内的自注意力模块。该模块由捕捉特征间相互依赖关系的线性层和单头注意力机制构成。在这个阶段，数据表示的维度为  $B \times N \times T_1$ ，其中  $B$  表示批量大小， $N$  表示输入特征的序列长度， $T_1$  表示每个输入向量的维度。多头注意力的输出随后通过层归一化的方式进行标准化，保持维度为  $B \times N \times T_1$ 。随后，输出被输入到由两个全连接层组成的前馈神经网络层中，由激活函数分隔。第一个全连接层将维度降低到  $B \times N \times 2T_1$ ，第二个全连接层再将其还原到  $B \times N \times T_1$ 。经过另一轮层归一化后，输出被传递到胶囊层。

#### 4.2.2 基于Transformer和改进胶囊网络的声音事件检测模型

本文提出的基于 Transformer 和改进胶囊网络的声音事件检测模型架构如下图所示，由门控卷积层、Transformer 层和胶囊层三个部分组成。




图 4-3 基于 Transformer 和改进胶囊网络的声音事件检测模型

Fig.4-3 Sound event detection model based on transformer and improved capsule network

前两部分用于特征提取，而第三部分用于声学事件的分类和检测。在卷积层中，使用门控卷积<sup>[55]</sup>，通过该机制可以应用动态特征选择机制到每个通道和空间位置，从而实现对不同音频实例的局部特征选择。利用三个平行的门控卷积神经网络块，将信息从输入特性中提取出来。每块和行块都是由 3 个卷积层组成的。在每个块之后，沿频率轴应用二维最大池化（Max Pool）进行维度降低，而时间轴保持不变以匹配目标长度。另外，在卷积层中利用大小相同的卷积核，将信息从输入特性中提取出来。

在卷积层之后，加入 Transformer 的编码器部分，可以帮助系统在音频信号中捕捉全局信息。编码器结构有两个结构：一个是自注意力层，一个是前馈层。前文概述了自注意力机制，并在自注意力层之后加入了残差连接和归一化，以提高

收敛速度。随后，特征被输入到前馈神经网络层，其中应用了带有 GELU 激活函数的全连接网络，以增强模型的泛化能力。在最终输出之前，再应用残差连接和归一化。

在胶囊层中，利用了第三章提出的改进胶囊网络结构，结合了一个时间注意力层，并与第二个胶囊层并行计算输出。引入这一层有效解决了由音频数据中的背景噪声引起的模型性能降低问题，特别是在复杂数据集中。特征被输入到带有 ReLU 激活的初级胶囊层中。重塑后，输出变为单独的时间片段，这些片段被视为后续层的分开输入。随后，时间片段被传送至第二层胶囊层，同样被传送至时间关注层。在第二层胶囊层中，使用动态路由算法对特征进行训练，并对输出进行计算。与原始的胶囊路由机制相比，受到文献<sup>[56]</sup>中提出的注意力方案的启发，TA 层在音频帧上使用注意力权重，即关注关键帧同时减弱无关帧。最后，第二个胶囊层和 TA 层的输出合并以获得数据特征的预测值。这些预测值可以看作是相对于从 TA 层得到的概率分布的胶囊的期望长度。

## 4.3 实验及结果分析

### 4.3.1 数据集及评价指标

由于本文提出的方法是针对弱标注的多声音事件检测，因此使用来自 DCASE 2017 Task 4 的弱标记数据集来评估和验证，使用 F1 分数和错误率来评估所提模型的性能。

### 4.3.2 基线系统

本节对提出的方法与目前典型的声音事件检测方案进行比较分析：

**GCCaps:** 指的是门控卷积胶囊模型。该系统由三个门控卷积网络块、两个胶囊层和一个与高级胶囊层并行运行的 TA 层组成。在每个门控卷积层和初级胶囊层之后应用归一化。每个卷积块包括三个门控卷积层。

**GCRNN<sup>[49]</sup>:** 指的是门控卷积循环神经网络模型。在该系统中，CNN 的每个音频分类层之后的 ReLU 激活函数被可学习的门控线性单元所取代。

**GCNN<sup>[50]</sup>:** 指的是门控卷积神经网络模型。该系统类似于 GCRNN 模型，因为它用门控卷积替换了传统的卷积神经网络。但是它不包括循环层。

CNN-transformer<sup>[54]</sup>: 指的是 CNN 和 Transformer 的集成模型。该系统由 4 个卷积块组成, 其中包含 2 个卷积层。在每个卷积层后应用归一化和 ReLU 非线性。该模型使用学习率为 0.001 的 Adam 优化器, 并在训练过程中利用 alpha 值为 1 的 mixup 方法来缓解过拟合。最终输出通过对最后一个卷积层的频率轴输出进行平均, 并利用 sigmoid 非线性的全连接层预测每个时间帧中声音事件的存在概率。

### 4.3.3 实验设置

在进行特征提取之前, 本文使用 Log-Mel 谱图作为输入特征, 再对特征进行提取。每段音频片段都进行了重置, 每个音频样本都会产生一个大小为  $240 \times 64$  的特征向量, 就像第三章的实验设定那样。在每个门控卷积网络部分中, 本文使用了大小为  $3 \times 3$  的 64 个滤波器。音频标记子任务和声音事件检测子任务的池化大小均设置为  $2 \times 2$ 。为了解决过拟合问题并加快收敛速度, 本文使用归一化方法进行处理。在 Transformer 结构中, 输入到编码器的数据特征具有长度为 64 的序列, 并且词汇大小为 3840。同时采用了一个注意力头的编码器结构。

表 4-1 和表 4-2 提供了模型不同阶段使用的超参数, 其中“Tf”表示 Transformer, 后面的数字表示 Transformer 层的索引。

表 4-1 模型参数 (特征提取阶段)

Table 4-1 Model parameters (Feature extraction)

|           | 特征提取              |      |                   |      |                   |      |
|-----------|-------------------|------|-------------------|------|-------------------|------|
|           | Conv1             | Tf1  | Conv2             | Tf2  | Conv3             | Tf3  |
| 内核大小      | $64 @ 3 \times 3$ | —    | $64 @ 3 \times 3$ | —    | $64 @ 3 \times 3$ | —    |
| 步幅        | $1 \times 1$      | —    | $1 \times 1$      | —    | $1 \times 1$      | —    |
| 池化大小      | $2 \times 2$      | —    | $2 \times 2$      | —    | $2 \times 2$      | —    |
| 头数        | —                 | 1    | —                 | 1    | —                 | 1    |
| Dropout 率 | 0.2               | 0.3  | 0.2               | 0.3  | 0.2               | 0.3  |
| 激活函数      | ReLU              | ReLU | ReLU              | ReLU | ReLU              | ReLU |

表 4-2 模型参数 (胶囊网络结构)  
Table 4-2 Model parameters (Capsule network structure)

|           | 胶囊网络      |           |
|-----------|-----------|-----------|
|           | 初级胶囊层     | 第二胶囊层     |
| 内核大小      | 32@3×3    | —         |
| 步幅        | 1×1       | —         |
| Dropout 率 | 0.5       | —         |
| 激活函数      | Squashing | Squashing |
| 胶囊维度      | 8         | 16        |

在优化方面, 采用 Adam 优化器<sup>[57]</sup>作为梯度下降算法, 保持固定的学习率为 0.001。路由迭代设置为 4, 学习率每两个周期衰减 0.9 倍。损失函数使用二元交叉熵, 并据此计算相应梯度。小批量大小设置为 44, 总共训练了 30 个周期。

为了减轻数据集内显著的类别不平衡问题, 本文实施了数据平衡技术, 如文献<sup>[49]</sup>中建议的。这确保在训练、测试和评估集中涵盖了音频数据集的每个类别的样本, 从而防止了分类偏差。

本文在推断过程中, 从验证集中选取准确率最高的五个周期, 并平均其预测结果得出最终结果。声音事件检测的检测阈值分别设置为 0.3 和 0.6。此外, 为 SED 设置了分别为 10 和 5 的扩张和腐蚀大小。这些超参数是通过在验证集上进行的实验确定的。

除了 SED 结果, 本文还展示了音频标记结果, 通过对整个信号的检测结果进行聚合。音频标记是通过从音频片段中识别音频类别来解决的多标签分类问题, 而 SED 任务则侧重于检测连续音频录音中目标声音事件的存在或缺失。有了 SED 结果, 可以直接获得标记结果, 方法是丢弃与声音事件的起始/结束时间相关的信息。

#### 4.3.4 实验结果及分析

在本节中, 对 GCCaps 模型与本文提出的模型进行对比实验。具体来说, 本文关注的是卷积层大小为 3 的情况。不同指标 (包括 F1 分数和批量大小为 30-44 时的精确度) 的比较图如图 4-4 所示。显然, 本文所提出的模型在 F1 分数和精确



度方面都获得了更好的性能。




图 4-4 批量数指标在 30-44 间的不同模型结果比较图

Fig.4-4 The comparative graphs of different models at batch\_size 30-44 under various metrics

为了进一步展示本文模型中特征提取部分的有效性，并突出本文提出的模型与基线模型之间的差异，提供一个 t-分布随机邻域嵌入（t-SNE）聚类可视化图，对基线系统的特征提取输出和本文提出的系统进行了展示。t-SNE 是一种无监督非线性技术<sup>[58]</sup>，被广泛应用于各个领域，包括图像和音频分析。它的主要目的是观察数据点之间的关系，通过向低维空间映射高维数据。在 t-SNE 算法中，高维空间中的相似度以高斯分布表示，而低维度则以 t 分布表示。数据点越接近，说明两者相似度越高。我们使用相同的训练样本训练了两个模型，并将结果显示在图 4-5 中。




图 4-5 不同模型输出特征的 t-SNE 可视化

Fig.4-5 The t-SNE visualization of the output features from different models

从图中可以观察到，与其他声音事件检测模型相比，本文提出的模型呈现出更密集的聚类，并且同一类别样本之间的相似性更高。这表明，它可以更准确地提取具有模糊特征的样本的特征。即提出的网络架构能够对样本进行更好的识别，



其特点具有唯一性。

除了本文提出的系统外，本文还评估了基线系统中提出的 GCCaps 模型，以及 GCRNN 和 GCNN，作为消融实验的比较研究的一部分。图 4-6 将四种模型在不同基线系统下的不同时期的损失进行了比较。可以观察到，与其他模型相比，本文提出的模型损失较低。




图 4-6 四种不同模型在不同时期的损失函数比较

Fig.4-6 Comparison of the loss function at different epochs for four different models

表 4-3 显示了不同方法在音频标记任务的评估集上的 F 分数、准确率和召回率。

在音频标记任务中，本节提出的系统在评估集上取得了 60.6% 的 F 分数，超过了相同任务中的其他方法。Transformer 和胶囊模型的融合表现出最佳性能，略高于使用 GCCaps 模型。GCRNN 和 GCNN 在这个子任务中表现相当。然而，CNN-Transformer 模型的 F 分数最低，为 55.7%。

表 4-3 音频标记任务的不同表现结果

Table 4-3 Different performance results of audio tagging subtask

| 方法                  | F score      | Precision | Recall |
|---------------------|--------------|-----------|--------|
| Transformer-Capsule | <b>60.6%</b> | 62.9%     | 57.6%  |
| GCCaps              | 58.6%        | 59.2%     | 59.6%  |
| GCRNN               | 57.3%        | 53.6%     | 59.6%  |
| GCNN                | 57.2%        | 59.0%     | 57.2%  |
| CNN-Transformer     | 55.7%        | 55.4%     | 56.1%  |

表 4-4 声音事件检测任务的不同表现结果

Table 4-4 Different performance results of sound event detection subtask

| 方法                  | F score | Precision | Recall | Error rate  |
|---------------------|---------|-----------|--------|-------------|
| Transformer-Capsule | 47.9%   | 68.7%     | 29.1%  | <b>0.75</b> |
| GCCaps              | 46.3%   | 58.3%     | 38.4%  | 0.76        |
| GCRNN               | 43.3%   | 57.9%     | 34.8%  | 0.79        |
| GCNN                | 37.5%   | 46.6%     | 31.1%  | 0.88        |
| CNN-Transformer     | 48.3%   | -         | -      | 0.91        |

表 4-4 显示了不同方法在声音事件检测任务的评估集上的 F 分数、准确率、召回率和错误率。

对于声音事件检测子任务，Transformer 和胶囊网络模型的融合实现了最低的错误率为 0.75，同时有较好的 F 分数为 47.9%，略优于 GCCaps 模型。GCCaps 的性能比 GCRNN 略胜一筹，其 F 分数为 46.3%，错误率为 0.76。循环层的引入增强了 GCRNN 模型的时间定位能力，得分比 GCNN 要好一些，错误率也比较低。尽管 CNN-Transformer 模型的 F 分数最高，但其错误率较高，为 0.91。

表 4-5 是本文提出的模型在音频标记子任务中各种事件的 F 分数，而表 4-6 则表示了声音事件检测子任务中各种事件的错误率。对于音频标记子任务，像“民防警报”和“尖叫”等事件表现出较高的 F 得分，而像“汽车驶过”和“公共汽车”等事件表现出较低的 F 得分。在声音事件检测子任务中，“民防警报”和“火车喇叭”等事件的错误率较低，而“自行车”和“卡车”等事件的错误率较高。

表 4-5 音频标记子任务对每个事件的 F 分数

Table 4-5 F-score of audio tagging subtask for each event

| 警告声音(Warning sounds)    |       | 车辆声音(Vehicle sounds) |       |
|-------------------------|-------|----------------------|-------|
| 声音事件                    | F 得分  | 声音事件                 | F 得分  |
| Train horn              | 61.1% | Police car           | 48.1% |
| Air horn, Truck horn    | 62.2% | Screaming            | 87.6% |
| Car alarm               | 66.0% | Car                  | 65.7% |
| Reversing beeps         | 45.0% | Car passing by       | 30.1% |
| Bicycle                 | 49.6% | Bus                  | 43.5% |
| Skateboard              | 65.5% | Truck                | 58.9% |
| Ambulance               | 50.4% | Motorcycle           | 76.8% |
| Fire engine, fire truck | 57.4% | Train                | 76.8% |
| Civil defense siren     | 82.0% | Micro average        | 60.6% |

表 4-6 声音事件检测子任务对每个事件的 EER 值

Table 4-6 EER of sound event detection subtask for each event

| 警告声音(Warning sounds)    |      | 车辆声音(Vehicle sounds) |      |
|-------------------------|------|----------------------|------|
| 声音事件                    | 错误率  | 声音事件                 | 错误率  |
| Train horn              | 0.66 | Police car           | 0.9  |
| Air horn, Truck horn    | 0.71 | Screaming            | 0.68 |
| Car alarm               | 0.67 | Car                  | 0.93 |
| Reversing beeps         | 0.79 | Car passing by       | 1.00 |
| Bicycle                 | 1.20 | Bus                  | 1.04 |
| Skateboard              | 0.89 | Truck                | 1.05 |
| Ambulance               | 0.88 | Motorcycle           | 0.72 |
| Fire engine, fire truck | 0.93 | Train                | 0.67 |
| Civil defense siren     | 0.31 | Micro average        | 0.72 |

本节对基线模型 GCCaps 和提出的模型进行配对样本  $t$  检验,对两组样本之间的差异进行比较,从而对模型的精确性和关联性进行更好的观察。公式如下:

$$t = \frac{M_d - 0}{s_d / \sqrt{n}} \sim t(n-1) \quad (4-7)$$

其中,  $M_d$  表示样本之间差异的均值,  $s_d$  表示样本之间差异的标准差,  $n$  是差异的数量,  $n_d$  表示样本大小,而  $t$  统计量遵循自由度为  $n-1$  的  $t$  分布。在阈值设

置为  $p = 0.05$  的情况下, 当  $|t| > t_{\frac{\alpha}{2}, n-1}$  时, 拒绝零假设, 得出两组样本之间存在显著差异的结论, 并代表了总体结果。计算  $t$  值为  $-0.383$ , 通过查阅  $t$  表, 根据自由度找到对应的  $t$  值, 发现计算得到的  $t$  值大于表中的值。因此, 我们拒绝零假设, 表明两种方法得到的结果存在显著差异。

本节还参考了文献<sup>[59]</sup>中提到的非对称核卷积神经网络, 并测试了具有不同核大小的卷积网络模型的性能。最终发现选择大小为  $3 \times 3$  的对称卷积核可以获得最佳的模型性能。还通过实验比较不同门控卷积层数下的模型, 发现当层数为 3 时, 模型的性能更好。值得注意的是, 尽管将 Transformer 编码器合并到传统的胶囊模型中提高了性能, 但其参数数量方面的模型大小也增加到 523,873, 高于 GCCaps 模型的参数数量, 后者为 448,225。

上述结果表明, 使用基于 Transformer 和改进胶囊网络的声音事件检测方法导致音频标记子任务和声音事件检测子任务的训练速度有所下降, 但与模型性能的提高相比, 这一点可忽略不计。同时, 虽然本文提出的模型进行了改进, 但在性能方面与基线提出的 CNN-Transformer 模型仍存在差距。这种差距源于本研究使用的阈值是一个固定值, 而不是 CNN-Transformer 模型中使用的自动阈值优化系统。如果两个模型都使用固定阈值, 则提出的模型的性能要优于与 CNN-Transformer 模型的性能。因此, 在未来的研究中, 我们将专注于优化和改进 Transformer 方面和路由机制, 以实现更好的检测性能。

#### 4.4 本章小结

在本章中, 我们将第三章提出的改进的胶囊网络模型引入了 Transformer 的编码器结构, 提出了基于 Transformer 和改进胶囊网络的声音事件检测模型。实验发现, 这种融合方法可以有效提高模型在测试和评估集上的性能。具体而言, 引入使用对称卷积核的并行门控卷积, 可以有效利用数据中的原始特征信息, 从而提高了模型的性能。同时, 使用 Transformer 从输入中提取高级别的特征降低模型的计算复杂度, 并提高其整体性能。最后, 使用胶囊路由机制和注意力机制能够识别模型部分和整体之间的相关性, 增强其泛化能力, 并对潜在的过拟合问题起到了有效的抑制和缓解背景噪音的效果, 从而提高模型的整体性能。

## 5 总结与展望

声音与日常生活密切相关，它结合了信号处理、机器学习等多个领域的技术，所涉及的声音事件检测等研究也随着时代的进步而不断发展，应用前景广阔。声音事件检测技术在很多领域都有广泛的应用，包括环境监测，智能家居，安防监控，智能交通等等。例如，在智能家居中，声音事件检测可以用于识别门铃声、烟雾警报等重要事件。

### 5.1 总结

目前，多声音事件检测在日常生活中出现频率更高，其所对应的声音大多为复杂、重叠的，所涉及到的音频数据也多为弱标记数据，因此，这给声音事件检测任务的研究带来了一些困难和难题。本文结合声音事件检测理论和深度学习理论，提出了一种针对弱标记音频数据的声音事件检测模型，旨在解决当前研究背景下所涉及的问题。完成的主要工作如下：

（1）对声音及声音事件检测的研究背景、意义、以及国内外研究现状进行了详细阐述和介绍，同时对本文涉及到的章节内容进行细致划分。研究并分析了声音事件检测的基础理论、分类以及常见架构，介绍了音频方面常用特征的选择与提取。其次，弱标注声音事件检测以多实例学习为基础，配以实例介绍常用的评价指标和分类器，对弱标注声音事件检测进行系统讲解。接着，深度学习理论被引入，并举例说明卷积神经网络和深度神经网络的理论架构，以及一系列常用的激活功能和损失功能。

（2）本文提出了一种基于并行门控卷积的胶囊网络声音事件检测模型，采用多层并行门控卷积对特征进行提取，同时采用改进的胶囊网状结构，引入时间注意力层，利用胶囊网层和时间注意力层进行权重合并，得到输出，提出改进胶囊网络声音事件检测模型。通过使用并行门控卷积，显著提升了模型的整体性能。具体来说，相较于本文引用的基线系统，所提出的模型性能在音频标记和声音事件检测方面均有提升。

（3）本文提出了一种基于 Transformer-胶囊网络的多声音事件检测新方法，这是在先前研究基础上的进一步发展。首先，我们采用并行门控卷积提取不同频

率的特征，然后使用变压器编码器进一步提取了更高级别的特征。接着，我们利用改进的胶囊网络结构，通过胶囊网络层与时间注意力层来合并权重并生成最终预测。提出的系统采用 DCASE 2017 挑战任务 4 的弱标记数据集进行评估。在声音事件检测子任务和音频标记子任务中表现优异，相比基线系统，分别获得 60.6% 的 F 分数和 0.75 的错误率。

## 5.2 展望

虽然研究工作取得了一定的成果，但在今后的工作中，还存在着一些亟待改进的问题：

本文提出的模型虽然能够在一定程度上可以解决事件重叠问题，但是模型的性能还存在一定瑕疵，其最优性能仍不够出色；在声音事件检测任务和音频标记任务中，除对数梅尔谱图之外，还有很多其他特征可以使用，因此未来会在这方面加强相关的研究，计划研究特征增强技术，以增强模型的稳健性。

在胶囊网络内部，随在音频任务领域取得不错的成绩，但仍存在训练速度不够快、性能不够完善等问题，未来的研究方向将包括探索更加有效的方法来改进路由机制，以期提高模型的训练速度和效率。

## 参考文献

- [1] C. Clavel, T. Ehrette, and G. Richard. Events detection for an audio-based surveillance system. IEEE International Conference on Multimedia and Expo, 2005.
- [2] Y. Wu, Q. Li, and Z. Wang. Application of sound event detection in intelligent traffic management systems: A review. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(1), 78-93.
- [3] L. Zhang, Y. Wang, and Q. Chen. Application of sound event detection in medical diagnosis: A review. Journal of Medical Engineering and Technology, 2022, 46(3), 211-225.
- [4] T. K. Chan, and C. S. Chin. A comprehensive review of polyphonic sound event detection. In IEEE Access, 2020, vol. 8, pp. 103339-103373, doi: 10.1109/ACCESS.2020.2999388.
- [5] J. K. Chorowski, D. Bahdanau, D. Serdyuk, K. Cho, and Y. Bengio, Attention-based models for speech recognition. In Advances in Neural Information Processing Systems, 2015, 577-585.
- [6] J. Xu, J. Zhu, and Y. Yang, Disappeared command: spoofing attack on automatic speech recognition systems with sound masking. arXiv: 2204.08977, 2022.
- [7] Z. Zhao, S. Zhang, Z. Xu, K. Bellisario, N. Dai, H. Omrani, and B. C. Pijanowski, Automated bird acoustic event detection and robust species classification. Ecological Informatics, 2017, 99-108.
- [8] R. Abinaya, Acoustic based scene event identification using deep learning CNN. Turkish Journal of Computer and Mathematics Education (TURCOMAT), 2021, 1398-1405.
- [9] D. Stowell, D. Giannoulis, E. Benetos, M. Lagrange, and M. D. Plumbley, Detection and classification of acoustic scenes and events. in IEEE Transactions on Multimedia, 2015, 1733-1746.
- [10] A. Mesaros, T. Heittola, and T. Virtanen, A multi-device dataset for urban acoustic scene classification. Workshop Detect. Classific. Acoust. Scenes Events, 2018.
- [11] 侯晓明, 邱亚峰. 基于卷积神经网络与特征融合的天气识别方法[J]. 应用光学, 2023, 44(02): 323-329.
- [12] 张港. 基于深度学习轻量化卷积神经网络的遥感图像场景分类研究[D]. 南京邮电大学, 2022.
- [13] M. Valenti, S. Squartini, A. Diment, G. Parascandolo, and T. Virtanen, A convolutional neural network approach for acoustic scene classification. In 2017 International Joint Conference on Neural Networks (IJCNN), 2017, 1547-1554.
- [14] J. Salamon, and J. P. Bello, Deep convolutional neural networks and data augmentation for environmental sound classification. In IEEE Signal Processing Letters, 2017, vol. 24, no. 3, 279-283, doi: 10.1109/LSP.2017.2657381.
- [15] K. J. Piczak, Environmental sound classification with convolutional neural networks. In 2015 IEEE 25th International Workshop on Machine Learning for Signal Processing (MLSP), 2015, 1-6.
- [16] X. Zhu, Z. Wu, and S. Fu. Learning contextual features for acoustic event detection using dilated convolutional recurrent neural networks. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 28(12), 2860-2871.

- [17] Y. Zhang, J. Wang, and Y. LeCun. Attend and discriminate: beyond the front-end spectrum for acoustic event detection. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2018, 468-472.
- [18] S. Sabour, N. Frosst, and G. E. Hinton, Dynamic routing between capsules. In Proceedings of the 31st International Conference on Neural Information Processing Systems, 2017, 3859-3869.
- [19] D. Xie, X. Zhang, and Z. Huang. An iterative capsule network for weakly supervised sound event detection. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 28(1), 2020, 227-236.
- [20] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, Attention is all you need. In Proceedings of the 31st International Conference on Neural Information Processing Systems, 2017, 5998-6008.
- [21] Liu, Y. Zhu, and D. Guo. Learning a wavelet-like transform with locally-global Self-Attention. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2021, 712-716.
- [22] S. Gunasekaran, K. Revathy. Content-Based classification and retrieval of wild animal sounds using feature selection algorithm. Second International Conference on Machine Learning and Computing, 2010.
- [23] D. Mitrovic, M. Zeppelzauer, and C. Breiteneder. Discrimination and retrieval of animal sound. 12th International Multi-Media Modelling Conference. IEEE, 2006.
- [24] S. Goetze, J. Schroder, and S. Gerlach. Acoustic monitoring and localization for social care. Journal of Computing Science and Engineering, 2012, 6(1): 40-50.
- [25] M. Chan, Daniel Estève, and Escriba C. A review of smart homes-present state and future challenges. Computer Methods & Programs in Biomedicine, 2008, 91(1): 55-81.
- [26] J. Lee, B. Noh, and S. Jang. Stress detection and classification of laying hens by sound analysis. Asian-Australasian Journal of Animal Sciences, 2015, 28(4): 592-598.
- [27] M. Vacher, F. Portet, and Fleury A. Challenges in the processing of audio channels for ambient assisted living. IEEE International Conference on E-health Networking Applications & Services. IEEE, 2010.
- [28] S. Goetze, F. Xiong, and J. Rennie. Hands-free telecommunication for elderly persons suffering from hearing deficiencies. 12th IEEE International Conference on e-Health Networking, Application and Services, Healthcom 2010.
- [29] P. Foggia, N. Petkov, and A. Saggese. Reliable detection of audio events in highly noisy environments. Pattern Recognition Letters, 2015, 65(NOV.1): 22-28.
- [30] A. Temko, and C. Nadeu. Classification of meeting-room acoustic events with support vector machines and variable-feature-set clustering. Proceedings. IEEE International Conference on Acoustics, Speech, and Signal Processing, 2005.
- [31] G. Guo, and S. Z. Li. Content-based audio classification and retrieval by support vector machines. IEEE Transactions on Neural Networks, 2003, 14(1): 209-215.



- [32] X. Zhou, X. Zhuang, and M. Liu. HMM-based acoustic event detection with adaBoost feature selection. *Multimodal Technologies for Perception of Humans*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008, 345-353.
- [33] R. Malkin, D. Macho, and A. Temko. First evaluation of acoustic event classification systems in chil project. In *Hands-Free Speech Communications and Microphone Arrays (HSCMA) Workshop*, 2005.
- [34] P. K. Atrey, N. C. Maddage, and M. S. Kankanhalli. Audio based event detection for multimedia surveillance. *IEEE International Conference on Acoustics Speech and Signal Processing Proceedings*, 2006.
- [35] S. Squartini, F. Vesperini, and B. Schuller. Acoustic scene classification: A comparison of approaches and features in standard databases. In *Proceedings of the 23rd European Signal Processing Conference (EUSIPCO)*, 2015, 1583-1587.
- [36] T. Virtanen. Monaural sound source separation by nonnegative matrix factorization with temporal continuity and sparseness criteria. *IEEE Transactions on Audio, Speech, and Language Processing*, 2007, 15(3), 1066-1074.
- [37] D. A. Reynolds, T. A. Hughes, and A. S. Acero. Acoustic event detection using gaussian mixture models. *Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, 1999, 3081-3084.
- [38] A. Hämmäläinen, and T. Virtanen. Recurrent neural networks for acoustic event detection. In *Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, 2019, 76-80.
- [39] D. Wang, and G. J. Brown. *Computational auditory scene analysis: Principles, algorithms, and applications*. Wiley-IEEE Press, 2008, 19(1):199.
- [40] K. B. M. Rathna, and N. Nagaraja. Studies on phytoremediation of chromated copper arsenate (CCA) using Acacia plant species (Fabaceae). *International journal of phytoremediation*, 2023.
- [41] 高建宇. 基于机器学习的多技术指标量化择时研究. *中国集体经济* [J]. 2022(34): 153-155+165.
- [42] S. Deshmukh, B. Raj, and R. Singh, Multi-Task learning for interpretable weakly labelled sound event detection, *arXiv: Audio and Speech Processing*, 2020.
- [43] T. K. Chan, C. S. Chin, and Y. Li, Non-Negative matrix factorization-convolutional neural network (NMF-CNN) for sound event detection, *arXiv: Audio and Speech Processing*, 2020.
- [44] S. Ntalampiras, T. Virtanen, and T. Ganchev. DCASE 2017 submission: multiple instance learning for sound event detection. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events 2017 Workshop (DCASE2017)*, 2017, Munich, Germany.
- [45] K. Simonyan, and A. Zisserman. Very deep convolutional networks for Large-Scale image recognition. *arXiv preprint arXiv:1409.1556*, 2017.
- [46] A. Graves, A. Mohamed, and G. Hinton. Speech recognition with deep recurrent neural networks. In *Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, 2017, 6645-6649.

- [47] Y. Xu, Q. Kong, Q. Huang, W. Wang, and M. Plumbley, Attention and localization based on a deep convolutional recurrent model for weakly supervised audio tagging. In Interspeech 2017, 2017, 3083-3087.
- [48] F. Font, G. Roma, and X. Serra, Sound sharing and retrieval. In Computational Analysis of Sound Scenes and Events, 2018, 279-301.
- [49] Y. Xu, Q. Kong, W. Wang, and M. D. Plumbley, Large-scale weakly supervised audio classification using gated convolutional neural network. In 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2018, 121-125.
- [50] T. Iqbal, Y. Xu, Q. Kong, and W. Wang, Capsule routing for sound event detection. In 2018 26th European Signal Processing Conference (EUSIPCO), 2018, 2255-2259.
- [51] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, Attention is all you need. In Proceedings of the 31st International Conference on Neural Information Processing Systems, 2017, 5998-6008.
- [52] Y. Mao, Y. Zeng, H. Liu, W. Zhu, and Y. Zhou, ICASSP 2022 L3DAS22 Challenge: Ensemble of resnet-conformers with ambisonics data augmentation for sound event localization and detection. ICASSP 2022-2022 IEEE International Conference on Acoustics, 2022, 9191-9195.
- [53] K. Wakayama and S. Saito, CNN-Transformer with self-attention network for sound event detection. ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2022, 806-810.
- [54] J. Liu, and D. Chu. Sound event detection of weakly labelled data with CNN-Transformer and automatic threshold optimization. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29, 1280-1290.
- [55] G. Liu, F. A. Reda, and K. Shih, Image inpainting for irregular holes using partial convolutions. In Proceedings of the European Conference on Computer Vision (ECCV), 2018, 85-100.
- [56] Y. N. Dauphin, A. Fan, M. Auli, and D. Grangier, Language modeling with gated convolutional networks. In Proceedings of the 34th International Conference on Machine Learning (ICML), 2017, 933-941.
- [57] D. P. Kingma and J. Ba, Adam: A method for stochastic optimization. In 3rd Int. Conf. Learn. Repr. (ICLR), 2014.
- [58] Laurens, V. D. Maaten, and Hinton. G, Visualizing data using t-sne. Journal of Machine Learning Research, 2008, 2579-2605.
- [59] Y. C. Wu, P. C. Chang, C. Y. Wang, and J. C. Wang, Asymmetric kernel convolutional neural network for acoustic scenes classification. In 2017 IEEE International Symposium on Consumer Electronics (ISCE), 2017, 11-12.