

基于深度学习的音视频语音识别技术回顾与展望

□文 / 张景宣¹, 万根顺²

(1. 陕西师范大学 计算机科学学院, 西安 710119; 2. 中国科学技术大学, 合肥 230026)

摘要: 音视频语音识别旨在基于语音以及对应唇形视频输入识别语音的文本内容信息。音视频语音识别技术在噪声场景下可以有效地提升语音识别的准确率, 因而其具有广泛的应用前景。本文聚焦深度学习框架下的音视频语音识别技术, 总结音视频语音识别的发展现状。具体而言, 本文针对音视频语音识别的端到端框架、唇形表征提取、音视频融合模块的相关研究进行回顾。除此之外, 本文还对音视频语音识别的学习范式, 包括有监督学习、自监督学习, 以及半监督学习的相关研究进行了总结。进一步地, 本文对音视频语音识别当前面临的挑战进行分析, 并对未来的研究方向进行展望。

关键词: 语音识别; 音视频语音识别; 唇语识别; 音视频自监督学习

中图分类号: TN912; TP391 **文献标志码:** A **文章编号:** 2096-5036(2024)03-0057-10

DOI: 10.16453/j.2096-5036.202423

0 引言

语音识别技术在过去的几十年间快速发展。尤其是近几年, 受益于端到端的语音识别框架以及海量的语音训练数据, 语音识别在高信噪比的场景下能够达到非常高的识别准确率。语音识别技术已经普及, 被广泛地应用于各种智能设备中, 例如手机智能助手、智能家居设备、智能机器人等。但是, 语音识别在更加复杂的真实世界场景下仍然可能出现识别错误率高、效果严重降低的情况, 其中噪声干扰

是当前语音识别的最大挑战之一。

针对该问题, 研究者提出了音视频语音识别技术。该技术能够结合说话人的语音以及说话人唇形视频的多模态信息同时作为输入进行语音识别。由于说话人的唇形视频具有不受噪声干扰影响的特点, 音视频语音识别利用音频和视频模态之间的互补性信息, 能够一定程度上降低干扰, 提升语音识别的抗噪能力以及在噪声环境下的识别准确率。因此, 音视频语音识别具有非常广泛的实际应用, 使得智能设备语音交互的稳健性与可靠性大幅度提升, 能够




图 1 音视频语音识别技术中的关键性技术及分类示意图

进一步拓展语音交互技术的应用场景，例如部署在嘈杂环境下的机器人、多人交谈场景下的自动会议记录等。

音视频语音识别技术和人类大脑的语音处理机制具有一定的相似性。鸡尾酒会效应是指在类似于鸡尾酒会的极端噪声场景下，人类的听觉系统仍然能够持续地追踪单个目标人的声音。而著名的McGurk效应^[1]指出，人类的听觉系统可以同时利用视觉和听觉信号进行语音感知。而神经生理学的其他诸多研究^[2-5]都已经证实，视觉信号（例如人脸和唇形动作等）能够在噪声环境下有效地帮助人类感知相应的说话人的语音信息。因此，音视频语音识别技术是实现拟人化的语音对话与交互技术的重要技术之一。

近年来，音视频语音识别技术快速发展。受到端到端的语音识别的启发，研究者提出了端到端的音视频语音识别技术，使用音视频原始信号序列直接作为输入，预测文本输出。在端到端音视频语音识别中，视觉表征提取模块以及音视频模态融合模块的设计是重点研究问

题。除了传统的有监督学习，音视频自监督、半监督学习等范式被应用于音视频语音识别任务当中，可以利用大量无标注的音视频数据训练模型，仅用少量人工文本标注就可以达到很好的识别效果。虽然近期音视频语音识别有了很大进展，但在视频模态缺失、小语种等复杂场景，音视频语音识别技术仍然存在许多技术瓶颈，在进一步实用化和普及化方面存在挑战。

本文将首先针对音视频语音识别技术的现状进行回顾，并总结其中的关键性进展和技术方法，如图1所示。基于当前研究现状，本文对音视频语音识别存在的挑战进行分析，对未来的研究和应用前景进行展望。

1 端到端的音视频语音识别框架

早期的音视频语音识别技术通常包括视觉特征提取、声学特征提取，以及基于HMM-GMM的序列统计模型等部分组成，其中视觉特征以及声学特征通常需要人工设计^[6,7]。在深度学习技术出现的早期，研究者提出利用深

度神经网络对唇形视频和音频分别提取瓶颈特征^[8-13]，并进一步送入到分类器中进行多模态音视频语音识别。随着深度学习技术的进一步发展，研究者提出了端到端的音视频语音识别方法^[14-18]，对音频和视频的表征提取和分类进行联合建模和训练。端到端的音视频语音识别使用序列到序列的模型结构，对音频帧序列和视频图像帧的输入序列到文本的输出序列之间的映射关系进行直接建模，其中代表性的方法有时间连接分类 (Connectionist Temporal Classification, CTC)^[15,19]、基于注意力机制的编码器-解码器 (Attention-based Encoder-Decoder, AED)^[15,18]、混合 CTC/Attention，以及循环神经网络转换模型 (Recurrent Neural Network Transducer, RNNT)^[17]。代表性的端到端音视频语音识别框架的模型结构示意图如图2所示。

1.1 基于AED和CTC的方法

Afouras等^[15]提出的TM-seq2seq与TM-CTC，是较早提出的分别基于AED和CTC

的端到端音视频语音识别的方法。这两种方法使用相同的音频以及视频特征提取模块。其中，音频采用对数幅度谱进行输入，使用Transformer网络进行处理得到音频表征。视频则首先对每帧图像采用3D/2D ResNet网络进行独立处理，然后通过Transformer网络处理并输出视觉表征。本文以TM-seq2seq和TM-CTC为例分别描述基于AED和CTC方法的结构。

1.1.1 基于AED的方法

TM-seq2seq将音频和视频特征提取网络作为独立的编码器模块。在解码器网络中，采用两个独立的多头注意力模块，分别对音频和视频特征进行处理，并提取当前时刻关注的特征。得到的音视频特征在通道维度拼接之后输入到解码器中。解码器最终根据历史时刻的解码文本结果以及当前时刻所关注的音视频特征作为条件，输出当前时刻预测的文本概率分布。在模型训练中，使用交叉熵准则对编码器-解码器网络整体进行参数优化。在模型解码时，TM-seq2seq可以融合外置的语言模型，基于




图2 代表性的端到端音视频语音识别模型结构示意图

波束搜索 (beam search) 算法, 解码出预测的音视频。

1.1.2 基于CTC的方法

TM-CTC则直接将音频和视频中间层特征在通道维度进行拼接, 并送入Transformer网络中进一步处理, 然后预测文本的后验概率分布。模型在训练中使用CTC损失函数进行参数优化。模型训练结束之后, 可以融合外置语言模型, 使用CTC的前缀搜索算法融合语言模型对解码路径进行打分, 最终输出识别文本的解码结果。

1.1.3 基于混合CTC/Attention的方法

Petridis等^[13]最早提出了基于混合CTC/Attention框架的端到端音视频语音识别模型。具体而言, 混合CTC/Attention模型基于多任务学习策略, 在训练中同时使用CTC以及AED损失函数, 在测试中使用CTC以及AED解码结果联合打分, 使得音视频语音识别效果超过单独使用CTC或者AED框架的模型。CTC损失函数在优化中引入了语音帧之间的独立性假设。而AED模型则避免了这一个不合理假设, 并直接对序列的条件概率进行建模, 所以AED模型一般可以取得相比CTC模型更好的识别结果。但是, AED模型在解码中难以保证注意力机制的单调性, 容易出现解码结果不稳定的现象。AED模型在模型训练以及解码中分别联合CTC准则以及CTC输出概率打分则可以有效地缓解这一问题。目前, 混合CTC/Attention的框架已经被广泛应用于端到端的音视频语音识别任务中^[18]。

1.2 基于RNNT的方法

Makino等^[17]最早将RNNT框架应用于音视频语音识别任务中。具体而言, RNNT模型一般包含编码网络(encoder)、解

码网络(decoder), 以及联合网络(joint network)三个部分。其中, 编码网络对音视频进行处理得到音视频表征, 解码网络则对历史时刻的文本输出进行建模, 联合网络用于组合编码以及解码网络输出并预测当前的输出文本的概率分布。RNNT框架对音视频特征帧和文本序列之间的所有潜在单调对齐路径进行计算, 并最大化文本的预测概率。Makino等^[17]提出对视频图像帧进行时间插值处理, 以便得到和音频成固定倍率的视频帧输入。然后, 采用卷积网络对视频帧进行处理, 将输出和语音的梅尔滤波器特征拼接送入LSTM网络中得到编码器输出。解码器和联合网络则分别采用了LSTM网络和线性网络。实验采用了3万小时谷歌内部的YouTube数据训练模型, 最终在LRS3测试集上的唇语识别和音视频语音识别词错误率分别达到了33.6%和4.5%。这一结果在当时大幅度领先TM-seq2seq基线, 证明了基于RNNT框架和大规模数据训练音视频语音识别模型的有效性。

1.3 音视频语音识别的关键模块

1.3.1 视觉表征提取

视觉表征提取的目标是从唇形视频中提取含有语音发音内容相关的信息, 以便与语音信号形成互补, 提升最终的识别效果。视觉表征提取是提升音视频语音识别性能的关键, 也是音视频语音识别的一大难点问题, 因为唇形视频对于区分发音内容具有一定的歧义性。相对于音频, 视频通常含有的语言内容信息更弱。真实环境中, 唇形视频可能存在距离远、画面质量低、暗光、可视角度大等问题, 都对唇形视频的发音内容信息提取造成了很大挑战。

研究者对音视频语音识别以及唇语识别中的视觉表征提取问题开展了广泛的研究。

Assael等^[20]在句子级别的唇语识别任务中提出了采用3DCNN网络对唇形图像序列进行建模。LSTM网络^[21]、3DCNN-LSTM网络^[22]等也被应用于唇语识别任务中。目前应用较为广泛的视觉表征提取结构是Afouras等^[15]提出的3DCNN-ResNet网络,用以抽取具有局部视野的中间视觉表征,一般在该网络基础上再堆叠TCN网络^[23]、Transformer网络^[15]或Conformer网络^[18]对长时间的唇语视频上下文关系建模。为了加速模型计算, Ma等^[24]提出了采用轻量化卷积网络ShuffleNet V2替换ResNet网络,在计算效率上有所提升。Prajwal等提出了一种基于visual Transformer pooling的模型结构^[25],使用3D/2DCNN网络首先处理并得到每帧图像的浅层表征,然后采用Transformer网络对图像的时空关系进一步建模,并采用注意力机制得到该图像帧的池化表征。Serdyuk等^[16]则提出了一种完全基于Transformer的视觉表征抽取模型。该模型将唇形图像序列首先按照预设大小进行时间-空间分块,对每一块内部的序列采用前端Transformer网络建模,并直接抽取第一个位置的对应的表征作为该部分的输出表征,最后将得到的表征序列进一步送入后端Transformer网络中进行长距离的上下文关系建模。

1.3.2 音视频模态融合

音视频多模态信息融合是另一个音视频语音识别研究中的重点问题。在音视频语音识别中,多模态信息融合的目的是充分地结合音频和视频信号的信息进行识别。音频和视频信号本身有较大的模态差异性,含有的发音内容信息的多少也存在不同,两者在不同的数据条件下的互补性作用也存在动态变化的特点。因此,音视频模态融合是具有挑战性的难题。尤

其是在一些视频模态缺失、视频中唇形遮挡等复杂情况下,音视频语音识别有可能出现效果严重下降的问题。当音视频融合过于依赖音频模态输入时,视频模态的输入则对识别效果的提升幅度不够理想,无法充分发挥音视频语音识别相对语音识别的优势。

在音视频融合中,当前的主流方法可以分为表征层面融合和决策层面融合。表征层面融合将音频和视频提取的中间层表征进行融合,然后送入共享的解码器中进行处理,是目前应用最广泛的音视频融合方法之一。决策层面融合则使用多个模态独立的解码器,然后对不同模态解码输出的预测结果进行融合。

在表征融合方面,对音频和视频表征在通道维度进行直接拼接融合是一种被广泛采用的方法^[14-19]。AV Align方法^[26]提出了采用注意力机制对音视频模态表征进行时间对齐和融合。Yu等^[27]在基于音视频的重叠语音识别中提出了基于门控机制的音视频融合(gated fusion)结构,并提出了视觉表征驱动和音视频表征驱动计算门控的两种变体。Li等^[28]还提出了基于Transformer联合自注意力机制的(unified-attention)融合方法,对于音视频输入不对齐或者视频帧缺失的情况具有更好的鲁棒性。Predict-and-update模型^[29]对唇形的字符表征设计了基于分解-激励前馈网络(factorized-excitation FFN)与音频表征进行融合,并对比了不同的音视频融合阶段对于音视频语音识别效果的影响。受到音视频语音增强启发, Hong等^[30]提出了一种视觉上下文驱动的音频表征增强网络(Visual Context-driven Audio Feature Enhancement, V-CAFE),并应用于端到端的音视频语音识别任务中。为了增强模型对于视频受损或者音视频模态缺失的鲁棒性,大部分研究的模

型训练会随机丢弃音频或视频表征^[14,17,31]。Dai等^[32]提出了一种基于模态偏置假设改进的随机丢弃的音视频融合策略，可以有效缓解训练中的模态偏置问题。针对视频缺失的问题，Chang等^[33]提出了基于级联的音视频融合方法，模型能够根据视频模态缺失情况，采用音频帧或音视频融合帧送入解码器中处理。Hong等^[34]则考虑了视频被遮挡以及含有噪声的情况，并提出了一种音视频模态置信度打分模块，根据音视频置信度得分缩放相应模态的表征之后再行融合。

在决策融合方面，Yu等^[35]提出了一种基于置信度信息的策略融合网络，对音视频输出概率进行融合。Chen等^[36]提出一种基于强化学习的方法，对视频解码器输出和音视频解码器输出采用一个策略网络进行动态融合，能够有效缓解音视频语音识别中过度依赖音频的问题。

2 音视频语音识别的学习范式

在音视频语音识别中，模型的训练方式主要包括有监督学习、自监督学习，以及半监督学习。传统的有监督学习采用视频语音以及相应的标签数据，使用标签预测的损失函数进行模型优化。而自监督学习框架则通常分为预训练和微调两个阶段。在预训练阶段，首先利用无标注的音视频数据，基于掩码损失预测或者音视频跨模态对比学习等代理任务训练模型，从音视频数据中提取通用的深层表征。然后在微调阶段，利用有标注的音视频数据，针对音视频语音识别任务进行有监督的学习和优化。半监督学习则利用一部分有标注的数据先训练音视频语音识别模型，继而利用训练好的模型对无标注音视频语音进行伪标签标注，随后联合所有音视频数据训练模型。

2.1 有监督学习

一般的端到端音视频语音识别直接采用文本标签训练模型，根据使用的序列到序列模型框架，采用CTC损失、RNNT损失或者交叉熵损失作为模型优化的目标函数。为了在模型训练过程中进一步约束模型，研究者提出了使用辅助目标作为训练的正则化项。这种方法也可以被视为一种多任务学习。Sterpu等^[37]基于AV Align模型^[26]提出了使用唇形相关的发音动作单元（action units）作为视觉表征的辅助训练目标，提升音视频模态对齐的效果。Ma等^[38,39]在唇语识别任务中提出了一种基于音频表征作为辅助训练目标的方法。其中，音频表征目标使用一个训练好的语音识别模型，通过抽取编码器的中间层表征得到。

2.2 自监督学习

随着近年来自监督学习范式的发展，基于音视频自监督学习的音视频语音识别方法也得到了越来越多的关注。早期的音视频自监督学习关注音视频局部特征的学习，大多方法利用了音视频模态之间的天然对齐特性互为监督信息，其中代表性的方法包括AVTS^[40]、XDC^[41]，以及局部-全局音视频对比学习^[42]方法等。LiRA^[43]提出了一种跨模态自监督学习的方法，基于预训练的音频自监督学习模型PHASE抽取音频表征作为目标，对视觉表征提取模块进行训练。

音频自监督学习方法在近期发展迅速，研究者受其启发并扩展到了音视频自监督学习中，其中包括基于HuBERT模型^[44]扩展到音视频语音中的AV-HuBERT^[45]，基于data2vec模型^[46]扩展到音视频语音中的AV-data2vec模型^[47]。在AV-HuBERT的模型基础上，Zhu等^[48]进一步引入了额外的文本模态，实现了

音频、视频、文本三个模态表征的联合学习。u-HuBERT^[49]则进一步在AV-HuBERT引入了额外的单模态语音，并且在理论上可以引入更多模态的数据。AV2vec模型^[50]和RAVE_n模型^[51]则使用了基于指数滑动平均方法的教师模型，对学生模型在训练中进行多模态自蒸馏学习。音视频自监督音视频语音识别在唇语识别以及音视频语音识别任务上取得了较好的效果，目前很多研究^[36,52]都采用了预训练的自监督模型初始化音视频语音识别模型的参数。

2.3 半监督学习

半监督的音视频语音识别方法大多受到音频语音识别的半监督学习方法的启发。Auto-AVSR模型^[53]利用预训练的语音识别模型对未标注的音视频语音识别数据集生成伪标签，然后利用有标注数据和伪标注数据联合起来训练音视频语音识别模型。AV-CPL方法^[54]则提出基于持续伪标签更新的半监督学习方法，对无标注的音视频不断采用更新后的模型进行伪标签的持续优化。自监督学习的方法受限于较少的标注数据，所以效果一般差于半监督学习。但是，自监督学习方法可以和半监督学习结合^[45,51]，即开始时使用自监督学习得到初始的音视频语音识别模型，然后利用初始模型对无标注数据生成文本伪标签，再联合有标注数据共同优化识别模型，一般可以取得更好的音视频语音识别效果。

3 音视频语音识别技术的未来展望

近几年，随着当前训练数据的不断增加、深度学习模型与学习范式的不断进步，音视频语音识别的效果已经有了很大的提升。但是，音视频语音识别仍然存在着很多挑战，未

来的研究需要更加关注以下几点。

第一，当前音视频语音识别在更加开放和复杂的环境，例如家居场景、多人自由交谈等场景下表现仍然不佳。目前，大多数研究仍然过度聚焦于LRS2和LRS3数据集，但是唇语识别以及音视频语音识别在这两个数据集上的词错误率已经出现了饱和的现象，例如Auto-AVSR在LRS3上音视频语音识别词错误率达到了0.9%。在其他更加具有挑战性的场景测试集下，例如MISP 2021^[55]、谷歌的YTDEV^[16]等，音视频语音识别的效果仍然不佳。在MISP 2021 AVSR比赛中，冠军队伍的字错误率仍然高达24.6%。因此，音视频语音识别未来的研究需要关注更多复杂条件的数据集表现，避免对单一或者多个类似场景数据集产生过拟合。

第二，音视频语音识别在数据稀疏的小语种下表现仍然有待提升。与语音识别类似，小语种音视频语音识别仍然存在很多挑战。相对于单语音，小语种的音视频数据更加难以采集，很多小语种甚至面临无法采集到视频数据的挑战。如何处理这种视觉数据缺失、极低资源的情况，提升小语种的音视频语音识别效果，仍然是需要进一步研究和解决的问题。

第三，音视频语音识别的计算量相对较大，在实际应用部署中会产生较高的推理计算成本。在很多高信噪比条件下，音视频语音识别相对音频语音识别提升幅度并不显著，带来的收益并不高。因此，如何进一步降低音视频语音识别的计算负担，实现视觉模块的轻量化计算，同时针对环境噪声情况实现有效的动态计算，是音视频语音识别实用化需要解决的重要问题之一。

第四，音视频语音识别在视频模态缺失、

人脸受到遮挡等情况下的鲁棒性有待进一步提升。近期，研究者开始越来越关注音视频语音识别在实际应用中出现的此类问题^[29,30]，提出的方法一定程度上提升了音视频语音识别的鲁棒性。但是，这些挑战并没有被完全解决，尤其当出现训练集分布外的视频受损、遮挡等情况，音视频语音识别效果仍然可能差于单模态语音识别。理想的音视频语音识别能够最大化地利用视频中的增量信息，而避免视频中出现的干扰信息的影响。如何更好地实现这一目标仍然是开放性的问题。

4 结束语

音视频语音识别技术能够有效地提升语音识别在噪声环境下的识别准确率，是目前多模态语音交互技术的重要研究方向。本文对音视频语音识别的技术现状进行了总结，重点回顾了端到端的音视频语音识别框架以及音视频语音识别的学习范式。同时，本文也对音视频语音识别未来的发展方向进行了展望。可以预见的是，随着搭载摄像头和麦克风智能设备的普及，音视频语音识别将持续作为工业界和学术界关注的热点问题，并在未来各类真实以及噪声场景下得到更广泛的应用。

参考文献

- [1] MCGURK H, MACDONALD J. Hearing lips and seeing voices[J]. *Nature*, 1976, 264(5588): 746-748.
- [2] MACLEOD A, SUMMERFIELD Q. Quantifying the contribution of vision to speech perception in noise[J]. *British Journal of Audiology*, 1987, 21(2): 131-141.
- [3] MASSARO D. Speech perception by ear and eye: a paradigm for psychological inquiry[J]. *Behavioral and Brain Sciences*, 1989, 12(4): 741-755.
- [4] ROSENBLUM L D. Speech perception as a multimodal phenomenon[J]. *Current Directions in Psychological Science*, 2008, 17(6): 405-409.
- [5] CHEN H, DU J, HU Y, et al. Correlating subword

- articulation with lip shapes for embedding aware audio-visual speech enhancement[J]. *Neural Networks*, 2021, 143: 171-182.
- [6] DUPONT S, LUETTIN J. Audio-visual speech modeling for continuous speech recognition[J]. *IEEE Transactions on Multimedia*, 2000, 2(3): 141-151.
- [7] POMIANOS G, NETI C, GRAVIER G, et al. Recent advances in the automatic recognition of audiovisual speech[J]. *Proceedings of the IEEE*, 2003, 91(9): 1306-1326.
- [8] NGIAM J, KHOSLA A, KIM M, et al. Multimodal deep learning[C]//*Proceedings of the 28th International Conference on International Conference on Machine Learning*, 28 June 2011-2 July 2011, Bellevue Washington USA. Madison: Omnipress, 2011: 689-696.
- [9] HU D, LI X L, LU X Q. Temporal multimodal learning in audiovisual speech recognition[C]//*2016 IEEE Conference on Computer Vision and Pattern Recognition*, Las Vegas, NV, USA. IEEE, 2016: 3574-3582.
- [10] NINOMIYA H, KITAOKA N, TAMURA S, et al. Integration of deep bottleneck features for audio-visual speech recognition[C]//*Interspeech 2015*, ISCA: ISCA, 2015: 563-567.
- [11] MROUEH Y, MARCHERET E, GOEL V. Deep multimodal learning for Audio-Visual Speech Recognition[C]//*2015 IEEE International Conference on Acoustics, Speech and Signal Processing*, South Brisbane, Queensland, Australia. IEEE, 2015: 2130-2134.
- [12] TAKASHIMA Y, AIHARA R, TAKIGUCHI T, et al. Audio-visual speech recognition using bimodal-trained bottleneck features for a person with severe hearing loss[C]//*Interspeech 2016*, ISCA: ISCA, 2016: 277-281.
- [13] PETRIDIS S, PANTIC M. Deep complementary bottleneck features for visual speech recognition[C]//*2016 IEEE International Conference on Acoustics, Speech and Signal Processing*, Shanghai. IEEE, 2016: 2304-2308.
- [14] CHUNG J S, SENIOR A, VINIYALS O, et al. Lip reading sentences in the wild[C]//*2017 IEEE Conference on Computer Vision and Pattern Recognition*, Honolulu, HI, USA. IEEE, 2017: 3444-3453.
- [15] AFOURAS T, CHUNG J S, SENIOR A, et al. Deep audio-visual speech recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022, 44(12): 8717-8727.
- [16] SERDYUK D, BRAGA O, SIOHAN O. Transformer-based video front-ends for audio-visual speech recognition for single and multi-person video[C]//*Interspeech 2022*. ISCA, 2022: 2833-2837.
- [17] MAKINO T, LIAO H, ASSAEL Y, et al. Recurrent neural network transducer for audio-visual speech recognition[C]//*2019 IEEE Automatic Speech Recognition and Understanding Workshop*, SG, Singapore. IEEE, 2019: 905-912.
- [18] MA P C, PETRIDIS S, PANTIC M. End-to-end audio-visual speech recognition with conformers[C]//*2021 IEEE*

- International Conference on Acoustics, Speech and Signal Processing, Toronto, ON, Canada. IEEE, 2021: 7613-7617.
- [19] PETRIDIS S, STAFYLAKIS T, MA P C, et al. Audio-visual speech recognition with a hybrid CTC/attention architecture[C]//2018 IEEE Spoken Language Technology Workshop, Athens, Greece. IEEE, 2018: 513-520.
- [20] ASSAEL Y M, SHILLINGFORD B, WHITESON S, et al. LipNet: sentence-level lipreading[Z]. arXiv preprint arXiv: 1611.01599, 2016.
- [21] WAND M, KOUTNÍK J, SCHMIDHUBER J. Lipreading with long short-term memory[C]//2016 IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2016: 6115-6119.
- [22] STAFYLAKIS T, TZIMIROPOULOS G. Combining residual networks with LSTMs for lipreading[C]//Interspeech 2017, ISCA: ISCA, 2017: 3652-3656.
- [23] GAO R H, GRAUMAN K. VisualVoice: audio-visual speech separation with cross-modal consistency[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Nashville, TN, USA. IEEE, 2021: 15490-15500.
- [24] MA P C, MARTINEZ B, PETRIDIS S, et al. Towards practical lipreading with distilled and efficient models[C]//ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing, Toronto, ON, Canada. IEEE, 2021: 7608-7612.
- [25] PRAJWAL K R, AFOURAS T, ZISSERMAN A. Sub-word level lip reading with visual attention[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans, LA, USA. IEEE, 2022: 5152-5162.
- [26] STERPU G, SAAM C, HARTE N. Attention-based audio-visual fusion for robust automatic speech recognition[C]//Proceedings of the 20th ACM International Conference on Multimodal Interaction, Boulder, CO, USA. ACM, 2018: 111-115.
- [27] YU J W, ZHANG S X, WU J, et al. Audio-visual recognition of overlapped speech for the LRS2 dataset[C]//ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing, Barcelona, Spain. IEEE, 2020: 6984-6988.
- [28] LI J H, LI C D, WU Y F, et al. Robust audio-visual ASR with unified cross-modal attention[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing, Rhodes Island, Greece. IEEE, 2023: 1-5.
- [29] WANG J D, QIAN X Y, LI H Z. Predict-and-update network: audio-visual speech recognition inspired by human speech perception[Z]. arXiv preprint arXiv: 2209.01768, 2022.
- [30] HONG J, KIM M, YOO D H. Visual context-driven audio feature enhancement for robust end-to-end audio-visual speech recognition[Z]. arXiv preprint arXiv: 2207.06020, 2022.
- [31] ZHANG S L, LEI M, MA B, et al. Robust audio-visual speech recognition using bimodal dfsmn with multi-condition training and dropout regularization[C]//2019 IEEE International Conference on Acoustics, Speech and Signal Processing, Brighton, United Kingdom. IEEE, 2019: 6570-6574.
- [32] DAI Y S, CHEN H, DU J, et al. A study of dropout-induced modality bias on robustness to missing video frames for audio-visual speech recognition[Z]. arXiv preprint arXiv: 2403.04245, 2024.
- [33] CHANG O, BRAGA O, LIAO H, et al. On robustness to missing video for audiovisual speech recognition[Z]. arXiv preprint arXiv: 2312.10088, 2023.
- [34] HONG J, KIM M, CHOI J, et al. Watch or listen: robust audio-visual speech recognition with visual corruption modeling and reliability scoring[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Vancouver, BC, Canada. IEEE, 2023: 18783-18794.
- [35] YU W T, ZEILER S, KOLOSSA D. Fusing information streams in end-to-end audio-visual speech recognition[C]//2021 IEEE International Conference on Acoustics, Speech and Signal Processing, Toronto, ON, Canada. IEEE, 2021: 3430-3434.
- [36] CHEN C, HU Y C, ZHANG Q, et al. Leveraging modality-specific representations for audio-visual speech recognition via reinforcement learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. AAAI, 2023, 37(11): 12607-12615.
- [37] STERPU G, SAAM C, HARTE N. How to teach DNNs to pay attention to the visual modality in speech recognition[J]. ACM Transactions on Audio, Speech, and Language Processing, 2020, 28: 1052-1064.
- [38] MA P C, PETRIDIS S, PANTIC M. Visual speech recognition for multiple languages in the wild[J]. Nature Machine Intelligence, 2022, 4: 930-939.
- [39] MA P C, WANG Y J, PETRIDIS S, et al. Training strategies for improved lip-reading[C]//2022 IEEE International Conference on Acoustics, Speech and Signal Processing, Singapore, Singapore. IEEE, 2022: 8472-8476.
- [40] KORBAR B, TRAN D, TORRESANI L. Cooperative learning of audio and video models from self-supervised synchronization[Z]. arXiv preprint arXiv: 1807.00230, 2018.
- [41] ALWASSEL H, MAHAJAN D, TORRESANI L, et al. Self-supervised learning by cross-modal audio-video clustering[Z]. arXiv preprint arXiv: 1911.12667, 2019.
- [42] MA S, ZENG Z Y, MCDUFF D J, et al. Contrastive learning of global and local video representations[C]//Conference and Workshop on Neural Information Processing Systems. Curran Associates, 2021, 34: 7025-7040.
- [43] MA P C, MIRA R, PETRIDIS S, et al. LiRA: learning visual speech representations from audio through self-supervision[C]//Interspeech 2021. ISCA, 2021: 3011-3015.
- [44] HSU W N, BOLTE B, TSAI Y H H, et al. HuBERT: self-supervised speech representation learning by masked prediction of hidden units[J]. IEEE/ACM Transactions on Audio, Speech and Language Processing, 29: 3451-3460.

- [45] SHI B, HSU W N, LAKHOTIA K, et al. Learning audio-visual speech representation by masked multimodal cluster prediction[C]//International Conference on Learning Representations. ICRL, 2022.
- [46] BAEVSKI A, HSU W N, XU Q T, et al. Data2vec: a general framework for self-supervised learning in speech, vision and language[C]//International Conference on Machine Learning. ICML, 2022, 162: 1298-1312.
- [47] LIAN J C, BAEVSKI A, HSU W N, et al. Av-Data2Vec: self-supervised learning of audio-visual speech representations with contextualized target representations[C]//2023 IEEE Automatic Speech Recognition and Understanding Workshop. IEEE, 2023: 1-8.
- [48] ZHU Q S, ZHOU L, ZHANG Z Q, et al. VatLM: visual-audio-text pre-training with unified masked prediction for speech representation learning[J]. IEEE Transactions on Multimedia, 2024: 1-11.
- [49] HSU W N, SHI B W. U-HuBERT: unified Mixed-Modal Speech Pretraining And Zero-Shot Transfer to Unlabeled Modality[C]//Advances in Neural Information Processing Systems, 2022, 35: 21157-21170.
- [50] ZHANG J X, WAN G S, LING Z H, et al. Self-supervised audio-visual speech representations learning by multimodal self-distillation[C]//2023 IEEE International Conference on Acoustics, Speech and Signal Processing, Rhodes Island, Greece. IEEE, 2023: 1-5.
- [51] HALIASSOS A, MA P C, MIRA R, et al. Jointly learning visual and auditory speech representations from raw data[C]//International Conference on Learning Representations, 2023.
- [52] PAN X C, CHEN P Y, GONG Y C, et al. Leveraging unimodal self-supervised learning for multimodal audio-visual speech recognition[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics, Dublin, Ireland. Stroudsburg, PA, USA: Association for Computational Linguistics, 2022: 4491-4503.
- [53] MA P C, HALIASSOS A, FERNANDEZ-LOPEZ A, et al. Auto-AVSR: audio-visual speech recognition with automatic labels[C]//2023 IEEE International Conference on Acoustics, Speech and Signal Processing, Rhodes Island, Greece. IEEE, 2023: 1-5.
- [54] ROUDITCHENKO A, COLLOBERT R, LIKHOMANENKO T. AV-CPL: continuous pseudo-labeling for audio-visual speech recognition[Z]. arXiv preprint arXiv: 2309.17395, 2023.
- [55] CHEN H, ZHOU H S, DU J, et al. The first multimodal information based speech processing (MISP) challenge: data, tasks, baselines and results[C]//2022 IEEE International Conference on Acoustics, Speech and Signal Processing, Singapore. IEEE, 2022: 9266-9270.

作者简介

- 张景宣 男，陕西师范大学计算机学院讲师。2021年毕业于中国科学技术大学，获得信息与通信工程专业博士学位。研究方向为多模态语音、语音识别、语音合成、语音无监督预训练等。
- 万根顺 男，中国科学技术大学博士生在读。2012年毕业于江苏大学。研究方向为多模态语音、语音识别、语音无监督预训练等。