

密级:

保密期限:

北京邮电大学

硕士学位论文



题目: 针对人工智能的对抗样本生成算法
的研究与实现

学 号: 2018140815

姓 名: 都娟

专 业: 计算机技术

导 师: 朱洪亮

学 院: 网络空间安全学院

2021 年 6 月 7 日

中国·北京

密级： 保密期限：

北京邮电大学

硕士学位论文



题目： 针对人工智能的对抗样本生成
算法的研究与实现

学 号： 2018140815
姓 名： 都娟
专 业： 计算机技术
导 师： 朱洪亮
学 院： 网络空间安全学院

2021 年 6 月 7 日

Secret Level:

Confidentiality Period:



BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

Thesis for Master Degree

Topic: Research and Implementation of Adversarial
Examples for Artificial Intelligence

Student No.: 2018140815

Candidate: Du Juan

Subject: Computer Technology

Supervisor: Zhu Hongliang

Institute: School of Cyberspace Security

June 7, 2021

针对人工智能的对抗样本生成算法的研究与实现

摘 要

近年来,人工智能迎来发展高峰,机器学习作为人工智能的核心技术之一,已经被广泛应用于各个领域,但是机器学习也面临着不少安全问题的严峻挑战,对抗样本攻击就是其中最广泛的攻击方式之一。开展对抗样本攻击方法的研究有利于测试并提升机器学习算法的鲁棒性和安全性。

虽然目前学术界已经提出了很多种对抗样本攻击的方法,但大多数具有特定的条件限制,无法在现实环境中应用。一方面是因为现实环境多为黑盒,攻击者无法得知模型的具体结构和参数;另一方面,对抗样本在生成后需要通过系统的硬件采集设备才能输入算法模型,数据质量受损将极大影响攻击成功率。

本文针对人工智能领域的生物特征识别系统,研究了人脸对抗样本和语音对抗样本的生成算法,并且迁移到真实环境中进行对抗样本攻击,进行攻防博弈,验证现有人脸识别系统、语音识别系统和声纹识别系统的安全性和鲁棒性。论文的主要工作如下:

(1) 本文针对当前疫情情况下人们在公共场所通常佩戴口罩的现象,提出了基于注意力机制的对抗性攻击算法。算法通过视觉感知机制,搜索出容易被攻击的口罩图案区域,然后针对性地添加噪声,使得分类器分类错误,造成人脸识别失败。本文提出了基于集成学习的人脸对抗样本生成方法,通过集成多个骨干网络和损失函数,快速生成高质量人脸对抗样本,大大提高了生成速率和对抗样本质量。

(2) 本文使用 LFW 数据集和 CASIA-Webface 人脸数据集进行模型训练和测试,分别使用基于注意力机制的攻击方法和基于集成学习的攻击方法生成人脸对抗样本,并且使用商用的人脸识别系统接口进行了人脸识别和活体检测实验。实验的攻击成功率为 88.5%,高于 PGD 攻击算法和 L-FGSM 算法,并且 L_2 距离、峰值信噪比和结构相似性指标均高于 PGD 攻击算法和 L-FGSM 算法,生成图像的质量较好。

(3) 本文提出了基于 BERT 的词级韵律特征提取方法,不仅能够提取音频的声纹特征,而且能够表征词级特征,从而更好地生成语音对抗样本。另外针对语音识别和声纹识别系统,本文分别提出了基于内容和基于声纹的语音对抗样本生成算法,分别生成了能够欺骗语音识别系统和声纹识别系统的对抗性音频,并且不被人耳察觉。

(4) 本文在 MagicData 中文手机录音音频语料库和 ST-CMDS 中文数据集上进行了模型训练和测试。并且使用生成的对抗样本成功攻击了商用的语音识别系统和声纹识别系统,实现了黑盒对抗攻击。

关键词 人工智能 对抗样本 对抗攻击 人脸识别 语音识别 声纹识别

RESEARCH AND IMPLEMENTATION OF ADVERSARIAL EXAMPLES FOR ARTIFICIAL INTELLIGENCE

ABSTRACT

In recent years, artificial intelligence ushered in the peak of development, machine learning as one of the core technologies of artificial intelligence, has been widely used in various fields. But machine learning is facing a lot of severe challenges of security problems now, and adversarial example attack is one of the most extensive attack methods. The research of adversarial example attack method is helpful to test and improve the robustness and security of machine learning algorithm.

At present, many methods have been proposed to resist the adversarial example attack. But most of them need specific conditions and can not be applied in the real environment. On the one hand, the real environment is mostly black box scenes. The attacker can't get the specific structure and parameters of the model. On the other hand, the adversarial examples need to be input into the algorithm model through the hardware acquisition device of the system after they are generated. The data quality damage will greatly affect the attack success rate.

This paper aiming at the biometric recognition system in the field of artificial intelligence and studies how to generate high-quality face and voice adversarial examples, and migrate the them to the real environment to resist adversarial attacks, so as to verify the security and robustness of the existing face recognition systems、speech recognition systems and speaker recognition systems. The main work of this paper is as follows:

(1) In view of the phenomenon that people usually wear masks in public places in the current epidemic situation, this paper proposes an adversarial example attack algorithm based on attention mechanism. Through the visual perception mechanism, the algorithm searches out the mask pattern area which is easy to be attacked, and then adds noise to make the classifier classification error, resulting in face recognition failure. In this paper, a face confrontation sample generation method based on adaboost is proposed. By integrating multiple backbone networks and loss functions, high-quality face adversarial examples are generated quickly, which greatly improves the generation speed and the quality of adversarial examples.

(2) In this paper, LFW data set and CASIA Webface face data set are used for model training and testing. The attack method based on attention mechanism and the attack method based on ensemble learning are used to generate face adversarial examples respectively. The commercial face recognition system interface is used for face recognition and live detection experiments, and the black box attack is realized.

(3) In this paper, we propose a word level prosody feature extraction method based on BERT. It can not only extract the speech features of audio, but also represent the word level features, so as to better generate audio adversarial examples. In addition, for speech recognition system and speaker recognition system, this paper proposes content-based and speech-based adversarial example generation algorithms respectively, which can generate countermeasure audio that can deceive speech recognition system and speaker recognition system without being detected by human ears.

(4) In this paper, the model is trained and tested on the Magic Data Chinese mobile recording audio corpus and S-CMDS Chinese data set. The generated adversarial examples are used to attack the commercial speech recognition system and speaker recognition system successfully, and the black box counter attack is realized.

KEY WORDS AI Adversarial Example Adversarial attack
Face Recognition Speech Recognition

目 录

第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 对抗样本的研究现状	2
1.2.2 人脸对抗样本生成方法	4
1.2.3 语音对抗样本生成方法	5
1.3 主要内容	6
1.4 组织结构	7
1.5 本章小结	8
第二章 相关理论及技术介绍	9
2.1 对抗攻击算法	9
2.1.1 单像素攻击算法	9
2.1.2 基于梯度的攻击算法	10
2.1.3 对抗生成网络	11
2.2 深度学习	12
2.2.1 深度神经网络	12
2.2.2 卷积神经网络	13
2.2.3 残差神经网络	16
2.3 生物识别系统原理	18
2.3.1 人脸识别系统	18
2.3.2 语音识别系统	20
2.4 本章小结	21
第三章 人脸对抗样本生成算法研究	22
3.1 基于注意力机制的攻击方法	22

3.1.1 视觉感知机制研究.....	22
3.1.2 注意力机制研究.....	25
3.1.3 网络结构.....	25
3.1.4 算法实现.....	26
3.2 基于集成学习的人脸对抗样本生成算法.....	27
3.2.1 数据预处理.....	27
3.2.2 基于 Adaboost 的集成学习.....	30
3.2.3 损失函数.....	31
3.3 本章小结.....	32
第四章 语音对抗样本生成方法研究.....	34
4.1 基于 BERT 的韵律特征提取.....	34
4.1.1 韵律特征提取方法.....	36
4.1.2 基于 BERT 的层级韵律提取模型.....	38
4.2 语音对抗样本生成算法.....	40
4.2.1 基于内容的语音对抗样本生成算法.....	40
4.2.2 基于声纹的语音对抗样本生成算法.....	41
4.3 本章小结.....	42
第五章 实验过程及结果分析.....	43
5.1 实验环境与数据集.....	43
5.2 人脸对抗样本生成实验.....	44
5.2.1 模型训练.....	45
5.2.2 评价指标.....	48
5.2.3 对抗攻击实验.....	49
5.3 语音对抗样本生成实验.....	51
5.3.1 模型训练与对抗样本生成.....	51
5.3.2 评价指标.....	52

5.3.3 对抗攻击实验.....	54
5.4 本章小结.....	56
第六章 总结与展望.....	57
6.1 本文工作总结.....	57
6.2 问题与展望.....	58
参考文献.....	59
第七章 致谢.....	63

第一章 绪论

1.1 研究背景与意义

近年来,人工智能的发展和应用愈加广泛,机器学习作为人工智能的核心技术之一,已经被广泛应用于人脸识别、自动驾驶、智能控制、语音识别等各个领域。越来越多的软件和系统使用人脸识别、语音识别进行身份验证。手机、平板和电脑的人脸识别解锁、乘坐高铁时的刷脸验证、苹果的 Siri 语音助手、科大讯飞的语音输入法等都是其中的典型代表。深度学习能够帮助这些系统更好的认识用户、正确判断用户正在做什么和说什么。

人工智能相关技术的广泛应用给人们的生活带来了许多便利,但同时,生物特征识别系统的不完善,也暴露了不少安全性问题,对抗样本攻击就是其中最广泛的攻击方式之一。2014 年, Szegedy^[1]等人提出了深度神经网络易受对抗样本攻击的特性。对抗样本攻击是指对输入样本增加不可察觉的细微的扰动后,机器学习模型在多维特征向量层面通过样本学习,迭代计算出错误的分类结果。这种被伪造的样本就被称为对抗样本,使用对抗样本攻击生物识别系统的方式被称为对抗样本攻击^[2]。

在人脸识别系统和智能语音识别系统中,深度循环神经网络的应用已经取得了巨大的进步和商业上的成功。然而这些智能识别系统也同样面临着对抗样本攻击的潜在威胁。

由于人脸识别通常是远距离的和非接触式的身份识别方式,因此,攻击者可以通过在摄像头前摆放照片、播放视频甚至塑造 3D 真人模型等方式欺骗人脸识别系统,亦或者使用化妆、整形手术、假发道具、眼镜道具、胡子道具和口罩伪装等方式。照片攻击是将生成的被攻击身份的照片传给面部识别系统的传感器。视频攻击的攻击者可以在任何复制视频的设备中播放合法用户的视频,然后将其呈现给传感器或者摄像机。3D 蒙版攻击是攻击者构建目标面部的 3D 蒙版并将其呈现给传感器、相机。照片和视频对抗样本是最常见的人脸对抗样本攻击途径。

利用麦克风的漏洞,黑客还可以激活“Hey, Siri”或者“Ok, Google”这些基本指令,控制 iPhone 拨打某个电话号码或者进行视频通话。他们还可以命令 Amazon Echo 打开你家里门锁,甚至让奥迪 Q3 的导航系统定位到另一地点。

虽然目前学术界已经提出了很多种对抗攻击的方法,但是基于黑盒的对抗攻击方法通常需要在特定条件下,使用特定的设备进行攻击并且容易被发现。而基

于白盒的方法仅能够攻击已知模型且泛化能力较差，无法成功攻击真实环境的生物识别系统。

基于上述问题，本文针对人工智能领域的生物特征识别系统，研究了如何生成高质量的人脸对抗样本和语音对抗样本，并且迁移到真实环境中进行对抗样本攻击，验证现有人脸识别系统、语音识别系统和声纹识别系统的安全性和鲁棒性。针对人脸识别系统，提出了基于注意力机制的口罩贴片对抗样本生成算法，和基于集成学习的人脸对抗样本生成方法。针对语音识别系统提出了基于 BERT 的韵律特征提取方法，并且分别基于内容和声纹生成了能够欺骗语音识别系统和声纹识别系统的语音对抗样本。验证了现有的生物识别系统仍然面临着对抗样本攻击的安全风险。

1.2 国内外研究现状

1.2.1 对抗样本的研究现状

对抗攻击有很多分类方法，如下图 1-1 所示。根据攻击环境的不同，分为黑盒攻击和白盒攻击。黑盒攻击是在神经网络只有有限结果反馈的情况下的攻击，攻击者不知道具体的模型结构和参数信息，只通过系统的输入和输入接口便可构造欺骗人工智能系统的对抗样本；而白盒对抗则是算法完全开放、可获得包括网络结构、梯度等信息情况下的攻击。从攻击的实现来说，有基于梯度的攻击方法、有基于优化的攻击。另外根据攻击目的的不同，可分为有目标攻击和无目标攻击。




图 1-1 对抗攻击方法

现实环境中，人工智能的应用场景例如人脸识别系统、语音识别系统等易遭到黑盒攻击，而有目标的黑盒攻击可能造成巨大损失，给人工智能系统的应用带来巨大的风险。

Papemot^[4]等人在 2015 年提出了 JSMA (Jacobian Saliency Map Attack) 算法。它针对非循环前馈神经网络的进行有目标的对抗样本攻击算法。攻击时通过计算

前向导数生成一个对抗性显著图,然后确定输入特征空间与攻击目标之间的关联映射。显著图能够表征输入向量中对输出结果影响最大的特征向量。

Su^[5]等人在 2019 年提出了单点像素攻击算法 (One Pixel Attack),攻击者只需要修改图像的一个像素点就可以生成对应的对抗样本。该方法使用了差分进化算法,对需要修改的像素进行迭代计算,生成的子图与原始样本进行对比,根据调整阈值和损失筛选保留攻击效果最好的子图像,实现对抗样本攻击。单点像素攻击算法不需要知道模型的网络参数或梯度信息,属于黑盒攻击算法。

Carlini 和 Wagner^[6]在 2016 年提出了一种有效的攻击算法——C&W 算法去求解神经网络鲁棒性的上界,也用这种攻击算法来阐明防御性蒸馏并没有实质性的提高神经网络的鲁棒性,对于对抗攻击的防御依然很脆弱。作者用三种不同的距离度量 (L_0 , L_2 , L_∞) 下的攻击算法去攻击,即使是面对蒸馏网络,也达到了 100%的成功率的攻击效果。

Moosavi-Dezfooli S M^[7]等人在 2019 年的论文呢中提出了 Deepfool 算法。Deepfool 针对二分类问题和多分类的问题,可以在不同模型中推广。文章中还提出了一种简单而准确的方法计算和比较了 EOT、FGSM、deepfool 三种对抗攻击算法的鲁棒性。

Brendel W^[8]等人提出了一种基于决策的黑盒场景下的攻击方法,该方法可以对搜索方向的局部空间进行建模,论文使用 SphereFace、CosFace 和 ArcFace 进行鲁棒性测评,验证了现有人脸识别模型的脆弱性。

Athalye^[9]等人在前人研究工作的基础上提出了基于白盒的变换期望算法 (Expectation Over Transformation, EOT),EOT 的特点是生成在各种给定变换环境下都能保持对抗性的对抗样本。论文构建和制作了现实世界 3D 物体,使其能在各个角度下欺基于神经网络的生物识别系统,其生成的对抗样本具有很强的鲁棒性和普适性。

Chen P Y^[10]等人利用正负扰动带来的概率差估算一阶导数和二阶导数,通过梯度估计将黑盒转换为白盒过程。

Sarkar S^[11]等人提出了两种攻击算法,一种针对输出类别生成通用扰动,另针对不同图像生成特定扰动,两种方法均为定向攻击。

Baluja S^[12]等人通过训练一个神经网络 ATN (Adversarial Transformation Network),将原图作为输入,输出即为对抗样本。在给定原始输入样本的情况下,对分类器的输出进行最小的扰动,然后匹配目标类。这种方法生成的对抗样本保留了更多原始图像中的像素,但会在图像边缘或者角落产生较大的扰动。

Madry A^[13]等人研究了神经网络的防御对抗攻击的能力。提出了使用最强的一阶攻击训练神经网络，提高神经网络的鲁棒性，以防御几乎所有对手的攻击的方法。

1.2.2 人脸对抗样本生成方法

目前大多数针对图像的对抗样本生成算法的研究都是基于白盒进行进行的，例如：Goodfellow I J^[14]等人 2014 年提出了对抗生成网络（GAN, Generative Adversarial Network），这是一种基于白盒的攻击算法，论文对当时效果最好的人脸识别神经网络进行对抗攻击实验，目标模型为 VGG 和 OpenFace，两者的人脸识别准确度已经达到了人类水平。基于对抗生成网络的对抗样本生成算法，可以生成各种伪装，例如眼镜、帽子和纹身等，被人脸识别系统错误分类，实现不被人眼察觉的对抗攻击。

黑盒攻击时，攻击者只能获取模型的输入输出等有限的信息。基于决策的攻击属于黑盒攻击，它完全依赖于模型的最终决策，只能通过输入输出信息进行直接攻击。目前已经提出的基于决策的黑盒攻击方法有基于优化的攻击方法（Optimization-based）和边界攻击方法（Boundary Attack）等。然而，这几种方法大多需要较多的访问，效率较低，或者在有限的访问下生成的对抗样本扰动较大，易被察觉。

Dong Yin peng^[15]等人在 2019 年针对人脸识别系统，提出了一种基于进化算法的高效攻击方法，算法利用了搜索空间区域的几何特性进行攻击，并通过对搜索空间进行降维来提高攻击效率。实验表明其比已有的黑盒攻击方法更高效。同时，还对 ArcFace 人脸识别模型进行了黑盒攻击实验，充分展示了其算法的优越性。

马玉琨^[16]等提出了基于最小扰动维度和人眼视觉特性的活体检测对抗样本生成算法，将扰动集中在少数几个具有较高权重的维度上，充分考虑了人的视觉特性，加入扰动点的间距约束，使得最后生成的对抗样本更不易被人类察觉，同时也可成功地欺骗网络，输出了想要的分类结果，最后与 DeepFool^[7]对抗攻击方法进行了对比测试。

Stepan Komkov^[17]等人在 2019 年提出了一种全新且易于复现的对抗样本生成方法：AdvHat，它不需要特定的环境，可以在多种不同的拍摄条件下生成对抗样本，并且成功攻击了开源的人脸识别系统。研究基于快速符号梯度算法 (FGSM)，通过设计好的损失函数来对输入进行梯度回传，然后把输入以一定的方式加上回传的输入梯度对应的梯度来实现梯度上升，从而达到使之前的损失函数上升，模型输出错误分类的目的。

刘雨佳^[18]研究了基于决策的对抗样本生成算法,提出了针对图像收缩放的对抗样本生成算法和基于对抗样本的图像内容保护算法。

王燕^[19]研究了影响基于深度神经网络的人脸验证的要素:数据、网络结构和损失函数,使用迁移学习在东方人人脸数据集上进行试验,成功验证了人脸。

徐珍琦^[20]在论文中基于深度学习模型提出了新的解决人脸对齐的方法,分为两个阶段:特征映射和高斯分布响应图,使用 KL 散度损失函数,并将网络中的最大池化层替换为卷积池化。

李旭嵘^[21]基于黑盒提出了基于云平台图像应用的对抗样本生成算法,然后针对对抗样本检测,提出了基于空间映射的对抗样本检测算法,然后基于多任务学习,提出了对深度人脸伪造的检测算法。

Kevin Eykholt^[22]等人在 2018 年的论文中提出了一种通用的攻击算法:RP2(Robust Physical Perturbations),算法在不同的物理环境中均能生成鲁棒的对抗样本。但是论文只在路标数据集上进行了实验,无法体现模型泛化能力。

1.2.3 语音对抗样本生成方法

近年来针对语音识别系统的攻击主要有两种方法,一种是基于一个使用高斯混合模型(GMM)的传统语音识别系统,利用了类似噪声的隐藏语音命令进行白盒对抗样本攻击。另一种攻击通过超声波传输听不见的命令,但它利用的是麦克风的硬件漏洞,而不是 DNN 的弱点。

Hiromu Yakura^[23]等人在论文中证明了对于给定的任意一段音频波形,可以生成相似度 99%的另外一个波形且能被转录为所选择的任何短语。主要策略是首先确定你影响最终结果的关键信息(原始音频的子集),通过修改输出音频中对应频段,使其包含语音命令。然后再将其逆变换,得到相应的音频输入即为对抗样本。

Yuan X^[24]等人在论文中提出了一种在歌曲 1 中加入语音命令,通过播放歌曲实施攻击的方法。成功攻击了目标 ASR(Automatic Speech Recognition,自动语音识别)系统,这样的歌曲经过互联网的传播,将会影响数百万的用户。

Alepis, Efthimios^[25]等人在研究中绕过了权限模型,安装被授予许可的恶意应用程序,播放伪造语音命令。

Nirupam Roy^[26]等人利用麦克风固有的非线性特征,利用超声波来控制语音助手,演示了在各种情况下的不可听见的攻击。

Rohan Taori^[27]等人采用一种黑盒攻击,并结合了遗传算法与梯度估计的方法创建有针对性的对抗音频来实现欺骗 ASR 系统。没有进行真实物理世界攻击实验。

张兆阳^[28]研究了黑盒环境下语音识别模型的普适性,提出了一种基于遗传算法和梯度估计的黑盒方法和针对语音识别系统的普适性对抗扰动生成方法。

胡亚军^[29]研究了基于深度学习的频谱表征方法和声学模型构建方法,提出了基于神经网络统计参数合成语音的方法,使用生成对抗网络进行声学模型构建。对于频谱的表征方法,提出了基于二值隐层深度自编码器的表征频谱的办法。提高了声音合成的质量。

于泓^[30]提出了一种基于神经网络加噪训练的合成语音检测的方法,具有强鲁棒性,在声音的特征提取方面,提出了一中基于深度神经网络的网络滤波器倒谱系数特征表示方法,能够更加有效地识别自然语言和合成语音。

1.3 主要内容

本文针对人工智能领域的生物特征识别系统,研究了人脸对抗样本和语音对抗样本生成算法,并且迁移到真实环境中进行对抗样本攻击,从而进行安全博弈,验证现有人脸识别系统、语音识别系统和声纹识别系统的安全性和鲁棒性。论文在常用人脸数据集和语音数据集上分别进行了对抗样本生成实验,并且使用商用的生物特征识别系统接口进行了验证。论文主要工作如下:

(1) 人工智能领域面临的对抗样本攻击。论文分析总结了生物智能识别系统如人脸识别、语音识别和声纹识别系统面临的对抗样本攻击的种类和方法。分析了其安全性和鲁棒性。

(2) 人脸对抗样本生成方法的研究。本文针对当前疫情情况下,人们在公共场所通常佩戴口罩的现象,提出了基于注意力机制的对抗性攻击算法。其次,论文还提出了基于集成学习的人脸对抗样本生成方法。本文提出了基于集成学习的人脸对抗样本生成方法,大大提高了生成速率和对抗样本质量。

(3) 语音对抗样本生成方法的研究。本文提出了基于 BERT 的词级韵律特征提取方法。不仅能够提取音频的声纹特征,而且能够表征词级特征,从而更好地生成语音对抗样本。另外针对语音识别和声纹识别系统,本文分别提出了基于内容和基于声纹的语音对抗样本生成算法。

(4) 本文在 LFW 数据集和 CASIA-Webface 人脸数据集上进行模型训练和测试,分别使用基于注意力机制的攻击方法和基于集成学习的攻击方法分别生成人脸对抗样本。并且使用商用的人脸识别系统接口进行人脸识别和活体检测实验,实现了黑盒对抗攻击。

(5) 本文在 MagicData 中文手机录音音频语料库和 ST-CMDS 中文数据集上进行了模型训练和测试。并且使用生成的对抗样本成功攻击了商用的语音识别系统和声纹识别系统,实现了黑盒对抗攻击。

1.4 组织结构

本文的论文组织结构如下：

第一章，绪论。本文的绪论部分论述了人工智能识别和对抗样本的研究背景以及研究意义。通过阅读大量的对抗样本生成相关文献，总结了国内外研究人员和学者在人脸对抗样本生成和语音对抗样本生成方面的研究现状及成果。其次介绍了论文的主要内容、主要工作以及论文的组织结构。

第二章，关键技术研究。首先介绍了单像素攻击算法和基于梯度的攻击方法。然后介绍了深度学习领域的深度神经网络、卷积神经网络以及残差神经网络的网络结构及作用。

第三章，人脸对抗样本生成方法研究。在该部分中，提出了基于注意力机制的对抗性攻击算法。算法通过视觉感知机制，搜索出容易被攻击的口罩图案区域，然后针对性地添加噪声，使得分类器分类错误，造成人脸识别失败。另外还提出了基于集成学习的人脸对抗样本生成方法，通过集成多个骨干网络和损失函数，快速生成高质量人脸对抗样本，大大提高了生成速率和对抗样本质量。

第四章，语音对抗样本生成方法研究。在该部分中，提出了基于 BERT 的词级韵律特征提取方法。不仅能够提取音频的声纹特征，而且能够表征词级特征，从而更好地生成语音对抗样本。另外针对语音识别和声纹识别系统，分别提出了基于内容和基于声纹的语音对抗样本生成算法，分别生成了能够欺骗语音识别系统和声纹识别系统的对抗音频并且不被人耳察觉。

第五章，实验过程及结果分析。在该部分中，使用 LFW 数据集和 CASIA-Webface 人脸数据集进行模型训练和测试，分别使用基于注意力机制的攻击方法和基于集成学习的攻击方法分别生成人脸对抗样本。并且使用商用的人脸识别系统接口进行人脸识别和活体检测实验，实现了对抗样本攻击。在 MagicData 中文手机录音音频语料库和 ST-CMDS 中文数据集上进行了模型训练和测试。并且使用生成的对抗样本成功攻击了商用的语音识别系统和声纹识别系统，实现了黑盒对抗攻击。

第六章，总结与展望。该部分对本文主要的研究工作和研究内容进行了总结，阐述了本文工作内容的创新及可能存在的不足之处，对人工智能领域生物识别系统的安全验证方法进行了展望，提出了可行的改进思路。

1.5 本章小结

本章的主要内容有：本论文的研究背景和研究目的、对抗样本攻击的研究现状、人脸对抗样本生成的方法、语音对抗样本生成领域的研究现状、本论文的主要内容、本论文的组织结构和小结。

第二章 相关理论及技术介绍

本章主要介绍对抗攻击相关算法、深度学习相关的网络结构以及要攻击的人脸识别系统、语音识别系统的结构和功能。其中对抗攻击算法主要介绍单像素攻击、基于梯度的攻击和生成对抗攻击算法。深度学习主要介绍深度神经网络、卷积神经网络和残差网络结构。生物识别系统主要介绍人脸识别系统和语音识别系统。

2.1 对抗攻击算法

2.1.1 单像素攻击算法



图 2-1 单像素攻击

单像素攻击是一种比较典型的黑盒攻击算法，是由 Narodytska^[5]等人在 2019 年提出的。单像素攻击的基本思想是：通过改动原始样本上的一个像素值，让模型产生错误的输出。将对抗样本生成问题转换为求解一个含有限制条件的优化问题。假设算法的输入为 n 维图像 $x = (x_1, \dots, x_n)$ ，图像每个像素是向量的一个分量，其中：

f 是分类器，

t 为类别，

$f_t(x)$ 是图像属于类别 t 的概率，

$e(x) = (e_1, \dots, e_n)$ 是对抗扰动向量。

公式如下：

$$\text{maximize}_{e(x)} f_{adv}(X + e(X)) \quad (2-1)$$

$$\text{subject to } \|e(X)\| \leq L \quad (2-2)$$

单像素扰动问题可以分解为两个部分：扰动的位置和扰动量大小。问题可以简化为：

$$\text{maximize}_{e(X)} f_{adv}(X + e(X)) \quad (2-3)$$

$$\text{subject to } \|e(X)\|_0 \leq d \quad (2-4)$$

算法的优化目为：

$$\min \text{loss}_{f,t}(\tilde{x}_i), \tilde{x} \in [0,1]^n, \text{s.t. } \|x - \tilde{x}\|_0 \leq d \quad (2-5)$$

其中 $d = 1$ 。利用单像素攻击算法可以成功欺骗梯度不易求解的神经网络模型。

2.1.2 基于梯度的攻击算法

在图像攻击算法中，FGSM 是一个非常经典的通过梯度生成攻击噪声的算法。训练分类模型时，网络基于输入图像学习特征，然后经过 softmax 层得到分类概率，接着损失函数基于分类概率和真实标签计算损失值，然后回传损失值并计算反向梯度传播，最后网络参数不断通过重新计算梯度，进行迭代更新，网络参数的更新开以使损失值越来越小，这样模型分类正确的概率也就越来越高。

图像对抗攻击的原理是通过修改输入图像，增加微小噪声，使得修改后的图像能够欺骗分类网络的结果，使其对于人眼看来相同的照片输出完全不同的分类结果。梯度计算的输入是损失函数、待攻击的原始样本和真实标签，如公式 2-6 所示。其中 $J()$ 是损失函数， x 和 y 表示输入图像和真实标签， θ 表示网络参数：

$$\nabla_x J(\theta, x, y) \quad (2-6)$$

$$\text{sign}(\nabla_x J(\theta, x, y)) \quad (2-7)$$

$\text{sign}()$ 函数用来计算梯度的方向，返回值为 -1, 0, 1。-1 代表小于 0 的输入，1 代表大于 0 的输入，0 代表等于 0 的输入。 $\text{sign}()$ 函数可以保证训练的方向与梯度方向一致。FGSM 算法的评价指标是對抗样本与原始样本的距离，距离越小代表生成的對抗样本质量越高，生成的對抗样本越视觉上越接近原始样本，不容易被察觉出来。

FGSM 算法原理简单，通俗易懂，操作起来比较容易，因此被广泛应用于各个领域的對抗样本生成算法中。迭代的 FGSM 和相当于 K-FGSM 的 PGD 攻击算法也是在 FGSM 攻击算法的基础上提出的。

传统的分类训练目的是降低目标的损失函数来增加预测的分数，无目标的攻击则期望该模型能将输入图像误分类为其他类别，使用激活函数可以对分类结果

产生最大的变化,当模型参数更新时,为了成功进行攻击,需要求解损失函数的最大值,即在修改损失函数时加上梯度值而非减去梯度值。FGSM 攻击的噪声如下式 2-8 所示:

$$\eta = \epsilon \text{sign}(\nabla_{\mathcal{J}} J(\theta, x, y)) \quad (2-8)$$

FGSM 生成对抗样本的公式如 2-9 所示:

$$X^{adv} = X + \epsilon \text{sign}(\nabla_{\mathcal{J}} J(X, y_{true})) \quad (2-9)$$

I-FGSM 公式:

$$X_0^{adv} = X, X_{N+1}^{adv} = \text{Clip}_{X, \epsilon} \{X_N^{adv} + \alpha \text{sign}(\nabla_{\mathcal{J}} J(X_N^{adv}, y_{true}))\} \quad (2-10)$$

和 FGSM 论文中的公式相比, I-FGSM 少了网络参数 θ ,因为在生成攻击图像的过程中并不会修改网络参数,因此 θ 就没必要加到公式中。可以通过不断迭代 FGSM 算法得到攻击图像,也就是 I-FGSM。这个公式中有几个参数和 FGSM 算法中的不一样,比如权重用 α 表示,论文中取 1,同时迭代次数用 N 表示,其实就是将总的噪声幅值分配到每一次迭代中,因此在给定噪声幅值 ϵ 的前提下,还可以直接用 $\alpha = \frac{\epsilon}{N}$ 来设置 α 和 N 参数。

PGD (Project Gradient Descent)攻击的公式如下:

$$x_{t+1} = \Pi_{x+S}(x_t + \alpha \cdot \text{sign}(\nabla_{\mathcal{J}} J(x_t, y))) \quad (2-11)$$

PGD 攻击是一种迭代攻击,可以看作是 K-FGSM (K 表示迭代的次数)。相较 FGSM 算法仅做一次迭代计算,PGD 算法则是多次迭代,每次走一小步,每次增加的扰动是在一定范围内的。

2.1.3 对抗生成网络


对抗生成网络通常由一个判别模型和一个生成模型组成,生成模型的目的是通过添加随机噪声,生成可被识别为目标标签的样本,判别模型的目的则有分类、语义分割、目标检测等。

生成对抗网络的目标函数如下所示:

$$\min_G \max_D = E_{x \sim p_r} [\log D(x)] + E_{z \sim p_z} [\log (1 - D(G(z)))] \quad (2-12)$$

上式的含义是使生成器 G 生成的图片和真实的图片几乎一样,即求生成器 G 的损失函数得最小值,而判别器需要判断生成的图片和真实图片的细微不同, $D(G(z))$ 最小,即求 $(1 - D(G(z)))$ 的最大值。

对抗生成网络的迭代过程如下图所示：



2.2 深度学习

本章介绍了神经网络的发展，CNN 卷积神经网络经常被用于处理图篇、识别物体，但也不局限于图像领域，例如自然语音处理领域和语音识别领域，CNN 也得到了广泛的应用并取得了很好的效果。RNN 循环神经网络和长短时记忆网络 (LSTM) 主要用于序列预测，能够解决神经网络中梯度消失和梯度爆炸的问题。残差神经网络则针对深度学习网络层数增加时模型准确率降低饱和的退化问题，训练出更加优秀的神经网络结构。



2.2.1 深度神经网络

人工神经网络学习的概念来源于人工神经网络的研究，可以与神经网络的展相比较，都是模拟人脑的自学习过程，逐步提取特征从低层到超深层的神经网络，可逐步学习更多的基本特征，使模型的分类效果更好，促进模型的进一步发展。

人工神经网络 (Aritificial Neural Network, ANN) 作为一个具有节点，节点间具有内部连接的计算网络，具有层数，每层具有神经元或者节点，每个节点的权重在迭代的过程中被不断调整以创建更好的分类器。调整权重的过程被称为学习或者训练。

2006 年 Hinton^[31] 将神经网络隐含层推到了第七层，利用预训练缓解了局部最优解的问题，并且使用 ReLU 等激活函数代替了 sigmoid 激活函数，克服了梯度消失的问题，形成了如今 DNN 网络的基本结构。Hinton 等人提出的深度神经网络能够学习到数据更深层次的特征，使得模型分类的效果更好。

深度神经网络以神经元为基本计算单位，它包含输入层、隐藏层、输出层等网络层次。输入层，即将模型所需的训练的数据进行导入。中间的层次为隐藏层，浅层神经网络也可以没有隐藏层。最后一层是输出层。神经网络隐藏层通过全连接，构建了输入输出层之间的桥梁，如下图所示：



2.2.2 卷积神经网络

图 2-4 卷积神经网络

卷积神经网络（Convolutional Neural Networks, CNN）最早由 Yann LeCun^[10]等人提出，是一种深层次化的、前向反馈的神经网络学习模型。解决了前馈神经网络由于并行的互连网络结构组成的每一层与邻接层全连接，在图像处理中，图像会被转换为向量处理，无法识别像素相应的位置信息的问题。

CNN 的前向传播就是图像的经过卷积、池化等一系列变换，提取出原始数据中携带着的高层次信息，随着 CNN 层数的增加，提取的信息层次就越高，特征也就越抽象。最终，预测值与真实值之间的差值通过损失函数来计算和评估。在卷积神经网络模型中，CNN 的每一个神经元的参数在反向传播的过程中，利用如 SGD 等梯度下降方法进行确定。因此，CNN 的每一层神经元在反向传播的过程中都学习到了图像中的特征，在满足画面不变性的前提下能够较好地对图像进行特征提取并对其进行分类。CNN 是神经网络领域的热门分支，CNN 的每一层的网络参数都是通过损失函数反应预测误差反向传播的方式确定直至模型收敛，因此，CNN 模型较其他神经网络方法能够更好地提取图像特征。

CNN 网络结构包含输入层、卷积层、池化层、全连接层和输出层。其核心的结构是卷积层，每个卷积层的后面都跟随着池化层和激活函数，根据需要选择是否进行批归一化。前馈神经网络与卷积神经网络主要的区别就是卷积层。

卷积层使用的离散卷积计算。卷积层由滤波器和图像映射组成。滤波器是具有输入权重并生成输出的神经元，也被叫做卷积核。卷积层中存在各种不同尺度的卷积核，卷积核会对输入的图像进行卷积操作进行特征的提取，从而获取图像的局部特征信息。例如二次抽样就是对每次特征映射的权重做平均池化操作。




图 2-5 二维矩阵的输入矩阵（3×3）和卷积核（2×2）

卷积操作步骤为：

输入体积： $W_1 \times H_1 \times D_1$

模型超参数为：滤波器 f 、步长 s 、零值填充 P

卷积后的体积大小为： $W_2 \times H_2 \times D_2$

其中：

$$W_2 = \frac{W_1 - f + 2P}{s} + 1 \tag{2-13}$$

$$H_2 = \frac{H_1 - f + 2P}{s} + 1 \tag{2-14}$$

$$D_2 = \text{滤波器数} = f \tag{2-15}$$




图 2-6 卷积层卷积操作示意图

通过卷积操作，原始输入矩阵的尺度由 3×3 降维为 2×2 的尺度。从图中可以看出，由于卷积核的值是固定不变的，因此，如果输入矩阵中存在着相同的局部特征，其卷积操作的输出也相同。

对于高维的卷积运算而言，输入矩阵在卷积核上的特征图通过卷积核对图像的卷积操作后得到，输出特征图的数量等于该层卷积核的数量。卷积核的输出可以形式化表示为下式：

$$Output_{x,y,n} = \sum_{i=0}^H \sum_{j=0}^W \sum_{c=0}^L Kernel_{i,j,c,n} \times Feature_{x+i} \tag{2-16}$$

其中，卷积层中卷积核的尺寸为 $L \times H \times W$ ，那么 (x,y) 是第 n 个卷积核进行卷积运算时，卷积窗口左上角的位置坐标，*Output* 是卷积层卷积操作后的输出，*Kernel* 代表卷积层中的滤波器，*Feature* 是特征图中的卷积窗口所选运算矩阵。

池化层可以降低卷积神经网络的特征维度。池化层一般分为平均池化层和最大池化层。由于池化层的操作较为简单，没有任何需要反向传播进行调优的参数，只有核大小、步长、类型等参数需要定义。池化层对输入的图像进行降采样和抽象化两项操作，通过这种方式，减少了正向传播中传递给下一层的图像特征大小，降低了后续步骤的计算量，减少了需要反向传播调整的参数，降低了过拟合的风险。同时，池化层保证了图像特征的不变性，池化操作的目的是为了提取区域的某种特征，即使区域中的特征产生微小的偏移，池化的最终结果也不会发生变化，较好地解决了前馈神经网络中存在的问题，也在一定程度上减少了模型训练中出现过拟合的可能性。池化层减小了前一层的激活映射，后面跟随一个或多个卷积层，同时整合了之前所有层的特征，可以泛化地表示神经网络特征。

与前馈神经网络的结构相同，全连接层通过与 Softmax 函数相连接，主要起到分类的作用。它通过矩阵的乘法来变换特征空间，并将之前层学到的特征映射到样本标记空间。加上激活函数的非线性映射，多层次的全连接理论上可以进行任何非线性的特征变换。全连接的另一个作用是将高维空间映射到低维空间，不仅保留了原始样本的有效信息，还大大减少了运算量。

Embedding 层是一个特殊的全连接层，它将原始的特征映射到了隐藏语义节点上，分类表达了特征向量。CNN 的全连接层通常采用 BP 算法进行训练。

卷积神经网络中 dropout 层用于解决过拟合，通过在每轮 batch 中随机删除某些节点的方法，使得网络结构处在不断变化之中，最后的模型是在多模型的基础上综合提炼得到的，dropout 层增强了模型的训练效果，还减少了神经元之间的全依赖。使用大规模前馈神经网络训练小规模的数据集时，通常会出现留存测试数据表现不佳的问题，因为神经元并不是独立存在的，该方法的引入降低了神经元间相的复杂连接，使神经元学习具有更好的鲁棒性。

ReLU 激活函数是卷积神经网络中最常用的激活函数之一，相比 sigmoid 更加稳定，不会出现梯度消失的问题。同时 ReLU 函数更为稀疏，能够更大程度发挥每个神经元的价值。并且 ReLU 运算速度快。因此目前大部分 CNN 的分类模型都采用 ReLU 激励函数加 Dropout 层的方式。

2.2.3 残差神经网络

神经网络的宽度与深度影响着神经网络的复杂度，虽然随着神经网络模型深度的增加，模型的精度得到了大幅提高，但是在网络深度较深时，传统卷积神经网络会在反向传播的过程中，会出现梯度消失和梯度爆炸的问题。He 等人提出了残差神经网络（Residual Network, ResNet）解决了当传统神经网络层次过多结构复杂时信息传递丢失的问题。作为计算机视觉问题的经典主干神经网络结构之一，ResNet 系列网络结构例如 resnet18、resnet50、resnet101 等被广泛应用在人脸识别、目标分类等相关领域的解决方法当中。Resnet 网络的提出证明了神经网络能够向更深（包含更多隐藏层）的方向发展。

He^[35]等人在残差神经网络中引入了残差学习模块（Residual Block），假定神经网络的输入为 x ，神经网络的期望输出为 $H(x)$ ，那么残差学习模块的学习目标由 $H(x)$ 转化为模块的输入和输出之差： $H(x) - x$ ，残差目标的学习拟合目标即为 $H(x) = F(x) + x$ 。如果 $F(x)$ 为 0，那么拟合目标即为前文中的恒等变换。残差的出现网络的学习过程不用再去拟合复杂的映射，神经网络的拟合难度大大降低。残差网络的残差模块单元结构较为简单，残差学习模块通过将输入与模块输出的叠加，利用激活函数进行映射，形成一个完整的残差学习模块，如图 2-7 所示。残差学习模块只是进行简单的叠加，不会给网络带来额外的计算量。




图 2-7 残差神经网络残差模块示意图

ResNet 的残差模块主要有：层数为 2 的基础残差模块和层数为 3 的瓶颈残差模块。基础残差模块由 2 个大小为 3×3 的卷积层组成，而瓶颈残差模块则由 1 个大小为 1×1 的卷积核、1 个大小为 3×3 的卷积核和一个大小为 1×1 的卷积核共同组成。瓶颈残差模块中大小为 1×1 的卷积主要起到升维和降维的作用，使得 3×3 的卷积可以在低维的特征上进行卷积操作，对于深层网络的复杂网络结构，瓶颈残差模块的引入使得计算量大大减少。




图 2-8 基础残差模块和瓶颈残差模块示意图

现阶段的残差神经网络层数主要有 18、34、50、101、152 等 5 种，不同深度的神经网络结构不同。浅层的 resnet18、resnet34 都是由基础残差模块搭建而成。深层的 resnet50、resnet101、resnet152 乃至更加深层的网络结构是由瓶颈残差模块搭建而成。残差网络结构的出现使得更深层次的网络应用越来越广泛。



2.3 生物识别系统原理

2.3.1 人脸识别系统

人脸识别的一般流程如下图所示：




图 2-10 人脸识别流程图

常用的人脸图像预处理方法有 ASM (Active Shape Model)、AAM (Active Appearance Model)、CLM (Constrained Local Model) 和 LBP (Local Binary Pattern) 等。

ASM 是指主观外形模型, 是以外在形状特征为主要依据对目标物进行抽象的结果。基于主观外形模型的人脸对齐方法通过预先设定的 68 个关键点特征位置表示人脸特征。AAM 被称为主动外观模型, 是在 ASM 的基础上提出的, 模型进一步对纹理进行统计建模, 并将形状和纹理两个统计模型进一步融合为外观模型。AAM 模型在对形状和纹理特征统一量纲后, 建模和搜索过程和 ASM 基本相同。CLM 是有约束的局部模型, 检测人脸特征的方式是首先初始化平均脸的位置, 然后让平均脸上的特征点在其邻域空间进行搜索, 寻找匹配的人脸特征点。ASM 也属于 CLM 的一种。CLM 同时拥有 ASM 模型和 AAM 模型的优点, 相较于 ASM 模型提高了特征检测的能力。LBP 是局部二值模式, 一种处理局部图像纹理特征的程序算法。具有旋转不变及灰度不变的优点, 经常被用于提取图像局部纹理特征。LBP 算法定义是: 在 3×3 的窗口内, 以中心像素为基准, 与中心像素相邻的左上、上、右上、左、右、左下、下、右下 8 个像素的灰度值进行比较, 若周围像素值大于中心基准像素值, 则该像素点的位置被标记为 1, 反之标记 0。经过 LBP 算法处理的图像 3×3 范围内的 8 个像素点输出一个二进制数, 然后转换为十进制 LBP 码, 共有 256 种, 即为该窗口中心像素点的 LBP 值, 这个值能够反映该图像中心像素附近局部区域的纹理信息。

基于深度学习的人脸识别系统常用的算法有基于度量的方法和基于边界分类的方法。基于度量的方法使用欧氏距离、余弦相似度等来衡量特征向量之间的相似度。而基于边界的方法则把人脸识别当作分类任务进行训练。

基于度量的方法的典型代表有 DeepID2 网络和 FaceNet 网络。DeepID2 网络的输入是两张图片, 训练时同时训练验证和分类两个网络, 验证过程中使用了比对损失, 即模型认为两张图片为同一个人输出 1, 不同的人输出 -1, 将训练一个人脸分类器转化为训练一个人脸特征度量的分类器, 实现了一次训练。而 FaceNet 使用的损失函数是 Triplet Loss, 输入为三张图片, 分别为原始样本, 正样本和负样本, 原始样本和正样本为同一人, 负样本则是不同的人, Triplet Loss 的目的是使得相同人脸的距离在特征空间更近, 不同人脸距离更远。

基于边界分类方法的网络有 SphereFace, 它使用的损失函数为 A-Softmax Loss, 它考虑了不同类别的特征在空间中的分布具有角度性质而增加了余弦函数。

基于决策边界的方法比基于度量的方法更容易实现, 模型训练速度也更快。而 DeepID2、FaceNet 和 SphereFace 在大规模人脸数据集上也都取得了不错的效果。

2.3.2 语音识别系统

广义的语音识别系统包含了语音识别系统和声纹识别系统。语音识别和声纹识别的一般过程为：




图 2-11 语音识别系统流程图（左） 声纹识别流程图（右）

语音特征主要有谱包络参数、基音轮廓、共振峰频率、线性预测系数以及听觉特性等。

语音识别的解码比对和声纹识别的模型比对都需要模式匹配，模式匹配的一般方法有：概率统计、动态时间调整、矢量量化、隐马尔可夫模型、人工神经网络等。

声谱图是频谱的光学或电子学表示，是由篡改扣划的数据片段的 FFT 构成的一个序列。常见格式包含两个维度：时间轴和频率轴。还可以引入第三维，用不同颜色或者点的大小来表示在特定时刻某个频率的信号分量的幅值大小。声谱图的构建有两种方式：一种是由一系列的低通滤波器表示的滤波器组，另一种是使用 python 直接用函数将音频映射为声谱图。生成声谱图后的图像可以使用深度学习模型进行训练。

语音信号表征特性有时域、频域和语谱图。时域是用数学函数描述信号的物理量相对于时间的关系。频域用来描述声音每秒钟完成周期变化的次数。语谱图的横轴为时间，纵轴为频率，能量用点的灰度表示。时域分析不能直观看出频率特性；频域分析也看不出信号随时间的变化；一帧（一般为 1024 个采样点）信号，可认为频谱不变，是短时谱，只反应静态的频率特性。

傅立叶变换：音频信号由几个单频声波组成。在一段时间内对信号进行采样时，我们仅捕获得到的幅度。傅立叶变换是一个数学公式，它使我们可以将信号分解为单个频率和频率幅度，即它将信号从时域转换到频域，结果称为频谱，因为每个信号都可以分解为一组正弦波和余弦波，它们加起来等于原始信号。这就是著名的傅立叶定理。

快速傅立叶变换（FFT）是一种可以有效计算傅立叶变换的算法。它广泛用于信号处理。快速傅立叶变换是一种功能强大的工具，可以让我们分析信号的频率成分。大多数音频信号（例如音乐和语音）是非周期性信号，因此需要一种表示这些信号随时间变化的频谱的方法——短时傅立叶变换。

2.4 本章小结

本章主要介绍了本论文课题的基础技术。行文首先介绍了黑盒攻击算法，包括单像素攻击算法、基于梯度的攻击算法和生成对抗网络的结构和损失函数。其次介绍了深度学习的发展，包括深度神经网络、卷积神经网络、残差神经网络的结构和作用。最后介绍了人脸识别系统、语音识别系统、声纹识别系统的结构和一般流程，为后文针对人工智能的对抗样本的生成提供了技术基础。

第三章 人脸对抗样本生成算法研究

本章研究了人脸对抗样本生成算法。当前疫情情况下，公共场合戴口罩成为普遍的现象，相对不戴口罩的人脸识别，口罩图案上更容易叠加各种扰动，从而欺骗人脸识别系统。本章 3.1 节提出了基于注意力机制的人脸对抗样本生成算法，算法使用了 GAN 生成模型，基于注意力机制生成对抗性口罩贴片叠加到人脸图片上，从而很容易使得分类器误分类，使得生成的人脸对抗样本成功攻击人脸识别系统。


本章 3.2 节提出了不添加贴片的基于集成学习的人脸对抗样本生成算法，算法集成了 IR_50、IR_101 和 IR152 等骨干网络进行训练，采用 cos loss、L2 loss 和 TV loss 三个损失函数，既保证了生成图像的平滑度，又能减少对抗样本的扰动量，使得生成的图像更为逼真。基于集成学习的方法通过在人脸图片上添加微小的扰动，不添加贴片，就能欺骗分类器。

3.1 基于注意力机制的攻击方法

3.1.1 视觉感知机制研究

研究表明，视觉敏感度在完成稳健的视觉识别中起着非常重要的作用。因此，要完成高质量的攻击，对抗样本在视觉上应该是自然流畅的，并且与图像的上下文有很强的感知相关性，同时在空间上定位出被攻击图像的感知敏感位置。近年来大多数对抗攻击在攻击成功率上取得了较好成绩，但是往往忽视了感知敏感性，无法生成背景和谐但具有攻击性的贴片，从而导致攻击效果不稳定。

本文提出了一种新的攻击框架，即感知敏感 GAN 来生成对抗贴片。与现有的研究不同，本文提出的感知敏感 GAN 利用了被攻击网络的对抗样本感知敏感性，提高了生成的对抗样本的视觉逼真度。感知敏感 GAN 可以生成指定的任何类型的贴片，并采用贴片到贴片的翻译过程来追求视觉上自然的和上下文相关的贴片。而且为了进一步提高攻击能力，感知敏感 GAN 引入视觉注意机制来捕捉空间分布的敏感度并指导补片的攻击定位，使攻击效果稳定。



视觉敏感 GAN 的框架由生成器 G、鉴别器 D 和一个注意力模型 A 组成，攻击一个目标模型 F。实验结果表明，我们的视觉敏感 GAN 算法不仅能始终优于现有的对抗性贴片攻击方法，而且具有很强的泛化能力和传输能力。

问题定义： $\mathcal{X} \subseteq \mathcal{R}^n$ 是n维特征的特征空间。假设 (x_i, y_i) 是数据中的第i个实例，特征向量 $x_i \in \mathcal{X}, y_i \in \mathcal{Y}$ 是对应的类别标签。深度学习模型要学习的目标分类函数为 $F: \mathcal{X} \rightarrow \mathcal{Y}$ 。具体地说，本文考虑了视觉识别问题，利用对抗性图片 δ 来误导目标模型F使其错误预测。

给定一个具有原始类标签 y_{real} 的原始干净图像 x ，具有可攻击性的新图像 x^* 由原始图像 x 、一个附加的口罩贴片 $\delta \in \mathcal{R}^2$ 和一个位置编码 $m \in \{0, 1\}^n$ 组成，公式如下所示：

$$x^* = (1 - m) \odot x + m \odot \delta \tag{3-1}$$

其中 $\odot$ 为元素乘法，上式也可以简化为：

$$x^* = x + m\delta \tag{3-2}$$

x^* 经过F的映射的预测结果 y_{pre} 的表达式为：

$$y_{pre} = F(x^*) \tag{3-3}$$

对抗图片可以让模型预测出错误的分类标签。深层卷积神经网络通常对输入图像中物体的视觉逼真度和空间定位具有很强的感知敏感性。本文基于对抗生成网络提出了一个视觉敏感的 GAN 框架，可以生成与上下文自然相关的多功能贴片，并在视觉上注意输入图像的定位。

为了提高视觉逼真度，引入了逐步翻译过程以允许指定贴片的样式。在该过程中，指定的贴片和被攻击的图像都作为输入，输出的是一个在视觉上与输入贴片相似，同时又与被攻击图像协调的贴片。本论文在对抗性学习的过程中，生成器 G 被激励去创建与待处理图像具有高度感知相关性的对抗性贴片被攻击。即，对于输入的贴片 δ 和被攻击的图像，可以生成一个敌对贴片 $G(\delta)$ 。鉴别器 D 保证了视觉上的相似性。 D 激励了对抗样本表现出与被攻击图像有较高的视觉逼真度和感知能力相关性，看起来更加协调一致。

为了获得对抗性攻击能力，本论文在框架中引入了目标模型 F 。 F 作为攻击的目标模型，负责使贴片具有对抗攻击的能力，生成的贴片必须能够导致 F 错误分类。

对于空间定位敏感性的建模，在我们的框架中，注意力模型 M 被集成到端到端的贴片生成过程中。它可以捕捉到被攻击网络中关于贴片定位的注意力分布，从而帮助确定关键区域 $M(x)$ 来放置攻击能力强的贴片。在预测区域内， G 算法可以生成低失真率、高攻击成功率的对抗性贴片。同时具备对抗生成过程和注意力机制的感知敏感 GAN 可以生成更真实、更具攻击性的贴片。模型在样本图片的位置 $M(x)$ 处加贴片，形成对抗样本，公式如下：

$$x^* = x + M(x)G(\delta) \quad (3-4)$$

在感知敏感 GAN 框架中，有两个相对应的部分充分利用了感知敏感性：一是贴片到贴片的对抗生成，有助于产生具有视觉逼真度和感知相关性的理想对抗性贴片，二是视觉注意力模型，它可以预测对抗攻击的关键区域。这两个部分耦合在一起，保证了模型的攻击能力。为了使得该模型生成具有良好视觉逼真度的对抗性贴片，对抗性损失可以写为：

$$L_{GAN}(G, D) = E_x[\log D(\delta, x)] + E_{x,z}[\log(1 - D(\delta, x + M(x)G(z, \delta)))] \quad (3-5)$$

其中 x 、 δ 和 z 分别是要攻击的图像、输入贴片和噪声。

然后进一步附加贴片损失以捕获和增强生成的贴片与输入图像的上下文的高感知相关性。同时，损失也限制了贴片的失真。直观地说，我们期望生成的贴片与被攻击的图像具有相似的视觉感知，这意味着它们具有共同的相关感知意义，这种情况下生成的贴片通常应该在视觉上与图像上下文在像素和感知两个层面上相协调。因此，我们引入以下损失来指导贴片生成的对抗性网络学习过程：

$$L_{TP}(\delta) = E_{\delta} \|G(\delta) - \delta\|_2 \quad (3-6)$$

3.1.2 注意力机制研究

由于我们的目标是生成具有强大攻击能力的对抗贴片，因此需要引入一个对抗攻击损失。这种损失迫使生成器 G 产生贴片，注意力模型 M 可以预测贴片的位置，这两者一起会进一步欺骗目标模型。

一方面，我们要使对抗样本的预测标签尽量远离其原始预测标签，对于一个附加了对抗贴片 $G(\delta)$ 的干净输入，损失定义如下：

$$L_{adv}(G, F) = E_{x, \delta} [\log P_F(x^*)] \quad (3-7)$$

另一方面，攻击性能高度依赖于被攻击网络的视觉注意力的敏感性，即图像的哪个部分对模型决策的贡献更大，放置在这些区域的对抗性贴片对模型性能的影响更大。在视觉敏感性框架中，借用视觉注意力机制来预测关键攻击区域。具体地说，是为了获得类的判别局部化映射，梯度加权类激活映射（Grad-CAM）有助于计算 y^c （分类 c 的得分）相对于卷积层的特征映射 A 的梯度，例如： $\frac{\partial y^c}{\partial A_{ij}^k}$ 。这些梯度在被全局平均化后回流以获得重要性权重 α_k^c ，这个权值捕捉了特征图 k 对于目标类 c 的重要性，形成了放置对抗性贴片的注意力掩码位置。

最后，对抗性攻击损失与上述视觉保真度和感知相关损失相结合，形成最终的贴片生成公式为：

$$\min_G \max_D L_{GAN} + \lambda L_{TP} + \gamma L_{adv} \quad (3-8)$$

其和用来平衡各部分的贡献。在注意模型的指导下，通过对上述问题的优化，视觉敏感性 GAN 模型找到了一个能产生对被攻击网络具有较强的攻击能力和感知敏感性的近似最优生成器。

3.1.3 网络结构

生成器和判别器使用 DCGAN 的框架，用于图像翻译和感知信息捕获。在生成器中使用 U-Net 架构，允许低层信息在网络中抄近道，导致更好的结果。用表表示有着 k 个卷积核的 LeakyReLU 卷积层。所有的卷积操作都是采用步长为 2 的 4×4 空间滤波器。编码器-解码器体系结构包括：

编码器：C16-C32-C64-C128

解码器：C64-C32-C16-C3

判别器的结构为：C64-C128-C256-C512。判别器网络的最后一层送到线性层产生一维输出，后接 Sigmoid 激活函数。

目标模型 F 可以是任何给定的深度神经网络，最后两层都可以访问。这两层是损失函数 L_{adv} 的一部分。为了进行对抗攻击，损失函数 L_{adv} 激励生成地对抗样本 x^* 被目标模型 F 错误地分类。

在视觉注意力模型中，首先计算最后一个完全连接层相对于第四卷积层的输出特征映射的梯度。然后为了获得类判别映射，计算特征图的第四卷积层的特征图梯度。最后，利用这些梯度计算每个特征映射的权重。返回值是全局平均地权重 α_k^c ，计算公式如下：

$$\alpha_k^c = \frac{1}{u \times v} \sum_{i=1}^u \sum_{j=1}^v \frac{\partial y^c}{\partial A_{ij}^k} \quad (3-9)$$

之后由这些特征图获取并计算输入图像的注意力图。具体而言，权重 α_k^c 表示从 A 下层的深度神经网络的部分线性化，并捕获目标 c 类特征映射图 k 的重要性。注意力映射是特征映射的加权组合，后面是 ReLU 激活函数：

$$L_{Grad-CAM}^c = ReLU(\sum_k \alpha_k^c A^k) \quad (3-10)$$

因此，输出注意力图可以突出与感兴趣的任何决策相对应的图像的重要区域。因此，提供了关键区域，这些区域的修改对最终预测更敏感，从而实现强攻击能力。它主要是一个反复迭代的 G 和 D 训练过程，每次迭代中，对 D 训练 k 次，对 G 训练一次，每个小批次的每个图像的注意力图由 Grad CAM 获取，引导区域进行口罩贴片的放置。基于标准梯度的优化方法可用于学习 W_D 和 W_G 。在实验中分别使用 Adam 优化器和 SGD 优化器作为 G 和 D 。

3.1.4 算法实现

-
- 1、输入：训练集 $\mathcal{X}_{image} = \{x_i | i = 1, \dots, m\}$
 贴片集 $\delta_i = \{x_i | i = 1, \dots, m\}$
 - 2、输出：非线性参数集合 $\mathcal{W}_D$ 和 $\mathcal{W}_G$
 - 3、for: number of training epochs do
 - 4、 for: k steps do
 - 5、 m 个人脸样本 $\psi_x = \{x_1, \dots, x_m\}$
 - 6、 m 个贴片样本 $\psi_\delta = \{\delta_1, \dots, \delta_m\}$
 - 7、 m 个对抗样本贴片 $\psi_\delta^G = \{G(\delta_1), \dots, G(\delta_m)\}$
 - 8、 通过 GradCAM 的方法获取注意力映射 $M(\psi_x)$
 - 9、 构建 m^2 个对抗样本 $\psi_{x^*} = \{x_i + M(x_i)\delta_j | i, j = 1, \dots, m\}$
 - 10、 固定生成器 G ，通过 $\max_D L_{GAN}$ 优化判别器集合 $\mathcal{W}_D$
 - 11、 end for
 - 12、m 个人脸样本 $\psi_x = \{x_1, \dots, x_m\}$
 - 13、m 个贴片样本 $\psi_\delta = \{\delta_1, \dots, \delta_m\}$
 - 14、通过 GradCAM 的方法获取注意力映射 $M(\psi_x)$
 - 15、固定 D 通过 $\min_G L_{GAN} + \lambda L_{贴片} + \gamma L_{adv}$ 优化判别器集合 $\mathcal{W}_G$
 - 16、end for
-

3.2 基于集成学习的人脸对抗样本生成算法

3.2.1 数据预处理

由于人脸数据集里的图片有人脸图片、半身图片和全身图片等，但是进行人脸识别任务时，需要首先检测人脸的位置，因此需要对人脸数据集进行预处理操作，使其对齐到相同大小。图片的预处理包括人脸对齐和裁剪，人脸对齐通常通过定位人面部的关键特征点如：眼睛、鼻子、嘴巴、眉毛等部位，从而定位出人脸轮廓的大致位置。

本文使用 MTCNN (Multi-task Cascaded Convolutional Networks) 进行人脸图片的预处理。它利用了检测和对齐之间的内在联系来提高整体网络的性能。

MTCNN 主体框架属于级联结构,通过三个阶段的深度卷积网络,由粗到细地预测了人脸的位置和面部特征点的位置。

MTCNN 首先把初始图像按不同比例进行缩放,调整后的图片共同组构成一个图像金字塔,然后将不同比例的关联图像输入三个子网络: P-Net、R-Net 和 O-Net 中训练,目的是检测到不同尺寸图像中不同大小的人脸,实现多尺度的目标检测。

(1) P-Net (Proposal Network)

P-Net 的主要功能是定位人脸区域候选框、边界框的回归向量。之后再基于边界框回归运算后的向量预测结果对候选框进行矫正。然后,采用非极大值抑制算法来合并重复率高的候选框。

(2) R-Net (Refine Network)

P-Net 的所有候选框都输入到 R-Net 中, R-Net 网络结构也是通过边界框回归和 NMS 来去掉大量的不匹配区域。由于 R-Net 网络结构和 P-Net 网络结构相比增加了一个全连接层,所以会取得更好的抑制不匹配区域的作用。在输入 R-Net 之前,都需要缩放到 $24 \times 24 \times 3$, R-Net 输出与 P-Net 是相同的, R-Net 的目的是为了去除大量的非人脸框。

(3) O-Net (Output Network)

这个阶段类似于第二阶段,在此阶段,通过更多的手段来识别面部区域。特别是, O-Net 网络输出五个面部关键点的位置。该层比 R-Net 层又增加了一层卷积层,所以输出的结果更精确。输入的图像大小 $48 \times 48 \times 3$, 输出包括 N 个边界框的坐标信息, score 以及人脸关键特征点位置。

根据上述分析,从 P-Net 到 R-Net,到最终的 O-Net,网络输入的图像越来越大,卷积层的通道数越来越多,网络的深度(层数)也越来越深,在输入的图像中识别人脸图像的准确率也是越来越高。

MTCNN 主要有三个部分:非人脸-人脸二分类器、边界框回归和人脸图像特征点。这三个部分分别使用了不同的损失函数。

下面分别介绍这 3 个部分的损失函数。首先使用二分类器检测图像,面部分类模型损失函数如下:

$$L_i^{det} = - \left(y_i^{det} \log(p_i) + (1 - y_i^{det})(1 - \log(p_i)) \right) \quad (3-11)$$

其中, p_i 为面部图像出现的概率, y_i^{det} 为该区域真实标签。除了判断该区域是否存在人脸之外,模型识别出的人脸区域要尽可能准确,这是个基本要求, MTCNN 通常采用边界框回归(bounding box regression)来实现这个要求。

边界框回归一般采用欧氏距离,距离测量的损失函数如下式:

$$L_i^{box} = \|\hat{y}_i^{box} - y_i^{box}\|_2^2 \tag{3-12}$$

式中， y 是实际边框坐标， $\hat{y}$ 是通过网络预测得到的边框坐标，下式是表示矩形区域的四元组：

$$(X_{left}, Y_{left}, Width, Height) \tag{3-13}$$

面部图像关键特征点定位也是个回归问题（与边界回归过程类似），面部图像关键特征点定位使用的损失函数是计算实际关键点位置与预测的关键点位置之间的偏差，距离的测量使用欧氏距离。

面部图像关键特征点定位过程中的损失函数如下：

$$L_i^{landmark} = \|\hat{y}_i^{landmark} - y_i^{landmark}\|_2^2 \tag{3-14}$$

其中， $y_i^{landmark}$ 为实际关键点位置， $\hat{y}_i^{landmark}$ 为面部特征关键点预测位置。面部特征关键点是 5 个，因此需要预测 5 个面部特征关键点，每个点 2 个坐标值，所以 y 是 10 元组。

最终 MTCNN 要优化的损失为：

$$\min \sum_{i=1}^N \sum_{j \in \{det, box, landmark\}} \alpha_j \beta_i^j L_i^j \tag{3-15}$$

式中， N 是训练样本的数量， α_j 是任务的重要性， β_i^j 是样本标签， L_i^j 是上述损失函数。

经过上述 MTCNN 处理后的图像作为输入图片进入下述算法，它们叠加过噪声之后被送入集成网络模型中去训练学习。具体的算法实现流程如下所示。




图 3-2 基于集成学习的对抗样本生成方法

本算法结合集成学习的思想，集成了如图所示 IR50、IR101、IR152 等几个不同的骨干网络结构，IR50、IR101、IR152 是使用处理好的 Ifw 人脸数据集预先训练好的不同深度的模型，生成目标人脸人脸对抗样本时直接调用骨干网络模型即可。

算法的输入为原始样本、原始噪声和目标样本，目标样本即我们想要让他变成的另外一个人。算法的输出为原始样本与目标样本之间的相似度。最终目标是不断迭代增加输入图片的特征向量 embedding vector1 到目标特征向量 embedding vector2 之间的距离，即图片相似度，直至达到设定值，本文实验设置当输出的分数向量高于 0.25 后停止训练。算法设置了 cos loss、L2 Loss 和 TV loss，选择距离增大的方向不断更新噪声，添加到原始样本上，由于要保证扰动后人脸的视觉效果，单个像素的扰动需要在 $[-25.5, 25.5]$ 之间。这样生成的对抗样本在肉眼看来与原样本极为相似。原始噪声经过高斯卷积，叠加到待攻击的原始样本上，放入不同深度的骨干网络中进行训练，利用集成学习思想，逐步找到强分类器。

3.2.2 基于 Adaboost 的集成学习

对于不同的攻击场景，黑盒攻击的替代模型的建立方式可以不同，常规做法是集成一定量的模型作为基础模型，并在这个模型上开发攻击算法。可以通过固定微小扰动来比较不同模型的攻击成功率。比如，遍历事先设置的扰动阈值梯度，较好的“替代模型”在同一阈值下会表现出更好的攻击成功率。

Boosting 的一般通常采用两种实现方法：AdaBoost 和 RealBoost。Adaboost 使用相对较为方便，而 RealBoost 的输出结果相对较为精确。AdaBoost 算法应用比较容易实现，因此被经常用作训练强分类器解决实际问题，并且能够得到较好的效果。

AdaBoost 算法使用具有不同权重的训练集通过弱分类算法产生分类结果，即基分类器，然后分别计算基分类器的错误率，根据错误率重新更新权值向量分布。在对抗样本生成的实验中，我们给错误分类的样本分类器分配更大的权值，正确分类的样本分类器则分配较小的权值。这些分类假设的序列构成多分类器。将这些多分类器用加权的方法联合起来，最终输出预期的决策结果。

因为实际操作时，训练获多个识别率较低的弱分类器比获得一个识别率很高的强分类器要更加容易，因此 AdaBoost 算法的任务就是集成容易训练的识别率较低的弱分类为识别率较高的强分类器。在整个处理过程中，通过训练学习，只要找到一个优于随机猜测的弱分类器，就可以将其加入弱分类器的集合，训练过程较寻找强分类器更加快速高效。

假设训练样本集为：

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\} \quad (3-16)$$

训练集在第 k 个学习器的输出权重为:

$$D(k) = (w_{k1}, w_{k2}, \dots, w_{km}) \quad (3-17)$$

$$w_{1,i} = \frac{1}{m}, i = 1, 2, \dots, m \quad (3-18)$$

在二元分类问题上, 由于输出为 $\{-1, 1\}$, 则第 k 个弱分类器 $G_k(x)$ 在训练集上的加权误差率为:

$$e_k = P(G_k(x_i) \neq y_i) = \sum_{i=1}^m w_{ki} I(G_k(x_i) \neq y_i) \quad (3-19)$$

对于二元分类问题, 第 k 个弱分类器 $G_k(x)$ 的权重系数为:

$$a_k = \frac{1}{2} \log \frac{1-e_k}{e_k} \quad (3-20)$$

由上式可以看出如果分类误差率 e_k 越大, 则对应的分类器权重系数越小, 即误差率小的弱分类器权重系数大。

更新样本权重 D , 第 k 个弱分类器的样本权重为:

$$D(k) = (w_{k1}, w_{k2}, \dots, w_{km}) \quad (3-21)$$

则对应的第 $k+1$ 个弱分类器的样本权重系数为:

$$w_{k+1,j} = \frac{w_{kj}}{Z_k} \exp(-\alpha_k y_i G_k(x_i)) \quad (3-22)$$

这里 Z_k 为规范化因子。

$$Z_k = \sum_{i=1}^m w_{ki} \exp(-\alpha_k y_i G_k(x_i)) \quad (3-23)$$

从上式可以看出, 如果第 i 个样本分类错误, 那么就会导致 $y_i G_k(x_i) < 0$, 则样本的权重在第 $k+1$ 个弱分类器中降低。

在生成人脸对抗样本的时候, 损失函数用来衡量生成样本和原始样本之间的距离, 为了最大化类间方差和最小化类内方差, 常用的损失函数为 softmax loss。尝试使用不同的损失函数, 验证最终结果。

3.2.3 损失函数

损失函数分为三部分, 分别是: L2 loss、cos loss 和 TV loss。

(1) L2 loss

L2 范数损失函数, 也被称为最小平方误差 (LMSE)。它是把目标值 Y_i 与估计值 $f(x_i)$ 的差值的平方和最小化。公式如下:

$$L_2 = |f(x) - Y|^2 \quad (3-24)$$

对于多数的 CNN 网络，一般经常使用 L2 损失而不是 L1 损失，因为 L2 损失函数收敛速度比 L1 损失函数要快许多。对于边框预测回归问题，一般也可选择平方损失函数（L2 损失函数），但 L2 损失函数存在一个缺点，当存在离群点（outliers）时，这些点会构成 loss 的主要组成部分。比如说真实值为 1，预测 10 次，有一次预测值为 1000，其余次的预测值为 1 左右，则 loss 值主要受 1000 影响。所以 FastRCNN 采用较为缓和的绝对损失函数（smooth L1 损失），它是随误差线性增长，而不是平方增长。

(2) cos loss

人脸识别方法是基于误差的分类。在 large margin softmax 和 spherface 的 angular softmax 中，margin 是以一种 $\cos(m \times \theta)$ 的方式出现，带来的问题是反向传播计算比较复杂，损失函数优化不是很容易，对于训练不是很友好。而 cosface 的出现则是弥补了这个缺陷。它对 cosine loss 的结果设置阈值，即 $\cos(\theta - m)$ ，这样优化起来比较简单。

(3) TV loss

在降噪过程中，图像上的显著噪声可能对结果产生非常大的影响，此时可以在最优化问题的模型中添加一些正则项来提高图像的平滑性，TV loss 是常用的一种正则项。

Rudin 等人观察到，存在显著噪声干扰的图像的总变分比无噪图像的总变分明显的大，最小化 TV 理论上可以最小化噪声。图片中相邻像素值的差异可以通过降低 TV loss 来一定程度上解决，例如降噪。

定义为梯度幅值的积分：

其中， D_u 是图像的支持域。限制总变分就会限制噪声。

$$J_{T_0}(u) = \int_{\Omega_u} |\nabla u| dx dy = \int_{D_u} \sqrt{u_x^2 + u_y^2} dx dy \quad (3-25)$$

带阶数的 TV loss 定义如下：

$$\mathfrak{R}_V \beta(x) = \sum_{i,j} \left((x_{i,j-1} - x_{i,j})^2 + (x_{i+1,j} - x_{i,j})^2 \right)^{\frac{\beta}{2}} \quad (3-26)$$

在图像中，连续域的积分就变成了像素离散域中求和，所以 TV loss 计算公式如下：

$$tvloss = \sum_{i,j} \left((x_{i,j-1} - x_{i,j})^2 + (x_{i+1,j} - x_{i,j})^2 \right)^{\beta/2} \quad (3-27)$$

3.3 本章小结

本章介绍了人脸对抗样本生成方法的研究，主要分为两个部分。第一部分首先介绍了基于注意力机制的攻击方法，并从视觉感知机制、注意力机制和网络结

构三个方面进行了阐述，然后介绍了其算法实现步骤。第二部分介绍了基于集成学习的人脸对抗样本生成算法，主要内容有人脸图片预处理的方法和过程，接着阐述了集成学习的思想以及基于集成学习的人脸对抗样本生成方法，最后介绍了模型的三个损失函数：L2 loss、cos loss 和 TV loss。

第四章 语音对抗样本生成方法研究

本章针对人工智能场景中的语音识别和声纹识别系统，研究了基于内容和声纹的语音对抗样本生成方法，分别对语音识别系统和声纹识别系统进行对抗攻击。并且在 MFCC 特征提取的基础上，提出了基于 BERT 的韵律特征提取算法，相较于传统的 MFCC 特征，能够使得生成的语音具有更好的词级韵律。这种方法对于输入音频的要求较低，方法更加具有普适性。

4.1 基于 BERT 的韵律特征提取

为了准确识别声音音素，我们使用 MFCC 来精准表达声道形状形成的短时功率谱包络。在语音识别和话者识别方面，梅尔倒谱系数（Mel-scale Frequency Cepstral Coefficients，简称 MFCC），经常被用来表征语音特征。MFCC 提取过程包括预处理、快速傅里叶变换、Mel 滤波器组、对数运算、离散余弦变换、动态特征提取等步骤。

一般而言，不同人说相同的一段语音内容时时长很可能不同，间隔时间的长短也可能不同。在做 MFCC 语音特征采集的过程中要对原始信号做适当的预处理。为便于对数据处理并有足够的精度，先将语音数据转换为 64 位的浮点数，之后进行预加重处理，尽可能减弱口唇辐射造成的不利影响，弥补信号的高频衰减，计算公式如下式：

$$H(z) = 1 - az^{-1} \quad (4-1)$$

式中 a 一般取值为 0.9-1.0，通常取 0.97。预加重主要作用是弥补信号高频衰减（语音信号在经过传感器、信号采样电路时其中的高频部分会有衰减）以及减弱口唇辐射的不利影响，使信号的幅频特性更平坦，从低频到高频的整个频带中，能以较好的信噪比获得频谱。

分帧是把信号分成 20-40ms 的帧，通常会分成 25ms 的。如果语音信号的采样频率是 16kHz 的，那么一帧就有 $16000 \times 25 / 1000 = 400$ 个样本点。通常我们会让相邻的帧有重叠的部分，我们会每次移动 10ms（而不是 25ms），这就意味着相邻的帧重叠的样本为 $(25-10) / 1000 \times 16000 = 240$ 个。这样，第一帧是前 400 个样本点，第二帧是第 160 个到 560 个样本点。如果最后一帧不够 400 个样本点，我们一般在后面补 0。

对信号使用汉明窗做加窗处理以体现信号短时周期性性质以及消除吉布斯效应，函数如下：


$$\omega(n)=\begin{cases}0.54-0.46\cos[2\pi n/(N-1)], & 0\leq n\leq N-1 \\ 0 & \text{其他}\end{cases}\tag{4-2}$$

FFT 采用快速傅里叶变换将时域信号变换为信号的频率谱。

Mel 滤波器采用 Mel 滤波器对数字信号滤波，以减弱人耳的掩蔽效应，经过 Mel 滤波器处理后的信号更符合人耳的声音感知特性，频率响应定义为下式：

$$H_m(k)=\begin{cases}0, & k < f(m-1) \\ \frac{k-f(m-1)}{f(m)-f(m-1)}, & f(m-1)\leq k\leq f(m) \\ \frac{f(m+1)-k}{f(m+1)-f(m)}, & f(m)\leq k\leq f(m+1) \\ 0, & f(m)\leq k\leq f(m+1)\end{cases}\tag{4-3}$$

其中 $f(m)$ 为中心频率。 $f(m)$ 之间的距离随着 m 的增加而增加，如图所示，其中横坐标为频率，纵坐标为幅值，带宽随 m 的增加而变宽：



对数运算是对三角滤波器输出进行对数运算，获得同态滤波的效果，得到频率谱的包络，对数能量公式如下：

$$s(m)=\ln(\sum_{k=0}^{N-1}|X_a(k)|^2H_m(k)),\ 0\leq m\leq M\tag{4-4}$$

最后经过离散余弦变换（DCT），26 个倒谱系数（Cepstral Coefficients），最后保留 2-13 这 12 个数字，即为 MFCC 系数。MFCC 系数的计算公式如下：

$$C(n)=\sum_{m=0}^{N-1}s(m)\cos\left(\frac{\pi n(m-0.5)}{M}\right),n=1,2,...,L\tag{4-5}$$




图 4-2 MFCC 流程图

单单使用 MFCC 特征方法，虽然能够提取输入音频的声纹特征，但是却忽略了音频的语义特征，本文将语音的韵律特征和 MFCC 特征相结合，使用基于规则和韵律的层级韵律模型提取音频特征，能够更加充分地利用语音数据进行训练，达到更好的欺骗效果。

4.1.1 韵律特征提取方法

韵律模型组件包括韵律提取器和韵律预测器，如图所示。在训练时，从基础真值 Mel 谱图中提取细粒度的韵律标签。每个韵律标签包含短语音段(即单词或音素，统称为标记)的韵律信息。韵律标签是标量或低维向量。它们被映射到一个韵律嵌入，其维数等于音素级特征的维数。韵律嵌入序列随后被添加到音素级特征序列中，并被馈送到第二个快速傅立叶变换堆栈中用于融合谱图预测。我们

使用两种不同的韵律提取器配置，基于规则的和基于神经的，来提取细粒度的韵律信息。我们将在下面的段落中详细介绍他们的模型架构。




图 4-3 层级韵律模型

1、基于规则的韵律提取

在快速语音算法之后，我们使用 F0 和能量作为基于规则的韵律标签。我们使用 DIO 算法进行 F0 估计，使用每个短时傅立叶变换 (STFT) 帧的 L2 范数进行能量估计，以提取帧级韵律标签。F0 和能量值随后在每个标记的持续时间内进行平均，以获得标记级韵律标签。然后，平均值被量化成 256 个单元，并通过嵌入层转换成韵律嵌入序列。

2、基于神经网络的韵律提取

基于神经网络的韵律抽取器使用矢量量化的自动编码器 (VQ-VAE) 作为参考编码器。参考编码器与 TTS 模型联合学习，从真实标签的 mel 谱图中提取韵律信息。参考编码器从真实标签中提取每个标记的三维表示梅尔光谱图。VQ-VAE 中的矢量化作为信息瓶颈，制约了从真实标签到 mel 谱图预测的信息量，从而激励参考编码器提取文本输入中不包含的韵律信息。

参考编码器的结构如上图 4-3 所示。参考编码器包括两个 2D 卷积层的堆栈，每个二维卷积层由 32 个滤波器和 3 个滤波器组成，每个滤波器的大小为 3×3 ，步长为 1×1 。接着是 flatten 层，并使用平均池化将帧级特征序列转换为词级特征序列。接下来的两个线性层投射到一个三维的潜在空间中。所有层后面都有一个 dropout 为 0.2 的 dropout 层。

由 256 个编码组成的 VQ 码用于将三维潜在向量量化为最近的字编码(用 L2 距离测量)。这些韵律标签被传递到一个线性层以获得韵律嵌入，然后被添加到音素特征序列以预测 mel 谱图。VQ 损失函数用于将潜在矢量编码的相互转化。来自参考编码器的量化矢量被视为基本真实韵律标签。韵律预测器然后被学习来从文本输入的音素级或词级特征预测基本真实韵律标签。参考编码器的目标是提供基础真值韵律标签，因此其参数在训练韵律预测器时是固定的，而不是在推理时使用。

3、韵律预测模型

在推理时，由于基本韵律标签是不存在的，我们必须根据文本输入来预测一个话语的韵律。音素级特征和词级特征都可以作为韵律预测的输入。对于单词级的特征，有各种各样的预训练语言模型，可以作为一个好的单词嵌入。对于音素级特征，我们遵循 fastspeech2 的配置，第一个 FFT 堆栈的输出用于预测韵律标签。韵律预测器的模型结构如图 4-3 所示，其网络结构与 FastSpeech 2 中的持续时间模型相同。当韵律预测器以词级特征作为输入时，预测的词级韵律嵌入序列根据词的音位号及时展开。如果使用基于规则的韵律标注，则用 MAE 损失训练韵律预测词；如果使用基于神经网络的韵律标注，则用 MSE 损失训练韵律预测词，而不考虑输入特征。

4.1.2 基于 BERT 的层级韵律提取模型

BERT (Bidirectional Encoder Representation from Transformers) 是一个预训练多任务模型，BERT 直接引用了 Transformer 架构中的编码器结构，舍弃了解码器模块，使其拥有了双向编码的能力，特征提取的能力得到大大加强，本文使用 BERT 模型提取输入语音的语义信息，然后作为词级预测输入层级韵律模型，标准的 MFCC 特征仅体现语音的静态特性，但相关研究证明，加入动态特征能使语音信息的质量更好。因此，在原始 MFCC 特征的基础上，增加一阶差分系数和二阶差分系数，最后的 N 维 MFCC 特征由 N/3 的 MFCC 特征和各 N/3 的一阶和二阶差分参数组成。数据分析采用信号前 80000 个点，傅里叶变换点数为 512，由原始信号得到信号的 MFCC 参数。




图 4-4 词级韵律特征提取模型

在我们的模型架构下，可以选择不同的输入组合（音素特征或单词特征）和目标（基于规则或基于神经的韵律（标签））训练韵律预测。我们的初步实验表明，词汇特征提供了更准确的信息。韵律预测比音位特征更重要。然而单词级韵律嵌入的低分辨率阻碍了合成音频样本的质量，因为TTS模型倾向于在没有足够信息的情况下预测模糊的mel谱图。因此，我们设计了一个层次化的韵律建模架构，它由一个词级韵律预测器和一个音素级韵律预测器组成，如图4-4所示。

在该体系结构中，词级韵律是第一位的由词级韵律预测器预测并扩展，匹配音素序列长度。然后将扩展的嵌入序列添加到音素特征序列中。通过将求和的特征序列输入音素级韵律预测器，细粒度音素级韵律的预测以粗粒度词级韵律预测的结果为条件。提出的层次化韵律建模方法具有一定的优点，从高分辨率音素级韵律标签和准确的词级韵律预测同时推理的时间。在这个框架中，基于规则和基于音素的韵律标签都可以用于音素级或词级的韵律建模。

使用 FastText 和预训练 BERT 来生成词级特征序列，这些特征序列被用作词级韵律预测器的输入。为了公平比较，预处理后的 BERT 被视为静态特征提取器，无需微调。

4.2 语音对抗样本生成算法

在跨特征和跨特征模型设置的黑盒攻击中，首先将生成的对抗特征 (LPMS) 转化为音频，然后从音频中提取目标模型中采用的声学特征来执行攻击。




图 4-5 内容伪造与声纹伪造

4.2.1 基于内容的语音对抗样本生成算法

我们用 f_θ 表示系统函数。对于原始语音样本 x ，我们搜索一个对抗性扰动 δ_x 加到 x 上，生成对抗性样本 $x^* = x + \delta_x$ 。这种对抗扰动 δ_x 通过最大化给定样本输入 x 的系统预测之间的偏差来优化 x^* 和真实标签 y ，如等式所示：

$$\delta_x = \arg \max_{\|\delta_x\|_p \leq \epsilon} L(f_\theta(x + \delta_x), y) \tag{4-6}$$

偏差由系统预测和真实标签之间的损失函数 L 来测量，损失函数通常被用作分类任务的交叉熵或回归任务的均方误差。 δ_x 上的 p -范数约束保证了人类无法区分敌对样本 x^* 从最初 x 和上限。 ϵ 表示扰动程度。系统参数 θ 在优化过程中始终是固定的，这意味着敌对攻击者只修改攻击系统的输入，而不是系统参数。在这项工作中，采用快速梯度符号法 (FGSM) 来解决方程中的优化问题。

它朝着损失函数 L 的梯度扰动原始输入 x ，以生成对立样本。具体来说就是专门研究上式中的无穷范数。方程的求解如下式：

$$\delta_x = \epsilon \times \text{sign} \left(\nabla_x L \left(f_\theta(x), y \right) \right) \tag{4-7}$$

其中函数符号 $\text{sign}()$ 取梯度的符号， ϵ 表示扰动程度。

每个话语 i 的声学特征被表示为矩阵 $\mathcal{X}_i$ ，其中每一列表示每个帧的声学特征，横轴表示时间序列。给定两个发音的声学特征，相应的 $\mathbf{I}$ 向量分别为：

$$\omega_i = f_{\theta_1}(\mathcal{X}_i) \quad (4-8)$$

$$\omega_j = f_{\theta_1}(\mathcal{X}_j) \quad (4-9)$$

然后, 对于这两个向量的最终相似性分数(在实验中采用 PLDA 分数)求导:

$$S_{\theta_2}(f_{\theta_1}(\mathcal{X}_i), f_{\theta_1}(\mathcal{X}_j)) \quad (4-10)$$

在 ASV 测试阶段, 每个测试试验包括一个注册话语 $\mathcal{X}_i$ 和一个测试话语 $\mathcal{X}_j$ 。根据这两种话语背后的说话者身份, 可以有两种试验: 目标试验和非目标试验。在目标试验中, 登记和测试话语背后的说话者身份属于一个人。在非目标试验中, 身份属于两个不同的人。为了模拟真实的模型攻击, 我们保持注册特征 $\mathcal{X}_i$ 和系统参数 $\{\theta_1, \theta_2\}$ 不变, 并修改测试特征 $\mathcal{X}_j$ 以生成对抗样本。对于目标试验, 将搜索扰动 δ_x 添加到 $\mathcal{X}_j$ 中, 以最小化相似性得分。对于非目标试验, 搜索扰动以使得分最大化。优化问题可以形式化表示为:

$$\delta_x = \arg \max_{\|\delta_x\|_p \leq \varepsilon} k \times S_{\theta_2}(f_{\theta_1}(\mathcal{X}_i), f_{\theta_1}(\mathcal{X}_j + \delta_x)) \quad (4-11)$$

求解的公式为:

$$\delta_x = \varepsilon \times k \times \text{sign}(\nabla_{\mathcal{X}_j} S_{\theta_2}(f_{\theta_1}(\mathcal{X}_j))) \quad (4-12)$$

$$k = \begin{cases} -1, & \text{有目标实验} \\ 1, & \text{无目标实验} \end{cases} \quad (4-13)$$

4.2.2 基于声纹的语音对抗样本生成算法

问题建模: 对于任意输入的语音 x , 系统根据所有注册的说话者的分数和预设(分数)阈值 θ , 确定 x 是由一个注册的说话者说出还是没有人说出。形式上定义如下: 假设说话人组 G 有 n 个说话人 $\{1, 2, \dots, n\}$, 决策模块输出为:

$$D(x) = \begin{cases} \arg \max_{i \in G} [S(x)]_i, & \text{if } \max [S(x)]_i \geq \theta; \\ \text{refuse}, & \text{其他} \end{cases} \quad (4-14)$$

其中 $[S(x)]_i$, $i \in G$ 表示说话者 i 发出的声音 x 的分数。直观地, 当且仅当说话者 i 的分数 $[S(x)]_i$ 是所有说话人中最大的一个, 并且不小于阈值 θ 时, 系统将输入声音 x 分类为说话者 i 。如果最大得分小于 θ , 则系统直接拒绝该声音, 即该声音不是由已知说话者发出的。

给定由某个源说话者发出的原始声音 x , 对手旨在通过找到一个扰动 δ 来精心制作敌对声音 $x' = x + \delta$, 使得:

- (1) x' 是有效的声音

(2) δ 尽可能不被人察觉,

(3) 受到攻击的 SRS 将声音 x' 分类为登记的说话者之一或目标说话者。

为了保证对抗语音是有效的语音,其依赖于音频文件格式(例如, WAV, MP3 和 AAC),我们的攻击首先将语音 x 在每个采样点 i 的幅度值 $x(i)$ 归一化到范围 $[1, 1]$ 内,然后对扰动 δ 进行处理,以确保

$$-1 \leq x'(i) = x(i) + \delta(i) \leq 1 \quad (4-15)$$

最后将 x' 转换回音频文件格式,该格式将被馈送到目标 SRS。此后,我们假设振幅值的范围为 $[1, 1]$,为了尽可能不被人察觉,攻击采用 L_∞ 范数来度量原始语音和敌对语音之间的相似性,并确保 L_∞ 距离小于给定的最大幅度阈值 ε , L_∞ 距离如下式:

$$\|x', x\|_\infty = \max_i \{|x'(i) - x(i)|\} \quad (4-16)$$

其中 i 表示音频波形的采样点。为了成功地欺骗目标 SRS,我们将为语音 x 寻找对抗样本 x' 的问题形式化为以下约束最小化问题:

$$\operatorname{argmin}_\delta f(x + \delta) \quad (4-17)$$

$$\|x + \delta, x\|_\infty < \varepsilon, x + \delta \in [-1, 1]^n \quad (4-18)$$

其中 f 是损失函数。当 f 最小化时, $x + \delta$ 被识别为目标说话者(目标攻击)或已注册说话者之一(非目标攻击)。我们的公式旨在快速最小化损失函数。

4.3 本章小结

本章首先介绍了基于 BERT 的韵律特征提取方法,不仅能够提取声纹特征,而且加入了词级韵律特征提取,提高了生成的语音对抗样本的质量,使其具有更好的攻击效果。然后针对语音识别系统和声纹识别系统提出了基于内容和基于声纹的语音对抗样本生成算法。

第五章 实验过程及结果分析

本章将进行人脸对抗样本和语音对抗样本生成的实验和分析。人脸对抗样本的生成使用了两种方法，一是基于注意力机制的贴片人脸对抗样本，二是基于集成学习的对抗样本生成方法。语音对抗样本则使用了基于内容和声纹的生成方法。实验均在常用数据集上进行训练和测试，生成了符合要求的人脸对抗样本和语音对抗样本，并且将生成的对抗样本应用于讯飞开放平台中的人脸识别接口和语音识别接口以验证对抗的攻击效果。

5.1 实验环境与数据集

具体的实验环境配置如下表所示：

表 5-1 对抗样本生成实验环境

环境	说明
处理器	Intel i7-10750H
内存	16GB
显卡	GeForce RTX2060
操作系统	Windows
编程语言	Python3.7
依赖	OpenCV、Tensorflow、Numpy、Pytorch、pillow、

本文使用的人脸图片数据集是 LFW (Labeled Faces in the Wild) 和 CASIA-Webface 数据集。

LFW 人脸数据库的收集和整理是由美国马萨诸塞州立大学阿默斯特分校计算机视觉实验室整理完成的，书库包含的人脸图像有 13000 多张，来源是互联网。每张照片都带有对应的姓名标签，有的人只有一张照片，有大约 1680 个人包含两张以上照片。

CASIA-Webface 数据集发布于 2014 年，包含了 10575 个人的 494414 张图片。人脸图片来源是互联网名人，并且经过裁剪和对齐预处理，图像质量较高。选择此数据集的图像进行对比实验。从 10575 个人中随机选取 512 张不同人脸图片作为测试集。

本实验从 LFW 数据集和 CASIA-Webface 数据集中分别抽取了 712 张不同人脸图像作为测试集。

测试数据的目录结构如下：

```
./images/  
→00001. jpg  
→00001. jpg  
→00001. jpg  
→.....  
→00712. jpg
```

描述文件 dev.csv 说明了测试集数据每一张人脸图像对应的 id，路径和人名：ImageId, ImageName, PersonName

```
1, 00001. jpg, Paul_McNulty  
2, 00002. jpg, Claudia_Pechstein  
3, 00003. jpg, Ranil_Wickremasinghe  
...  
712, 00712. jpg, Li_Zhaoxing
```

本文使用的语音数据集为 MagicData 中文手机录音音频语料库和 ST-CMDS 中文数据集。

ST-CMDS 是由一个 AI 数据公司发布的中文语音数据集，包含 10 万余条语音文件，大约 100 余小时的语音数据。数据内容以平时的网上语音聊天和智能语音控制语句为主，855 个不同说话者，同时有男声和女声，适合多种场景下使用。

Magic Data 技术有限公司的语料库，语料库包含 755 小时的语音数据，其主要是移动终端的录音数据。邀请来自中国不同重点区域的 1080 名演讲者参与录制。句子转录准确率高于 98%。录音在安静的室内环境中进行。数据库分为训练集，验证集和测试集，比例为 51: 1: 2。诸如语音数据编码和说话者信息的细节信息被保存在元数据文件中。录音文本领域多样化，包括互动问答，音乐搜索，SNS 信息，家庭指挥和控制等。还提供了分段列表。说话人元数据字段有：语音文件名、说话人年龄、性别、口语等。

5.2 人脸对抗样本生成实验

模型原始的 LFW 数据集包含许多无关背景信息，因此在进行特征提取之前对原始数据集进行预处理。对原始数据进行对齐并缩放到 112*112 尺寸，得到 5749 个人的人脸数据库，并进行了简单的数据清洗。在这里，每个人的照片数量不同，对每一张照片计算模型最后一层输出的特征向量，同时对个人的特征向

量进行平均，以该平均向量作为特定人脸的特征标准，最终得到的人脸平均特征向量库 mean.csv。

5.2.1 模型训练

本节按照第三章提出的基于注意力机制和基于集成学习的对抗样本生成算法，在 LFW 人脸数据集和 CASIA-Webface 数据集上进行模型训练和测试。基于注意力机制的人脸对抗样本生成实验中，参数设置如下表所示。

表 5-2 参数设置

参数	参数值	参数说明
Epoch	250	训练轮次
Batch size	64	批处理样本个数
Learning rate	0.00005	学习率
λ	0.002-0.005	贴片损失的系数
γ	1.0	对抗样本损失的系数
δ	0.0001	扰动大小

基于注意力机制产生的对抗样本示例如下图所示。



基于集成学习的人脸对抗样本生成实验中，将常用的骨干网络模型进行集成，本实验分别集成了 IR50，IR101，IR152（模型深度不同）。使用有目标攻击，通过多模型集成计算出图片之间的相似度，损失函数分为三个部分，包括经典的距离计算损失函数如 L2 loss、cos loss 和 TV loss。TV loss 保证了对抗样本的光滑性。最后生成的噪声会经过高斯卷积，最后叠加在原图上。为了使添加噪声后的图像肉眼看不出明显的区别，不断迭代上述流程，直到当前图片与自己的矩阵相似度超过 0.25 之后终止。




图 5-2 相似度与攻击次数变化图

实验成功攻击了 LFW 数据集的 712 张照片。基于集成学习方法产生的对抗样本示例如下图所示。



实验中使用 VGG16 和 ResNet-34 作为训练时的目标模型。VGG16 和 ResNet 是目前最常用的人脸对抗样本的替代训练模型。不同方法的攻击成功率如下表所示：

表 5-3 攻击实验成功率

方法	LFW		CASIA-WebFace	
	VGG-16	ResNet	VGG-16	ResNet
OUR	0.885	0.973	0.955	0.974
PGD	0.871	0.932	0.875	0.958
L-FGSM	0.798	0.764	0.815	0.872




图 5-4 不同攻击方法的成功率

由上表可以看出，本论文提出的方法在 LFW、CISIA-WwbFace 数据集上生成的对抗样本在 LFW 数据集和 CASIA-WebFace 数据集上均获得了较好的效果，成功率高于传统的 PGD 攻击算法和 L-FGSM 攻击算法。CASIA-WebFace 数据集的图像质量优于 LFW 数据集，因此，CASIA-WebFace 数据集上生成的对抗样本质量也要好于 LFW 数据集。

5.2.2 评价指标

对抗样本的目的是使分类器决策错误，当输入图像的最高置信度所属的类别标签发生改变即视为攻击成功。此外，需要建立针对对抗样本的评估指标来保障对抗样本生成的质量。而在图像审核器的攻击任务中评估对抗样本的质量与分类器也有很大不同。当攻击图像分类器时，通常目标是尽可能少的扰动像素。而在攻击图像审核器时，即使输入图像被扰动了大量的像素，但是依然不影响人的主观判断。通常用三个指标来评估对抗样本的质量： L_2 距离，峰值信噪比（Peak Signal to Noise Ratio, PSNR）和结构相似性（Structural Similarity, SSIM）。

峰值信噪比衡量图像的质量及图像失真的程度，单位是 dB，值通常在 20-40 之间，值越大，代表像素质量越好，失真越小，对于一个三通道 RGB (red, green, blue) 图像 ($m \times n \times 3$) 来说，定义如下：

$$MSE = \frac{1}{m \times n \times 3} \times \sum_{b=0}^2 \sum_{i=1}^n \sum_{j=1}^m \|ADV(i, j, b) - O(i, j, b)\|^2 \tag{5-1}$$

峰值信噪比:

$$PSNR = 10\log_{10}(MAX^2/MSE) \tag{5-2}$$

其中, MAX=255, (i,j,b) 为图像**b**通道在位置 (i,j) 的坐标。

SSIM 用来评估两张图像 (x,y) 的相似性, 定义如下:

$$SSIM(x,y) = \frac{(2\mu_x\mu_y+c_1)(2\sigma_{xy}+c_2)}{(\mu_x^2+\mu_y^2+c_1)(\sigma_x^2+\sigma_y^2+c_2)} \tag{5-3}$$

其中 μ_x 为样本 x 的均值, μ_y 是样本 y 的均值, σ_x^2 是 x 的方差, σ_y^2 是样本 y 的方差, c_1 和 c_2 是两个常数, $c_1 = (k_1L)^2$, $c_2 = (k_2L)^2$, k_1 和 k_2 是固定值, $k_1 = 0.01$, $k_2 = 0.03$, L 是像素值的范围, $L = 2^B - 1$ 。

5.2.3 对抗攻击实验

为了验证本论文提出的方法能够迁移至真实环境, 成功攻击商用的人脸识别系统的接口, 本文选择了开源的讯飞人脸识别系统进行实验。

ATDF 平台基于计算机视觉、检测算法、人脸比对等技术, 实现了对视频中的人脸真伪进行快速检测和分析。换脸甄别包含三个不同阶段的检测, 根据视频图像中像素、纹理级别的低阶特征, 到具有全局语义信息的高阶特征, 对图像、视频进行多方位、多层次的分析, 覆盖多种 AI 换脸算法。

讯飞开放平台的静默活体检测基于讯飞自研的活体检测算法, 针对打印照、屏幕二次翻拍等作弊场景, 基于图片中人像破绽及成像畸形, 验证样本是否为活体, 并给出置信度参考。

讯飞 AI 开放平台在线图片活体检测接口能力: 基于讯飞自研的活体检测算法, 针对打印照、屏幕二次翻拍等作弊场景, 基于图片中人像破绽及成像畸形, 可有效识别目标是否为活体, 并给出置信度参考。该能力是通过 HTTP API 的方式给开发者提供一个通用的接口。HTTP API 适用于一次性交互数据传输的 AI 服务场景, 块式传输。相较于 SDK, API 具有轻量、跨语言的特点。要求输入清晰的人脸照片, 人脸大小不小于 30*30 像素, 其中人脸俯仰角、左右偏航角、人脸翻转角 60° 以内。接口要求如下表所示:

表 5-4 讯飞开放平台 API 接口要求

内容	说明
传输方式	http[s]
请求行	POST /v1/private/s67c9c78c HTTP/1.1
接口鉴权	在调用业务接口时, 请求方需要对请求进行签名, 服务端通

字符编码	UTF-8
响应格式	JSON 格式
图片格式	jpg/png/bmp
图片大小	Base64 编码后大小不超过 4M
图片要求	清晰的人脸照片，人脸大小不小于 30*30 像素，其中人脸俯

攻击的返回值如下表所示：

表 5-5 攻击实验的返回值

ret	x	y	w	h	passed	score
0	9	3	87	108	true	0.5193

攻击操作的返回值包含 ret、x、y、w、h、passed、score 等字段，字段含义和描述如下表所示：

表 5-6 人脸识别系统返回值字段

参数名	类型	描述	备注
ret	int	内部服务返回值	ret=0 表示请求成功
passed	boolean	是否通过活体检测，true	
score	float	活体置信度	最大值：1，最小值：0
x	int	人脸框左上角 x 坐标，以图片	单位：像素。最小值：0
y	int	人脸框左上角 y 坐标，以图片	单位：像素。最小值：0
w	int	人脸框宽度	单位：像素。最小值：0
h	int	人脸框高度	单位：像素。最小值：0

由上表可知，返回值 ret=0 代表攻击成功，即对抗样本成功地欺骗了商业人脸识别系统，给人工智能带来了安全方面的隐患。

本文对比试验的结果如下表所示：

表 5-7 实验结果

	L_2 距离	峰值信噪比	结构相似性
OUR	2.83	23.22dB	0.77
PGD	2.97	16.36dB	0.45
L-FGSM	3.45	13.36dB	0.35

如上表所示，本文提出的方法生成的对抗样本 L_2 距离小于 PGD 攻击算法和 L-FGSM 算法，峰值信噪比明显高于 PGD 算法和 L-FGSM 算法，而结构相似性指标高于 PGD 攻击算法和 L-FGSM 算法。这表明，本论文提出的算法生成的人脸对抗样本质量较高，相关指标均优于以往的算法。并且，实验证明本论文提出的人脸对抗样本生成算法能够成功迁移至真实环境中实现对抗攻击。

5.3 语音对抗样本生成实验

本节使用第四章提出的的对抗样本生成算法在 MagicData 中文手机录音音频语料库和 ST-CMDS 中文数据集上进行实验。在特征提取和对抗样本生成过程中均获得了较好的效果。

5.3.1 模型训练与对抗样本生成

首先使用 BERT 模型对音频进行词级预测，将预测结果输入层级韵律模型的词级特种中进行训练，通过最小化损失函数生成目标对抗样本。实验中的参数设置如下表所示。

表 5-8 实验参数

参数	参数值	参数说明
epoch	250	训练轮次
steps	300	批训练次数
batch size	16	一次批处理的样本个数
learning rate	2e-5	学习率
β_1	0.9	贴片损失的系数
β_2	0.98	对抗样本损失的系数
ϵ	1e-9	扰动大小

生成的对抗样本波形图如下图所示。




图 5-5 样本 A 的对抗样本波形图和样本 B 的对抗样本波形图

5.3.2 评价指标

语音对抗样本的评价指标有编辑距离、扰动大小、攻击的成功率、对抗性扰动信噪比、错误拒绝率、错误接受率和等错误率等。

表 5-9 语音对抗样本的评价指标

分类	评估指标	缩写	全称
攻击效果	编辑距离	MED	Minimum Edit Distance
攻击效果	攻击成功率	ACC	Accuracy
音频质量	信噪比	SNR	Signal Noise Ratio
音频质量	错误拒绝率	FRR	False Rejection Rate
音频质量	错误接受率	FAR	False Rejection Rate
音频质量	等错误率	EER	Equal Error Rate

(1) 编辑距离

编辑距离也称字错误率，用来衡量两个序列相似程度，也是语音识别的常用指标。编辑距离的定义是由一个字符串转成另一个字符串所需要的最少操作次数。编辑操作包括 S、I 和 D：

S：将一个字符替换成另一个字符

I：插入一个字符

D：删除一个字符

默认添加和删除一个字符时需要的距离为 1，修改一个字符时需要的距离为 2。计算公式如下：

$$WAR = 100 \frac{S+D+1}{N} \% \quad (5-4)$$

(2) 攻击成功率

若商用的语音识别系统能够成功识别对抗样本即为攻击成功。

(3) 信噪比

本实验使用信噪比指的是有效信号能量与无用噪音能量的比值，单位为分贝 (dB)，信噪比越高表示噪声干扰越低。在语音模拟信号处理系统中信噪比用于衡量语音信号中噪声的大小。计算方法如下所示，式中 $\sum_{n=0}^{N-1} s^2(n)$ 代表信号能量大小， $\sum_{n=0}^{N-1} d^2(n)$ 代表噪音能量的大小。信噪比值越大意味着噪声能量越小。

$$SNR = 10 \log_{10} \frac{\sum_{n=0}^{N-1} s^2(n)}{\sum_{n=0}^{N-1} d^2(n)} \quad (5-5)$$

(4) 错误拒绝率

错误拒绝率计算公式如下所示。式中 NFR 是错误拒绝的次数， $NGRA$ 是类内的测试的次数。 FRR 表征了不匹配率。但是真实场景中，简单的环境噪声等加到输入中也会导致系统无法识别说话人的声音，所以 FRR 数值的增加不能很好地反映声纹识别系统对对抗式攻击的脆弱性。

$$FRR = \frac{NFR}{NGRA} \quad (5-6)$$

(5) 错误接受率

错误接受率的计算公式如下所示。 NFA 是错误接受次数， $NIRA$ 是类间测试次数。 FAR 的值随阈值的增大而将减小。

$$FAR = \frac{NFA}{NIRA} \quad (5-7)$$

(6) 等错误率

将FRR曲线和FAR曲线放在同一个坐标中，交点的值即为EER。由于FRR曲线和FAR曲线交点的阈值一般小于 0.3，而实验中，一般将阈值设定为大于等于 0.7，因此EER也不能很好地表征对抗样本本地攻击性能。

综上，本文选择FAR指标和EER指标综合衡量系统对对抗样本攻击的鲁棒性。

5.3.3 对抗攻击实验

为了验证本论文提出的方法能够迁移至真实环境，成功攻击商用的语音识别系统的接口，本文选择了开源的语音识别系统和声纹识别系统进行实验。

声纹识别是一项通过将说话人声音特征作为身份标识标准，自动核验说话人身份的技术。科大讯飞的移动语音终端 MSC SDK（Mobile Speech Client）的声纹识别功能包括注册、验证和模型操作。类似于一个网站的用户登录一样，用户必须先注册，才能登录（验证），在用户忘记密码时，可以提供重设密码的操作（模型操作），实现声纹的注册和声纹 1：1、1：N 对比验证的服务，对说话人的声纹特征进行提取和辨别。

讯飞开放平台的语音听写系统可以将 60s 以内的短音频精准识别成文字，支持除中文普通话和英文外的 35 个语种、24 种方言和 1 个民族语言，能实现多方言、多语种、高识别率、高准确率识别，实时返回识别结果，达到毫秒级别快速响应。语音识别功能包括实时语音识别、录音文件识别、语音异步识别和离线命令词识别等功能。

表 5-10 讯飞语音识别接口要求

内容	说明
请求协议	ws[s]
请求地址	中英文 ws[s]: //iat-api.xfyun.cn/v2/iat
请求行	GET /v2/iat HTTP/1.1
字符编码	UTF-8
响应格式	JSON 格式
音频格式	PCM、speex(8k)、speex-wb(16k)、mp3
音频长度	最长 60s
语言种类	中文、英文、小语种、中文方言等

语音对抗攻击的对比试验的结果如下表所示：

表 5-11 实验结果

	攻击成功率	信噪比	错误接受率	等错误率
OUR	0.85	25db	0.3	0.4
L-FGSM	0.7	20db	0.3	0.5

如上表所示，本论文方法生成的语音对抗样本攻击讯飞语音识别接口的成功率为 0.85，优于 L-FGSM 攻击方法生成的对抗样本。并且，语音对抗样本的信噪比较高于对比实验方法，音频质量更好。从错误接受率和等错误率值来看，由于实验目的为使对抗样本能够成功攻击语音识别系统，因此错误接受率较低，此时，系统不容易接受错误的音频，而此时，本文方法的等错误率值低于 L-FGSM 方法的等错误率，证明本论文算法具有优越性。




图 5-6 语音对抗样本

如图 5-6 所示，图 original audio 为原始音频的波形图，图 target audio 是目标语音的波形图，图 MFCC 是使用 MFCC 特征提取方法生成的对抗样本的波形图，图 adversarial audio 是使用基于 BERT 的韵律特征提取方法生成的语音波形图。由上图可以看出，使用本文提出的音频韵律特征提取方法生成的对抗音频波形图更接近原始音频，扰动更小，也更加不容易被人耳察觉，而且与目标音频的相似度更高，攻击效果更好。

5.4 本章小结

本章首先介绍了本论文的实验环境和使用的实验数据集。然后分别介绍了人脸对抗样本生成实验和语音对抗样本生成实验。通过模型训练，进一步生成符合标准的对抗样本，然后对其质量进行了评估，最后在商用的智能识别系统上进行了攻击实验。

第六章 总结与展望

6.1 本文工作总结

近年来,人工智能的发展和应用十分迅速,机器学习相关技术,已经被广泛应用于各个领域,但是机器学习却面临着不少安全问题的严峻挑战,对抗样本攻击就是其中之一。开展对抗样本生成方法的研究有利于提升机器学习算法的鲁棒性和安全性。

本文针对人工智能领域的生物特征识别系统,结合当前环境,研究了人脸对抗样本和语音对抗样本生成算法,并且迁移到真实环境中进行对抗样本攻击,验证现有人脸识别系统、语音识别系统和声纹识别系统的安全性和鲁棒性。论文的主要工作有:

(1) 本文针对当前疫情情况下,人们在公共场所通常带着口罩的现象,提出了基于注意力机制的对抗性攻击算法。算法通过视觉感知机制,搜索出容易被攻击的口罩图案区域,然后针对性地添加噪声,使得分类器分类错误,人脸识别失败。本文提出了基于 Adaboost 的人脸对抗样本生成方法。

(2) 本文针对人脸数据集 LFW 和 CASIA-Webface 分别进行对抗样本生成实验、模型训练和测试,使用基于注意力机制的攻击方法和基于集成学习的攻击方法分别生成了高质量的人脸对抗样本。并且使用商用的人脸识别系统接口进行人脸识别和活体检测实验,实现了黑盒对抗攻击。

(3) 本文提出了基于 BERT 的词级韵律特征提取方法。不仅能够提取音频的声纹特征,而且能够表征词级特征,从而更好地生成语音对抗样本。另外针对语音识别和声纹识别系统,本文分别提出了基于内容和基于声纹的语音对抗样本生成算法,分别生成了能够欺骗语音识别系统和声纹识别系统的对抗音频并且不被人耳察觉。

(4) 本文在 MagicData 中文手机录音音频语料库和 ST-CMDS 中文数据集上进行了模型训练和测试。并且使用生成的对抗样本成功攻击了商用的语音识别系统和声纹识别系统,实现了黑盒对抗攻击。

6.2 问题与展望

本文通过对人工智能领域的对抗样本生成方法进行研究和实验，生成了高质量的对抗样本。但是由于时间关系，本文的实验仍有很多不足，主要包括以下几点：

（1）人脸对抗样本生成实验中，生成的人脸对抗样本仅攻击了讯飞的开放平台接口，未在其他商用平台上进行实验。

（2）语音对抗样本只有一部分能够被讯飞开放平台的语音识别系统接口识别，未来可以尝试更好的生成算法。

综上所述，随着人工智能系统的应用越来越普及，应用场景越来越多，人脸识别系统和语音识别系统面临对抗攻击的可能性也越来越大，各种各样的攻击方法层出不穷，只有认识到了人工智能系统所面对的严峻考验，并且深刻理解其算法易受攻击的根本原因，才能更好地解决问题，训练出更加健壮和鲁棒的网络结构，才能更好的保护我们的信息安全。

参考文献

- [1] Szegedy C, Zaremba W, Sutskever I, et al. Intriguing properties of neural networks[J]. arXiv preprint arXiv: 1312.6199, 2013.
- [2] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[J]. arXiv preprint arXiv: 1412.6572, 2014.
- [3] Kurakin A, Goodfellow I, Bengio S. Adversarial examples in the physical world[J]. arXiv preprint arXiv: 1607.02533, 2016.
- [4] Papernot N, McDaniel P, Jha S, et al. The limitations of deep learning in adversarial settings[C]//2016 IEEE European symposium on security and privacy (EuroS&P). IEEE, 2016: 372-387.
- [5] Su J, Vargas D V, Sakurai K. One pixel attack for fooling deep neural networks[J]. IEEE Transactions on Evolutionary Computation, 2019, 23(5): 828-841.
- [6] Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]//2017 IEEE symposium on security and privacy (sp). IEEE, 2017: 39-57.
- [7] Moosavi-Dezfooli S M, Fawzi A, Frossard P. Deepfool: a simple and accurate method to fool deep neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 2574-2582.
- [8] Brendel W, Rauber J, Bethge M. Decision-based adversarial attacks: Reliable attacks against black-box machine learning models[J]. arXiv preprint arXiv:1712.04248, 2017.
- [9] Athalye A, Engstrom L, Ilyas A, et al. Synthesizing robust adversarial examples[C]//International conference on machine learning. PMLR, 2018: 284-293.
- [10] Chen P Y, Zhang H, Sharma Y, et al. Zoo: Zeroth order optimization based black-box attacks to deep neural networks without training substitute models[C]//Proceedings of the 10th ACM workshop on artificial intelligence and security. 2017: 15-26.
- [11] Sarkar S, Bansal A, Mahbub U, et al. UPSET and ANGRI: Breaking high performance image classifiers[J]. arXiv preprint arXiv:1707.01159, 2017.
- [12] Baluja S, Fischer I. Adversarial transformation networks: Learning to generate adversarial examples[J]. arXiv preprint arXiv:1703.09387, 2017.

- [13] Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[J]. arXiv preprint arXiv:1706.06083, 2017.
- [14] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. arXiv preprint arXiv:1406.2661, 2014.
- [15] Dong Y, Su H, Wu B, et al. Efficient decision-based black-box adversarial attacks on face recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 7714-7722.
- [16] 马玉琨, 毋立芳, 简萌, 刘方昊, 杨洲. 一种面向人脸活体检测的对抗样本生成算法[J]. 软件学报, 2019, 30(02): 469-480.
- [17] Komkov S, Petiushko A. Advhat: Real-world adversarial attack on arcface face id system[J]. arXiv preprint arXiv:1908.08705, 2019.
- [18] 刘雨佳. 针对神经网络的图像对抗样本生成及应用研究[D]. 中国科学技术大学, 2019.
- [19] 王艳. 基于深度神经网络的人脸验证[D]. 北京邮电大学, 2019.
- [20] 徐珍琦. 基于深度学习的人脸对齐[D]. 北京邮电大学, 2017.
- [21] 李旭嵘. 深度视觉对抗技术研究[D]. 浙江大学, 2020.
- [22] Eykholt K, Evtimov I, Fernandes E, et al. Robust physical-world attacks on deep learning visual classification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 1625-1634.
- [23] Yakura H, Sakuma J. Robust audio adversarial example for a physical attack[J]. arXiv preprint arXiv:1810.11793, 2018.
- [24] Yuan X, Chen Y, Zhao Y, et al. Commandersong: A systematic approach for practical adversarial voice recognition[C]//27th {USENIX} Security Symposium ({USENIX} Security 18). 2018: 49-64.
- [25] Alepis E, Patsakis C. Monkey says, monkey does: security and privacy on voice assistants[J]. IEEE Access, 2017, 5: 17841-17851.
- [26] Roy N, Hassanieh H, Roy Choudhury R. Backdoor: Making microphones hear inaudible sounds[C]//Proceedings of the 15th Annual International Conference on Mobile Systems, Applications, and Services. 2017: 2-14.
- [27] Taori R, Kamsetty A, Chu B, et al. Targeted adversarial examples for black box audio systems[C]//2019 IEEE Security and Privacy Workshops (SPW). IEEE, 2019: 15-20.

- [28] 张兆阳. 黑盒环境下语音识别模型的普适性对抗样本生成方法研究[D]. 哈尔滨工业大学, 2020.
- [29] 胡亚军. 基于神经网络的统计参数语音合成方法研究[D]. 中国科学技术大学, 2018.
- [30] 于泓. 合成语音检测算法研究[D]. 北京邮电大学, 2018.
- [31] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105.
- [32] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [33] Yakura H, Sakuma J. Robust audio adversarial example for a physical attack[J]. arXiv preprint arXiv:1810.11793, 2018.
- [34] Kreuk F, Adi Y, Cisse M, et al. Fooling end-to-end speaker verification with adversarial examples[C]//2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2018: 1962-1966.
- [35] Zhang K, Zhang Z, Li Z, et al. Joint face detection and alignment using multitask cascaded convolutional networks[J]. IEEE Signal Processing Letters, 2016, 23(10): 1499-1503.
- [36] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. arXiv preprint arXiv:1406.2661, 2014.
- [37] Papernot N, McDaniel P, Jha S, et al. The limitations of deep learning in adversarial settings[C]//2016 IEEE European symposium on security and privacy (EuroS&P). IEEE, 2016: 372-387.
- [38] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105.
- [39] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [40] Ren S, Cao X, Wei Y, et al. Face alignment at 3000 fps via regressing local binary features[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014: 1685-1692.

- [41] Zhang K, Zhang Z, Li Z, et al. Joint face detection and alignment using multitask cascaded convolutional networks[J]. IEEE Signal Processing Letters, 2016, 23(10): 1499-1503.
- [42] Kurakin A, Goodfellow I, Bengio S. Adversarial machine learning at scale[J]. arXiv preprint arXiv:1611.01236, 2016.
- [43] Papernot N, McDaniel P, Jha S, et al. The limitations of deep learning in adversarial settings[C]//2016 IEEE European symposium on security and privacy (EuroS&P). IEEE, 2016: 372-387.
- [45] Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]//2017 IEEE symposium on security and privacy (sp). IEEE, 2017: 39-57.
- [47] Lu J, Sibai H, Fabry E. Adversarial examples that fool detectors[J]. arXiv preprint arXiv:1712.02494, 2017.
- [48] Xie C, Wang J, Zhang Z, et al. Adversarial examples for semantic segmentation and object detection[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 1369-1378.
- [49] Li Y, Tian D, Chang M C, et al. Robust adversarial perturbation on deep proposal-based models[J]. arXiv preprint arXiv:1809.05962, 2018.
- [50] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[J]. arXiv preprint arXiv:1412.6572, 2014.

第七章 致谢

转眼间，在北京邮电大学的研究生生活就要结束了，细细想来，在这三年的学习生涯中，我收获了很多。至今还记得当时报考北京邮电大学时内心的紧张和忐忑、初入北邮的激动和憧憬、学习收获知识时的喜悦和满足……在这里，向所有帮助过我、批评过我、支持着我、爱着我的人表达真诚的感谢！

首先感谢我的导师朱洪亮老师，不仅在专业上为我们授课解惑，为我指引前进的方向，生活上也关心我们，爱护我们，尽可能地帮助我们解决困难，遇到问题开导我们乐观豁达，培养我们发现问题和解决问题的能力。指导论文时细心、有耐心，包容我的不足，鼓励我。老师那种对信息安全专业的热爱、对科研的探索的精神也深深地影响了我，使我受益匪浅。

同时，我也要感谢灾备技术国家工程实验室地杨义先老师、辛阳老师、罗守山老师、商彦磊老师，感谢老师们为我们的学习和研究提供了良好的环境和设备，还有珍贵的实践机会，专业上耐心地指导我们，教会我们宝贵的人生经验。另外我还要感谢李祺老师，在我的研究方向上给予了无微不至的指导，为我的论文提供了很多宝贵的建议。感谢教授《高级人工智能安全》这门课的袁开国老师带给我的对专业方向的思考，也感谢所有任课老师们的辛勤付出！

我还要感谢我的室友们、实验室的同学们、师姐、师兄、师弟、师妹们，在写论文的过程中给予我的帮助和支持。通过研究生阶段的学习，我不仅获得了许多宝贵的知识，在专业技能方面有了很大的提升，还收获了宝贵的友谊！大家都在努力成为着更好的自己。

感谢我的家人对我学业的支持和鼓励，生活中他们的陪伴和关心、支持和鼓励是我前进的巨大动力！

最后，也感谢评审老师和专家学者们，感谢你们百忙之中抽出时间来指导本论文。