

面向语音识别系统的黑盒对抗攻击方法

陈晋音, 叶林辉, 郑海斌, 杨奕涛, 俞山青

(浙江工业大学 信息工程学院, 杭州 310023)

E-mail: chenjinyin@zjut.edu.cn

摘要: 随着深度学习方法在语音识别系统中的广泛应用,尤其是在自动驾驶、身份认证等安全等级较高的应用,语音识别系统的安全问题至关重要.深度学习给语音识别系统带来更便捷的训练步骤、更高的识别准确率的同时,也给系统的安全性带来了潜在风险.最近的研究表明深度神经网络容易受到对输入数据添加细微扰动的对抗攻击,导致模型输出错误的预测结果.当基于深度学习的语音识别系统被外加的细微扰动所攻击,自动驾驶汽车将会被恶意语音攻击执行危险操作,给自动驾驶系统带来了严重的安全隐患.针对语音识别系统的安全性,本文提出了一种面向语音识别系统的黑盒对抗攻击方法,采用布谷鸟搜索算法自动生成对抗语音样本,实现目标攻击.最后,利用生成的对抗语音样本攻击语音识别系统,挖掘当前性能优异的语音识别系统存在的安全漏洞,将本文提出的黑盒攻击方法在公共语音数据集、谷歌语音命令数据集、GTZAN数据集和 LibriSpeech数据集上展开实验,验证了黑盒攻击方法的有效性.更进一步,利用对抗样本对其他语音识别系统进行攻击,验证其具有较强攻击迁移性,并对生成的对抗样本进行了主观评价试验,探究其隐蔽性.

关键词: 语音识别; 深度学习; 布谷鸟搜索算法; 对抗攻击; 黑盒攻击

中图分类号: TP312

文献标识码: A

文章编号: 1000-4220(2020)05-1019-11

Black-box Adversarial Attack Toward Speech Recognition System

CHEN Jin-yin, YE Lin-hui, ZHENG Hai-bin, YANG Yi-tao, YU Shan-qing

(College of Information Engineering, Zhejiang University of Technology, Hangzhou 310023, China)

Abstract: With the wide application of deep learning method in speech recognition system, especially in autopilot and personal identification, the security of speech recognition system is crucial. In recent years, the application of deep learning has brought more convenient training steps to speech recognition system, higher recognition accuracy with the potential risks to the security problem. Recent studies have shown that deep neural networks are vulnerable to adversarial attacks in the form of subtle perturbations added onto the input data, resulting in incorrect predictive results. If the speech recognition system based on deep learning is attacked by additional minor disturbances, the autopilot will be attacked by malicious voice attacks, which will bring great security risks to the autopilot system. Aiming at the security of speech recognition system, in this paper we propose a novel black-box adversarial attack toward speech recognition system, which uses the cuckoo search algorithm to automatically generate the adversarial speech examples to achieve the target attack. Using the generated speech examples to attack the speech recognition system, it is found that there are security vulnerabilities even in the current state-of-the-art speech recognition systems. Extensive experiments are carried out on public voice data set, Google voice command data set, GTZAN data set and LibriSpeech data set, to testify the effectiveness of the proposed black-box attack method. Furthermore, the generated adversarial examples are applied to attack other speech recognition system to testify the strong transfer attack capacity and makes a subjective evaluation test on the them to explore their concealment.

Key words: speech recognition; deep learning; cuckoo search algorithm; adversarial attack; black-box attack

1 引言

随着深度学习模型在语音识别应用中取得的成功,语音识别控制系统如 Amazon Alexa、谷歌语音助手、苹果 Siri、微软 Cortana 和科大讯飞等商业产品在人机交互中获得广泛应用,并在移动设备、智能家居等多个领域取得成功,尤其在自动驾驶、声纹身份认证等安全级别较高的应用场景中实现了关键应用.

传统语音识别模型多数采用隐马尔科夫高斯混合模型(HMM-GMM)^[1],建立在似然概率基础上,利用区分度训练在一定程度上拟合了模式类之间的差异性.深度学习的引入使语音识别系统原有的技术框架得到彻底改变^[2-3].深度神经网络可以充分利用特征之间的关联性,将连续帧的语音特征合并后进行训练,使语音识别系统的识别率大幅度提高.

由于深度神经网络的优异性能,已有较多基于深度神经网络模型的语音识别系统.然而,Goodfellow^[4]和 Szegedy^[5]

收稿日期: 2019-12-26 收修改稿日期: 2020-01-13 基金项目: 浙江省自然科学基金项目(LY19F020025)资助; 宁波市“科技创新 2025”重大专项(2018B10063)资助; 浙江省认知医疗工程技术研究中心(2018KFJ07)资助. 作者简介: 陈晋音(通讯作者),女,1982年生,博士,副教授,CCF会员,研究方向为数据挖掘、智能计算、复杂网络分析等; 叶林辉,男,1996年生,硕士研究生,研究方向为语音识别、深度学习等; 郑海斌,男,1995年生,硕士研究生,研究方向为数据挖掘和应用、智能计算等; 杨奕涛,男,1997年生,研究方向为语音攻防; 俞山青,女,1984年生,博士,讲师,研究方向为智能计算、数据挖掘等.

发现深度神经网络容易受到对输入数据添加细微扰动形式的对抗攻击。例如在自动驾驶领域,车载语音识别系统在输入时被外加的细微扰动所攻击,语音识别系统将错误地识别乘客的指令,这给自动驾驶系统带来了极大的安全隐患。

随着图像领域对抗攻击的研究深入,音频领域的对抗攻击也逐步提出。两种攻击存在差异,首先,语音识别系统需要处理时间域上的信息变化,这比图像分类系统更复杂;其次,音频的采样率通常都非常高。例如:采样率为 16kHz 的音频,每秒采样 16000 个数据点,相比于图像分类,这意味着要处理更大的数据量。因此,语音识别领域对抗样本的生成过程更加复杂。

Carlini^[3], Cisse^[4] 和 Iter^[5] 提出了语音识别对抗攻击生成方法,在已知识别模型结构的前提下基于梯度信息生成对抗样本,属于白盒攻击方法,Carlini 指定了攻击的目标短语,属于目标攻击,而 Cisse 和 Iter 的攻击方法未指定特定攻击目标短语,属于无目标攻击(逃逸攻击)。而在实际应用中,通常攻击者很难获得识别模型的结构信息,且攻击是为了达到特定目标(例如,使得某一段语音识别成特定的指令),因此黑盒的目标攻击在实际应用中更具有攻击性与隐蔽性。

为实现面向语音识别系统的黑盒目标攻击,本文提出了一种面向语音识别系统的黑盒攻击方法,主要工作包括:

- 1) 提出了一种基于布谷鸟搜索优化算法的黑盒对抗攻击方法,实现对语音识别系统的黑盒攻击;
- 2) 通过设定攻击目标指令,可将任意正常样本通过布谷鸟搜索算法自动生成对抗样本,实现了黑盒设置下的目标对抗攻击,验证了提出方法具有较强的目标攻击能力与样本生成能力;
- 3) 将本文提出的方法在多个实际数据集展开验证,包括:公共语音数据集、谷歌语音命令数据集、GTZAN 数据集和 LibriSpeech 数据集,验证提出方法的有效性。并分析了生成对抗样本的攻击迁移性,验证其对其他语音识别模型具有迁移性攻击,并对对抗样本进行了主观评测,探究了其隐蔽性。

2 相关工作

2.1 语音识别深度模型

基于隐马尔可夫模型(HMM)的语音识别模型是常用方法之一,Baum^[6] 率先使用最大似然原则对 HMM 模型进行训练。Macherey^[7] 把比最大似然原则更优的判别训练应用在 HMM 上,采用了最小分类误差优化模型的参数并取得较好结果。Zheng^[8] 提出了一种新的判别训练标准,使用最小通话帧误差加速了模型的训练,并且使得模型的准确率有所提高。Wu^[9] 提出了基于最小代误差的 HMM 训练方法,提高了模型的识别精度。

在基于 HMM 的语音识别模型基础上,利用高斯混合模型(GMM)状态观测概率进行建模。Yu^[10,11] 用上下文相关的深度神经网络模型(DNN)来替代高斯混合模型,并取得了良好的效果。Mohamed^[12] 使用深度置信网络代替高斯混合模型来提高模型的识别率。Yao^[13] 将自适应的方法引入 DNN-HMM 的模型中,使词错误率进一步降低。

近几年,提出了较多基于深度学习模型的语音识别方法,

端到端的语音识别方法直接将输入的声学特征序列映射到输出的词序列。Graves^[14] 利用连接主义时间分类(CTC)来建立端到端的语音识别模型。随后,百度拓展了这项工作,利用大量的数据训练得到能成功商用于英语和普通话的语音识别模型^[3]。Zhang^[15] 将深度卷积网络引入端到端模型,进一步增强了模型的表达和泛化能力。谷歌的 DeepMind 团队推出了可以生成音频的深度神经网络 WaveNet 模型^[3],WaveNet 不仅能作为一种生成模型,而且可以完成语音识别的任务。Chan^[16] 提出了一种端到端的语音识别注意力模型,进一步提高识别准确率。

2.2 对抗攻击与防御方法

受到图像领域对抗攻击研究的启发,音频领域的对抗攻击正在受到越来越多的关注。Gong^[17] 使用 2% 大小的扰动使得基于深度神经网络的语音识别系统误识别,实现了无目标攻击。Carlini^[18] 提出了一种通过 MFC 层传递梯度的方法,并将其应用到 DeepSpeech 模型^[3] 中,通过从一个梯度连接到原始输入,其攻击绝大多数情况下能够成功。Wang^[19] 利用快速梯度符号法(FGSM),对基于注意力机制的深度关键词识别模型生成了对抗样本。Schönherr^[20] 利用心理声学原理,基于梯度信息构建了隐蔽性良好的对抗样本,实现了目标攻击。Qin^[21] 同样利用了心理声学原理和梯度信息实现了目标攻击,与 Schönherr^[20] 不同的是,Qin^[21] 构建的对抗样本具有更好的隐蔽性和更强的鲁棒性。Yakura^[22] 在对抗样本生成过程中引入了脉冲响应和高斯白噪声,提高了生成的对抗样本对回声和环境噪声的鲁棒性。而这些攻击的方法均在已知模型结构前提下展开攻击,属于白盒攻击。

在黑盒攻击方面,Alzantot^[23] 已经证明,实现针对自动语音识别系统的黑盒目标攻击是可行的。Zhang^[24] 通过调制超声波载波的命令并利用麦克风的漏洞提出了海豚攻击。Du^[25] 提出了 SirenAttack,利用粒子群优化算法,分别在白盒和黑盒设置下成功生成了对抗样本,他们在多种语音识别模型上进行了实验,并取得了较好结果。Khare^[26] 在黑盒设置下使用多目标进化优化的方法对 DeepSpeech^[3] 和 Kaldi-ASR (Automatic Speech Recognition)^[4] 模型进行目标攻击,成功实现黑盒攻击。Gong^[17] 在黑盒设置下,利用强化学习实现了实时对抗攻击,但是只攻击了指令识别模型,实现的是无目标攻击,且存在计算资源消耗大的问题。Abdullah^[27] 使用在语音信号处理阶段加噪声的方法,通过将目标指令隐藏在噪声中实现了黑盒攻击,该方法生成的对抗样本能够使模型识别,而人听起来就像噪声,无法获取对抗样本中隐藏的内容。但现实中,当人听到扬声器传来噪声时,很有可能会引起警觉发现异常,也就是说该方法生成的对抗样本隐蔽性不够高。

针对语音识别系统的攻击,也提出了一些防御方法用于消除攻击带来的影响。这些方法的一个共同特点就是检测收到的信号是否来自于一个正在说话的人。Lei^[28] 提出了一种利用无线信号来检测人体运动的虚拟按钮,只有在检测到人体运动时才能接受语音命令。Feng^[29] 提出了 VAuth (Vee-Auth),这是第一个为语音助手提供连续和可用身份验证的系统。通过可穿戴设备采集用户的体表振动,并将其与语音助手的麦克风接收到的语音信号相匹配,以此来验证语音命令是用户发出的。然而,这些方法都是有限的,因为语音命令不

一定伴随可检测的运动,可穿戴设备(例如眼镜)也不方便。Zhang^[24]提出了利用超声波和麦克风漏洞攻击的方法,同时也提出了相应的防御方法,利用一种能抑制超声载体信号的增强型麦克风来防御。在对抗性声学系统的防御方面,Szegedy^[2]提出了对抗训练,Wang^[24]利用生成的对抗样本和原样本对关键词识别模型进行重训练,提高了模型的鲁棒性,但对抗训练的局限性在于,经过重训练的模型可实现相应攻击的防御,在实际中,攻击者可以更改参数来绕过防御。Du^[24]提出了滑动平均滤波的防御方法,即把某个采样点的前 $K-1$ 个和后 $K-1$ 个采样点作为参考点,用参考点的平均值代替这个采样点的方式进行防御,具有一定的防御效果。针对语音识别系统的防御研究,本文提出了两种防御对抗攻击的策略,尝试实现语音识别模型的防御。

2.3 群优化搜索算法

智能优化算法如遗传算法^[24]、蚁群算法^[24]、粒子群算法^[24]、布谷鸟搜索算法^[24]等,通过模拟生物的行为或自然界的现象求解目标优化问题。

布谷鸟搜索算法是 Yang^[24]提出的一种模仿自然界中布谷鸟育雏行为的启发式算法。布谷鸟本身不筑巢、不孵卵、不育雏,而是通过将卵产在其他鸟(宿主)的鸟巢中,由宿主代为主孵化和育雏的方式进行繁衍。布谷鸟趁宿主外出时将自己的卵产入宿主的鸟巢中。为了不被宿主察觉,布谷鸟在产卵之前会把宿主鸟巢中的一枚或多枚卵移走,来保持鸟巢中原有的卵数量。一旦布谷鸟的寄生卵被发现,这个卵便会被宿主移走或者宿主丢弃这个鸟巢去建立新的鸟巢,布谷鸟寄生繁殖失败。

布谷鸟通过莱维飞行搜寻鸟巢。莱维飞行属于随机行走的一种,行走的步长满足一个重尾的稳定分布,在这种形式的行走中,高频率的短距离飞行和低频率的长距离飞行相间。

由于布谷鸟搜索算法的操作简单、收敛速度快、具有较强的空间搜索能力,因而本文选用布谷鸟搜索算法优化扰动,生成对抗样本。在实际寻优过程中,鸟巢就是解,鸟巢的数量作为种群大小,根据具体优化问题而设定,通过莱维飞行更新鸟巢位置。宿主以一定的概率 P_a 发现异常卵,在实际问题中则以概率 P_a 剔除适应度低的解。

3 基于布谷鸟搜索算法的黑盒对抗攻击方法

本文提出基于布谷鸟搜索算法的对抗攻击方法,输入原始音频样本,通过布谷鸟搜索算法寻找近似最优对抗扰动,并生成相应的对抗样本,样本的攻击效果通过输入目标模型(DeepSpeech)判定其输出结果作出评价,最终将搜索得到的最优解输出,即为有效对抗样本,其系统框架如图1所示。

本文利用布谷鸟搜索算法优化扰动生成对抗样本。首先,原始音频复制至设定鸟巢数量后通过添加随机噪声扩大鸟巢之间的差异形成初步解;其次,通过莱维飞行产生新解,通过适应度函数,比较新旧解的优劣,更新鸟巢。在优化过程中,发现当适应度函数值低于一定值时,布谷鸟算法不再高效,因此设定阈值 ψ 。当适应度函数值小于阈值 ψ 时,在布谷鸟算法的基础上添加变异操作,扩大搜索范围。最后,判断对抗样本是否识别为目标短语或达到最大迭代次数,若未产生对抗样本

并未达到最大迭代次数,继续迭代优化对抗样本。




图1 系统框架

Fig. 1 System block diagram

3.1 鸟巢初始化

将原始音频复制至设定鸟巢数量,由于复制后的各个解之间不存在差异,无法确定最优解,因此不能直接通过布谷鸟搜索算法优化。通过添加随机噪声的方法扩大各个鸟巢之间的差异性,完成初始化。例如:DeepSpeech模型的输入为采样率为16kHz的音频文件,恢复为模拟信号后的音频文件的最高频率为8kHz。根据Reichenbach^[24]的研究表明,人耳对低频比高频更敏感,因此对噪声使用截止频率 $f_{cutoff} = 7\text{kHz}$ 的高通滤波器,将噪声限制在高频范围内,使人耳更难察觉。初始化后的鸟巢通过适应度函数进行评分,确定初始种群的最优解,并记录最优适应度值。

3.2 适应度函数

连结主义时间分类(CTC)是Graves^[24]提出的一种端到端的循环神经网络(RNN)训练方法。传统的语音识别模型中,对语音模型进行训练之前,需将文本与语音进行严格对齐,即需要将每一帧对应到标签,而CTC不需要对齐语音和文本。CTC的损失函数 $CTCLoss$ 可以解释为给定样本后输出正确label的概率之和。本文使用 $CTCLoss$ 作为适应度函数 $F_{CTCLoss}(x)$,一方面得益于CTC不要求对齐,另一方面是 $CTCLoss$ 可较好衡量对抗样本与目标短语之间的接近程度。

假定 x 为DeepSpeech的输入,其输出序列 π 为可能解码为对应文本 T 的序列,定义集合 $Z = (a, z) \cup () \cup (-)$,其中“ $-$ ”表示空格,“-”为CTC引入的特殊字符,这个字符可以避免CTC解码器在解码过程中删除序列 π 中可以解码为对应文本的字符,其中 $\pi \in Z$ 。

DeepSpeech模型定义为 $y = F(x)$,其中 $x \in X$,为输入音频 X 的某一帧,其输出 y 为字符的概率分布,由此概率分布可以确定输出序列为 π 的概率。对于输入 X ,CTC解码器在解

码时,对序列 π 进行移除相邻重复字母和移除特殊字符“-”的操作.例如对输入为 10 帧的音频 X ,若其对应文本 T 为“apple”,则对序列 π_1 —“aappp-ple”与序列 π_2 —“ap-p-l-eee”进行移除相邻重复字母和特殊字符的操作,则序列 π_1 和 π_2 均可解码为“apple”.因此对于一个输入音频 X ,其输出预测序列 π 是不唯一的.因此在输入 X 下,其输出为序列 π 的概率为:

$$P(\pi|y) = \prod_i y_{\pi}^i \quad (1)$$

其中, y_{π}^i 表示序列 π 中第 i 个字母的概率.由此可以定义在输入 X 下,输出为对应文本 T 的概率为:

$$P(T|y) = \sum_{\pi \in \Pi(t,y)} P(\pi|y) = \sum_{\pi \in \Pi(t,y)} \prod_i y_{\pi}^i \quad (2)$$

而 $CTCLoss$ 定义如下:

$$CTCLoss(f(x), T) = -\log P(T|f(x)) \quad (3)$$

可以发现,在模型训练时,当解码为 T 的概率 $P(T|f(x))$ 越大, $CTCLoss$ 越小,由此本文定义适应度函数 $F_{CTCLoss}(x)$ 如下:

$$F_{CTCLoss}(x) = -CTCLoss(f(x), t) \quad (4)$$

其中, t 为设置的目标短语,可见,当对抗样本解码为目标短语 t 的概率越大, $F_{CTCLoss}(x)$ 越大,则评分越高.

3.3 布谷鸟搜索算法实现

布谷鸟搜索算法通过莱维飞行机制和随机游走寻找鸟巢,莱维飞行是一种由小步长的短距离飞行和偶尔大步长的长距离飞行组成的随机游过程,因此布谷鸟搜索的寻窝路径容易在不同的搜索区域间跳跃,导致布谷鸟搜索算法的局部精细搜索能力较差,在算法迭代后期容易在全局最优解附近的区域出现震荡现象,造成算法效率偏低.因此本文在达到一定条件后,在布谷鸟搜索算法中加入变异操作,提高算法寻找最优解的效率.

3.3.1 莱维飞行

在自然界中,布谷鸟搜索以随机或者类似随机的飞行方式来寻找适合自己产卵的鸟巢位置,为了便于模拟布谷鸟搜索的繁殖策略,Yang 等^[8]将布谷鸟搜索算法假设为以下三个理想状态:

- 1) 每只布谷鸟搜索一次只产一个卵,并随机选择一个位置的鸟巢进行孵化.
- 2) 在随机选择的一组鸟巢中,优质的鸟巢将会被保留到下一代.
- 3) 可利用的鸟巢数量固定,宿主鸟发现外来鸟蛋的概率为 $Pa \in [0, 1]$.当宿主鸟发现外来的布谷鸟蛋的时候,它会将布谷鸟蛋丢弃或者重新建立新的鸟巢.

基于以上三个理想状态,使用 Mentegna 算法^[8]实现莱维飞行.莱维飞行更新如下:

$$X_i^{t+1} = X_i^t + \alpha * S * n \quad (5)$$

其中, X_i^t 是旧解, X_i^{t+1} 是新解, α 是步长缩放因子, n 是与 X_i^t 维数相同的,由标准正态分布的随机数组成的数组. S 为步长:

$$S = \frac{u}{|v|^{\frac{1}{\beta}}}, u \sim N(0, \sigma^2), v \sim N(0, 1) \quad (6)$$

其中, u, v 是两个服从高斯分布的变量, β 是常数,其值由

具体问题决定, σ^2 由公式(7)计算:

$$\sigma^2 = \left[\frac{\Gamma(1+\beta) \sin(\frac{\pi\beta}{2})}{\beta \Gamma(\frac{1+\beta}{2}) 2^{\frac{\beta-1}{2}}} \right]^{\frac{1}{\beta}} \quad (7)$$

其中 $\Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt (x > 0)$ 是伽马函数.

利用莱维飞行,对除最优鸟巢以外的鸟巢的位置和状态进行更新,产生新鸟巢.比较每个新鸟巢与旧鸟巢的适应度,将旧鸟巢中适应度差的解替换为新鸟巢中适应度优的解,并找出当前种群中适应度最优的鸟巢,保存至下一代.

3.3.2 局部随机游走

局部随机游走定义为宿主鸟以一定的概率 Pa 发现外来鸟后重新建窝的路径.产生的鸟窝的位置采用偏好随机游动的方式,即利用了其它鸟窝的相似性.新建的鸟窝的位置公式定义如下:

$$X_{i+1} = X_i + \gamma * Heaviside(Pa - \varepsilon) * (X_i - X_j) \quad (8)$$

其中, γ 和 ε 是服从均匀分布的随机数,相互独立, $Heaviside(x)$ 是跳跃函数, X_i, X_j 是其它任意的两个鸟巢.局部随机游走产生的新鸟巢同样需要与旧鸟巢比较,将旧鸟巢中适应度低的解替换为新鸟巢中适应度高的解,并记录当前种群中适应度函数最优的鸟巢,保存至下一代.

3.4 变异

当 $CTCLoss$ 减小到一定范围时,对抗样本接近目标扰动,此时的莱维飞行由于种群个体太过相似而容易陷入局部最优,无法产生更优解.因此,本文设计了变异操作拓展搜索空间,提高搜索效率.通过对所有解添加随机噪声的方式进行变异,同时,这个噪声会通过一个截止频率为 $f_{cutoff} = 7\text{kHz}$ 的高通滤波器,将噪音限制在高频范围内.若变异操作产生比原来解中更优的解,通过替换旧解更新鸟巢,最优解将会被保留到下一代.变异算法在增加种群的多样性的同时,用变异概率限制或扩大变异的程度.若变异概率太低,可能产生不了新的更好的最优解,而变异概率过大,可能会错过最优解.因此设置了动量更新公式更新突变概率:

$$p_{new} = \mu * p_{old} + \frac{\gamma}{|currScore - preScore|} \quad (9)$$

其中, p_{old} 表示种群原来的突变率, p_{new} 表示种群新的突变率, $currScore$ 表示当前种群的得分, $preScore$ 表示上一代种群的得分. μ 和 γ 是相关系数, μ 值越大,新的突变率 p_{new} 越接近 p_{old} ; γ 越大, p_{new} 变化的范围越大. μ 的取值应比较大, γ 应较小,这是为了控制 p_{new} 的变化幅度,若变化幅度太大,可能会使原有解的较好形态的消失.动量更新增加了突变概率的加速度,当种群优化停滞时,通过保持高的突变概率,使得突变的部位累积并随迭代次数而相加.变异操作将增加种群的多样性,与莱维飞行结合,将更加高效的获得最优解.

3.5 算法基本流程

布谷鸟搜索算法

输入: 原始音频 X , 目标短语 t , 迭代次数 itr , 最大迭代次数 Max

输出: 对抗样本 X_{adv}

初始化鸟巢: 产生 n 个寄主鸟巢,添加噪声扩大差异,形成初始解 X_n

计算初始鸟巢最优适应度值 F_{best} , 确定最优解 X_{best}

while (itr < Max) or Decode(X_{best}) ! = t do

莱维飞行产生新解 X'_n

比较新旧解适应度值 F'_n, F_n

if $F'_i > F_i (i = 1 \cdots n)$

$X_i = X'_i$

If $F'_{best} > F_{best}$

$X_{best} = X'_{best}$

以概率 Pa 丢弃旧解, 产生新解 X''_n

if $F''_i > F_i (i = 1 \cdots n)$

$X_i = X''_i$

if $F''_{best} > F_{best}$

$X_{best} = X''_{best}$

if $CTCLoss < \psi$

加入变异操作

end while

return $X_{adv} = X_{best}$

4 实验与结果分析

4.1 数据集

为验证本文方法的有效性,在四个数据集上展开实验,包括:公共语音数据集¹,谷歌语音命令数据集²,GTZAN 音乐数据集³和 LibriSpeech 数据集⁴。其中,公共语音数据集是 Mozilla 开源的大型语音数据集,它由用户朗读来自于博客,书籍,电影等多个公共信息源的文本收集而成。它拥有超过 500 小时的样本,大约有 20000 名志愿者提供了 40000 多份样本。谷歌语音命令数据集是由谷歌的 TensorFlow 团队创建的语音数据集。该数据集包含 30 种短单词的命令,总共有 65000 个时长为 1 秒的,只包含一个单词的命令语音。GTZAN 音乐数据集包含了 10 种音乐风格的总量为 1000 个的 30 秒长的音乐片段。LibriSpeech 语音数据集包含了 1000 小时采样率为 16kHz 的有声录音,并且经过切割和整理成每条 10 秒左右的、经过文本标注的音频文件。

4.2 评价指标

为了确定对抗样本和原始样本之间的扰动大小,引入了分贝(dB)。用分贝来衡量单个音频样本的相对强度:

$$dB(X) = \max(20 \log_{10} X) \quad (10)$$

其中, X 表示输入音频。在本次实验中,在 dB 级别上,将生成的对抗样本 X_{adv} 和原始音频 X 比较,以此确定相对扰动的强度:

$$dB_X(X_{adv}) = |dB(X_{adv}) - dB(X)| \quad (11)$$

为了比较生成的对抗样本和原音频的相似度,引入了皮尔逊相关系数来衡量对抗样本和原音频的相似度,皮尔逊相关系数公式如下:

$$\rho_{X,Y} = \text{corr}(X,Y) = \frac{\text{cov}(X,Y)}{\delta_X \delta_Y} \quad (12)$$

其中 $\text{cov}(X,Y)$ 是矩阵 X,Y 的协方差, δ_X, δ_Y 分别表示矩阵 X,Y 的标准差。

为了比较生成样本的解码结果与目标短语的差距,引入了编辑距离。编辑距离是用来度量两个序列相似程度的指标,指的是在两个序列 $\langle w_1, w_2 \rangle$ 之间,由其中一个序列 w_1 转换为另外一个序列 w_2 所需的最少单字符编辑操作次数。单字符编辑操作有且仅有三种:插入,删除,替换。

4.3 目标模型

本文设计攻击的目标模型为百度的 DeepSpeech 模型⁵。DeepSpeech 是一个开源的基于 CTC 的端到端深度语音识别模型⁵,其核心是一个循环神经网络(RNN),由五层隐藏单元组成。如图 2 所示,网络的前三层不是循环神经元,第一层的输出取决于每个时间的输入 x_t 以及 x_t 左右相邻的 C 帧音频,第二、三层的输入为前一层的输出,对于每一时间步,前 3 层可以计算为:

$$h_t^{(l)} = g(W^{(l)} h_t^{(l-1)} + b^{(l)}) \quad (13)$$

其中 $g(z) = \min\{\max\{0, z\}, 20\}$, 是 ReLu 激活函数, $h_t^{(l)}$ 表示 t 时刻,第 l 层的输出, $l = \{1, 2, 3\}$, h_t^0 表示输入层, $W^{(l)}$ 和 $b^{(l)}$ 分别表示第 l 层的权重矩阵和偏置参数。

第四层是双向递归层,这一层有两类神经元,一类是前向递归 $h_t^{(f)}$,另一类是后向递归 $h_t^{(b)}$:

$$h_t^{(f)} = g(W^{(4)} h_t^{(3)} + W_r^{(f)} h_{t-1}^{(f)} + b^{(4)}) \quad (14)$$

$$h_t^{(b)} = g(W^{(4)} h_t^{(3)} + W_r^{(b)} h_{t+1}^{(b)} + b^{(4)}) \quad (15)$$

若输入音频的总帧数为 T,则 $h_t^{(f)}$ 必须从 t = 1 到 t = T 依次计算,同时 $h_t^{(b)}$ 神经元从 t = T 到 t = 1 反向依次计算。

第五层将第四层中的前向和后向单元的输出作为输入:

$$h_t^{(5)} = g(W^{(5)} h_t^{(4)} + b^{(5)}) \quad (16)$$

其中 $h_t^{(4)} = h_t^{(f)} + h_t^{(b)}$, 输出层是 Softmax 层,它的输出是当前 t 时刻字符 k 的预测概率:

$$h_{t,k}^{(6)} = \hat{y}_{t,k} = P(c_t = k | x) = \frac{\exp(W_k^{(6)} h_t^{(5)} + b_k^{(6)})}{\sum_j \exp(W_j^{(6)} h_t^{(5)} + b_j^{(6)})} \quad (17)$$

其中 $W_k^{(6)}$ 和 $b_k^{(6)}$ 分别表示权重矩阵的第 k 列和第 k 个偏置。

模型通过 CTCLoss 计算预测误差。DeepSpeech 使用 Switchboard(SWB)数据集和 Fisher(FSH)数据集进行训练,数据集总时长为 2300 小时。模型通过数据并行和模型并行的方式训练,能在数小时内完成 2300 小时的音频数据的训练,并在 300 小时的 Switchboard 的数据集上进行了评价,在 Hub500S 数据集上进行了测试。实验结果表明在使用可比较的数据量进行训练时,DeepSpeech 与现有最佳 ASR 系统相比具有竞争力⁵。另外 DeepSpeech 向 Wall Street Journal(WSJ)数据集,Switchboard(SWB)数据集, Fisher(FSH)数据集和 Baidu 数据集加入噪声,将加入噪声后的数据集对模型进行训练,并将所有数据重新采样到 16khz,数据集总时长超过 10 万小时。DeepSpeech 的测试结果表明,其在噪音环境下的识别率优于 Bing, Apple 等语音识别系统⁵。

¹ <https://voice.mozilla.org/zh-CN/datasets>

² http://download.tensorflow.org/data/speech_commands_v0.01.tar.gz

³ <http://marsyas.info/downloads/datasets.html>

⁴ <http://www.openslr.org/12/>

⁵ https://github.com/carlini/audio_adversarial_examples

4.4 攻击的有效性实验结果分析

为了验证本文提出的基于布谷鸟搜索算法的黑盒攻击的有效性,在上述数据集上进行了语音的黑盒攻击. 初始化 40




图 2 DeepSpeech 模型结构

Fig. 2 DeepSpeech model structure

个鸟巢,最大迭代次数设为 3000,参数 β 设为 2. 当 $CTCLoss$ 大于 55 时,采用布谷鸟搜索算法优化扰动. 当 $CTCLoss$ 小于 55 时,在布谷鸟算法的基础上加入变异操作,变异率设为 0.005. 对于公共语音数据集和 LibriSpeech 数据集,分别从中随机挑选 50 个训练样本生成对抗样本. 对于谷歌语音命令数据集,随机挑选 5 个指令,在每个指令中随机挑选 10 条作为训练样本. 对于 GTZAN 数据集,随机从 5 种风格的音乐样本中随机挑选 10 条,截取为 5 秒后作为训练样本. 由于 DeepSpeech 模型的输入为采样率为 16kHz 的 wav 文件,因此将所选音频样转化为采样率为 16kHz 的 wav 格式的音频文件. 对于从每个数据集中随机选出的 50 条样本,随机以 10 个音频

文件为 1 组,分成 5 组,共 20 组,分别设置不同的目标短语. 为了模拟自动驾驶时的场景,对于从公共语音数据集,GTZAN 音乐数据集和 LibriSpeech 语音数据集选出的 15 组样本,将目标短语设置为“turn left”,“turn right”,“speed up”等自动驾驶时常用的短语. 若在自动驾驶时,语音识别系统将“stop”识别为“go”,这很有可能带来巨大风险,考虑到这个场景,将谷歌语音命令数据集的目标短语设置为与其相反的短语,如音频的对应文本为“on”,则目标短语设置为“off”. 另外,分别从 4 个数据集中,随机挑选 2 个音频文件作为样本,每个样本随机设置 10 条不同的目标短语,分析攻击效果. 根据上述 4 个语音数据集的实验结果分析本文攻击方法的有效性.

定义攻击成功,当生成的对抗样本被识别为目标短语,则视为攻击成功,否则失败. 表 1 列出了在各个数据集上的攻击成功率,扰动的相对强度的平均值和对抗样本与原音频相似度的平均值. 对比公共语音数据集,谷歌语音命令数据集和 LibriSpeech 数据集的结果可以发现,样本词长度越长,攻击的成功率越低,所添加的扰动越大,对抗样本与原音频的相似度越小. 而对谷歌语音命令数据集的高攻击成功率可以反映出在自动驾驶领域,使简单的指令误识别为目标指令是相对容易的,对自动驾驶领域的语音控制系统的攻击是存在较大可能性的. 从扰动相对强度和平均相似度上可以发现,所添加扰动的相对强度小,对抗样本与原音频有着较高的相似度. 对于 GTZAN 音乐数据集的成功攻击反映出可以将目标短语嵌入到音乐中,而由于音乐能够使人放松等特性,所加的噪声将更难被发现.

表 1 基于布谷鸟算法的黑盒攻击方法在不同数据集上的攻击情况

Table 1 Black-box attack based on cuckoo algorithm on different data sets

数据集	样本平均词长	目标短语平均词长	攻击效果		
			成功率	相对扰动强度(dB)	平均相似度
公共语音数据集	5.48	2.8	51.43%	0.184	93.07%
谷歌语音命令数据集	1.00	1	88.57%	0.108	95.07%
GTZAN 数据集	/	3.6	45.71%	0.254	96.16%
LibriSpeech 数据集	8.06	2	35.71%	0.245	94.12%

本文比较了布谷鸟搜索算法与 Taori^[43] 提出的遗传算法的攻击成功率,平均编辑距离和平均相似度. 从上述 4 个数据集中,每个数据集随机挑选 50 条音频作为样本,将目标短语设置为 1000 个最常用英语短语中词长度为 2 的短语,每个样本迭代 3000 代,分别用遗传算法和布谷鸟搜索算法生成对抗样本. 如表 2 所示,本文提出的布谷鸟搜索算法的攻击成功率和平均编辑距离要优于遗传算法,但布谷鸟搜索算法生成的对抗样本在平均相似度上低于遗传算法. 布谷鸟搜索算法的核心是莱维飞行和局部随机游走,而遗传算法的核心是种群间的交叉变异. 相比于布谷鸟搜索算法,遗传算法的种群间的交叉变异可以把添加的扰动限制在更小的范围内. 但通过莱维飞行和局部随机游走,布谷鸟搜索算法可以搜索更大的空间,因此布谷鸟搜索算法的攻击成功率要高于遗传算法,但由于添加的扰动比遗传算法大,因此平均相似度要略低于遗传算法.

为进一步分析对抗样本与原样本之间的相似性,本文在

每个数据集上,成功生成的对抗样本中,随机选取 4 条样本进行比较,并将原始波形和对抗样本波形叠加以可视化扰动. 表 3 列出了所选的样本的对应文本,目标短语,扰动相对强度等结果,为了比较所加的噪声对原音频的影响,将表 3 的结果用波形图的形式呈现,如图 3 ~ 图 6 所示. 其中,表 3 中的音频文件的命名只是为了与图 3 ~ 图 6 中的波形图对应,与样本的选择无关. 如图 3 ~ 图 6 所示,其中浅色波形表示原音频,深色波形表示对抗样本,将原音频与对抗样本叠加后进行比较. 首先,从图 3 ~ 图 6 可以发现所有扰动几乎都加在原音频波形幅值较小的位置,而这个部分通常被视为环境噪声,这使所加扰动不易被发现. 其次,从图中可以发现,在音频的语音部分,所加的扰动很小,因此此攻击方法对音频的语音部分的影响小,隐蔽性高. 从图 5 可以发现,对于 GTZAN 音乐数据集,所添加的扰动在各个位置的幅值都很小,这说明该攻击方法对 GTZAN 音乐数据集的改动小,把指令嵌入到音乐中有极高的隐蔽性.

表 2 布谷鸟搜索算法与遗传算法比较

Table 2 Comparison of cuckoo search algorithms and genetic algorithms

数据集	攻击方法	成功率	平均相似度	平均编辑距离
公共语音数据集	布谷鸟搜索算法	45%	93.07%	1.6
	遗传算法	35%	94.6%	2.3
谷歌语音命令数据集	布谷鸟搜索算法	92%	94.86%	0.12
	遗传算法	92%	99.07%	0.08
GTZAN 数据集	布谷鸟搜索算法	48%	96.75%	1
	遗传算法	48%	99.16%	1.26
LibriSpeech 语音数据集	布谷鸟搜索算法	34%	92.84%	10.1
	遗传算法	32%	93.45%	10.32

表 3 原始音频与对抗样本相似度比较

Table 3 Similarity comparison between original audio and adversarial examples

数据集	音频文件	对抗样本	原音频对应文本	目标短语	扰动相对强度	相似度
公共语音数据集	1. wav	1adv. wav	then I saw the way.	start the engine	0.1036	0.9143
	2. wav	2adv. wav	she half closed her eyes.		0.2197	0.9575
	3. wav	3-1adv. wav	no one notice her	no one like her	0.0361	0.9569
		3-2adv. wav		turn left	0.1291	0.9366
谷歌语音命令数据集	4. wav	4adv. wav	no	go	0.0131	0.9961
	5. wav	5adv. wav	off		0.0142	0.9924
	6. wav	6-1adv. wav	off	yes	0.0192	0.9945
		6-2adv. wav		ok	0.0126	0.9984
GTZAN 语音数据集	7. wav	7adv. wav	/	turn off the air conditioner	0.0341	0.9983
	8. wav	8adv. wav	/		0.1296	0.9936
	9. wav	9-1adv. wav	/	slow down	0.0642	0.9647
		9-2adv. wav		no one see her	0.0289	0.9986
LibriSpeech 数据集	10. wav	10adv. wav	comfortable dear	turn left	0.1516	0.9721
	11. wav	11adv. wav	very characteristic perfectly tyfical		0.2531	0.9183
	12. wav	12-1adv. wav	yes not at all well	not all bed	0.0733	0.9919
		12-2adv. wav		thank you	0.0859	0.9869




图 3 公共语音数据集的音频文件与相应的对抗样本的波形比较

Fig. 3 Waveform comparison between audio files of public voice data Set and corresponding adversarial examples




图 4 谷歌语音命令数据集的音频文件与相应的对抗样本的波形比较

Fig. 4 Waveform comparison between audio files of Google voice command data set and corresponding adversarial examples




图5 GTZAN 音数据集的音频文件与相应的对抗样本的波形比较

Fig.5 Waveform comparison between audio files of GTZAN audio data set and corresponding adversarial examples




图6 LibriSpeech 语音数据集的音频文件与相应的对抗样本的波形比较

Fig.6 Waveform comparison between audio files of LibriSpeech voice dataset and corresponding adversarial examples

进一步把在 4 个数据集上生成的对抗样本的识别结果与目标短语进行比较,用编辑距离衡量对抗样本与目标短语间的差距。如图 7 所示,可以发现大部分样本分布在编辑距离较小的这一侧,说明即使攻击失败,但对抗样本已经十分接近目标短语,只有少部分对抗样本与目标短语相差很远,若增加迭代次数,攻击的成功率将会更高。




图7 3000 次迭代后样本的编辑距离所占的比例

Fig.7 Proportion of levenshtein distance of example after 3000 iterations

本文进一步在谷歌语音命令数据集上的命令做相互转换。随机选出 10 种指令,在每种指令中都随机挑选 10 条作为原始音频,将原始音频的目标短语依次设置为其他 9 种指令。图 8 比较的是在谷歌语音命令数据集上做命令相互转换后的结果。由于语音命令是单个单词,目标短语的长度也是单个单词,与在另外三个语音数据集上的攻击相比,攻击的难度降低。可以发现不同的语音指令之间进行对抗攻击的成功率很高。从现实角度看,在自动驾驶领域,这也说明语音识别控制系统是存在漏洞的。如简单的“Stop”在加入扰动后就能被识

别为“Go”,这将导致汽车识别错误的指令,造成危险。

4.5 参数敏感性

本文对布谷鸟搜索算法的关键参数鸟巢个数 n 和参数 β 进行研究,分别分析两个参数对对抗样本的影响,通过参数敏感性分析算法的稳定性。




图8 谷歌语音命令数据集实验结果

Fig.8 Experimental results of google voice command data set

4.5.1 鸟巢个数对抗样本生成时间与相似度的影响

为了研究鸟巢个数对抗样本生成时间以及对抗样本与原音频相似度的影响,在不同的鸟巢个数下生成对抗样本。从上述四个数据集中,每个数据集随机挑选 5 条音频作为样本,在不同的鸟巢个数下生成对抗样本,统计在不同鸟巢个数下生成对抗样本的平均时间和平均相似度。实验结果如图 9 所示,对抗样本的平均生成时间随着鸟巢个数的增加而增加,因为鸟巢个数越大,计算机需要处理的数据越多,生成对抗样本的时间会越长。鸟巢个数与平均相似度间没有明显的关系,但是注意到鸟巢个数设定为 40 时,平均相似度达到最大值。

4.5.2 β 值对相似度的影响

为了比较 β 值对对抗样本相似度的影响,在不同的 β 值设置下,生成对抗样本.从上述 4 个数据集中,每个数据集随机挑选 5 条音频作为样本,在不同的 β 值设置下生成对抗样本.迭代次数设置为 500,使生成的样本不能完全被解码为目




图9 鸟巢个数实验结果

Fig. 9 Experimental results of the number of bird nests

标短语.迭代次数设置较大时,对抗样本可以成功生成,成功生成的对抗样本间的迭代次数可能不同,所加的扰动大小会存在较大差异.为了只比较 β 对对抗样本的影响,将迭代次数设为 500,排除迭代次数不同而带来的差异.从图 10 可以发现,当 $\beta < 1.8$ 时,对抗样本与原音频间的相似度很低. β 与莱维飞行的步长有关,其值越小,步长越大,对原音频加的噪声就会越大.一方面过大的噪声使对抗样本不具有隐蔽性,另一方面添加的噪声过大会造成模型无法识别音频,导致攻击失败. $\beta = 2$ 时,步长很小,对原音频添加的扰动就小,对抗样本与原音频的相似度就高.




图10 β 值实验结果

Fig. 10 Experimental results of β value

4.6 攻击的迁移性

本文提出的基于布谷鸟搜索算法的黑盒攻击生成的对抗样本具有攻击的迁移性.分别从公共语音数据集,LibriSpeech 语音数据集,谷歌语音命令数据集和 GTZAN 数据集中随机挑选 50 条音频作为训练样本,对于 GTZAN 音乐数据集,对于每个样本,截取其中的 5 秒作为训练样本.在 DeepSpeech 上生成对抗样本.选取用来做攻击的迁移性的语音识别模型为 2016 年,主要由 Google 的 Deepmind 团队推出的一种用于生成音频的深度神经网络,WaveNet 模型^[9]. WaveNet 模型的主要成分是因果卷积,它利用卷积来学习 t 时刻之前的输入数据,预测 $t+1$ 时刻的输出.虽然该模型是作为一种生成模

型设计的,但通过在扩展后的卷积层之后添加平均池层,它可以直接适应诸如语音识别等区别于生成音频的任务.将原音频输入 WaveNet 模型,计算对原音频的识别率.由于对抗样本是对 DeepSpeech 模型进行攻击生成的,因此只在 WaveNet 上统计对抗样本的识别率.对于识别率,定义如下:

$$\text{识别率} = \frac{\text{正确识别的字符数}}{\text{总字符数}} \quad (18)$$

只要 WaveNet 识别的对抗样本与原音频识别结果不同,就视为迁移成功.则迁移成功率:

$$\text{迁移成功率} = \frac{\text{迁移成功的样本数}}{\text{总样本数}} \quad (19)$$

表 4 是本文提出的基于布谷鸟搜索算法的黑盒攻击生成的对抗样本的迁移性实验结果.从表 4 可以看出,WaveNet 模型对对抗样本的识别率相比原音频的识别率下降了一半以上,而极高的迁移成功率说明了本文提出的黑盒攻击方法产生的对抗样本能极大的影响其他语音识别模型的识别结果.

表4 对抗样本迁移性实验结果

Table 4 Experiments on migration of adversarial examples

数据集	原音频 识别率	对抗样本 识别率	迁移成功率
公共语音数据集	71.5%	21.9%	100%
谷歌语音命令数据集	78%	14%	92%
GTZAN 数据集	/	/	80%
LibriSpeech 数据集	78.7%	37.84%	98%

4.7 主观评价

为了验证本文提出的基于布谷鸟搜索算法的黑盒攻击生成的对抗样本具有一定的隐蔽性,本文对生成的对抗样本进行了主观评价.从上述 4 个数据集中,每个数据集中随机挑选 5 条音频作为样本,生成对抗样本,共 20 条对抗样本.在进行主观评价的实验中,一共召集了 30 个听众,他们都是浙江工业大学与语音识别领域、对抗攻防领域无关的在读本科生.在安静的教室使用扬声器播放音频,在听完每个音频后,每个听众将会做一些问答(如你听到的音频存在任何的噪声吗;若存在噪声你认为噪声来自哪里).为了更加接近现实环境,首先单独播放了对抗样本,因为一个攻击者对语音识别模型进行攻击时,只会通过对抗样本对模型进行攻击,不会播放原音频,对于听众来说,原音频是接触不到的,因此通过对对抗样本进行主观评价来探究对抗样本的隐蔽性.然后,将对抗样本和原始音频先后播放,打乱播放顺序,即对于对抗样本和原音频,先播放哪一个都是随机的,以此探究对抗样本与原音频在听觉上的差异性.同样的,在听完每对对抗样本和原音频后,每个听众同样会做一些问答(如你听到的前后样本是否有差异;若有差异你认为差异来自哪里).图 11(a) 是对对抗样本进行主观评价的结果;图 11(b) 是在听出对抗样本中存在噪声的听众中,对噪声来自于哪里的主观评价;图 11(c) 是对对抗样本与原音频相似性的主观评价结果.从图 11(a) 中可以发现大部分的听众未从音频中发现噪声,只有 20% 的听众认为音频中有明显噪声;而从图 11(b) 中可以发现在听出噪声的听众中,超过一半的听众认为噪声来自于扬声器;从图 11(c) 中可以发现,认为对抗样本与原音频完全不同的听众低于 15%.由此可以说明基于布谷鸟搜索算法的黑盒攻击生成的

对抗样本不易引起听众的察觉,在听觉上与原音频相差不大,具有一定的隐蔽性.




图 11 对抗样本,对抗样本中的噪声以及对抗样本与原音频相似性的主观评价结果

Fig. 11 Subjective evaluation results of adversarial examples, noise in adversarial examples and similarity between adversarial examples and original audio

5 语音攻击的鲁棒性测试

对于本文提出的基于布谷鸟搜索算法的黑盒攻击生成的对抗样本,尝试找到防御这类对抗攻击的方法.针对扰动的分布特点,采用了两种方法:重采样和降噪.

为了更好的区分攻击是否失效,从公共语音数据集中随机挑选 100 个原始音频样本为大于 6 个词以上的句子,生成对抗样本的目标短语设为 2 个词.将对抗样本音频的识别结果与目标短语结果不一致定为失效,则失效率:

$$\text{失效率} = \frac{\text{失效的样本数}}{\text{总样本数}} \quad (20)$$

将完全失效定义为处理后的对抗样本识别结果的词长度大于 4 且总字母数大于目标短语的总字母数,则完全失效率:

$$\text{完全失效率} = \frac{\text{完全失效的样本数}}{\text{总样本数}} \quad (21)$$

5.1 重采样

从上图 3~图 6 可以发现扰动几乎在音频的每个时刻都会出现.考虑到语音的识别是逐帧进行检测的,具有连续性,通过实验希望验证扰动对于模型的攻击是否是通过持续的干扰起到的作用.对此,对对抗样本进行重采样.

对抗样本的音频格式为采样率 16kHz 的 wav 文件.首先,通过下采样将其降为 8kHz 的音频.下采样是一个将音频的采样率降低的过程,设原始音频格式的采样率为 Q ,目标原始音频的采样率为 P ,则下采样就是对于原始音频中的采样点每隔 $P/Q - 1$ 个取一次点,在本次实验中,每隔一个采样点取一个点.当下采样完成时,与原对抗样本相比,少了一半的采样点.

通过插值法进行上采样,将音频重新通过两个采样点插值的方法重新扩为 16kHz,这是为了符合语音识别模型的要求.重新扩充后的音频文件与原对抗样本相比,虽然每秒采样点数相同,但其中一半的采样点是通过重新插值而成,不再是原来的点.从表 5 中可以发现,重采样的失效率较高,经过重采样后的对抗样本几乎不能被识别为目标短语.但是重采样的完全失效率较低,这说明黑盒攻击虽然失效,但是其长度依然接近于目标短语的长度,也就是说语音识别模型依然把它识别为和目标短语相近的句子.从中可以发现由布谷鸟搜索算法得到的黑盒攻击具有较强的鲁棒性.

5.2 降噪

使用经典的谱减法^[4]对包括扰动在内的所有噪声进行降噪处理.谱减法假设的情况十分简单,如果原音频中只有加性噪声时,用原始音频的频谱减去噪声的频谱,剩下的就是纯粹的语音.将一段音频的前 5 帧视为无语音的背景噪声部分,将这 5 帧的噪声进行取平均值,原音频的各个部位都减去这个平均值.这个方法可以对音频各个时间的噪声都做出相减,在整体上对攻击扰动进行干扰.

表 5 不同防御方法的防御情况

Tabel 5 Defense situation of different defense methods

防御方法	失效率(%)	完全失效率(%)
重采样	94%	23%
降噪	100%	100%

表 5 是降噪下对抗样本的失效率和完全失效率.从结果来看,降噪法比重采样法对于对抗样本的防御效果更强.因为相比于重采样,降噪方法在整段音频的各个位置上都做了处理,都减去了估计的噪声.但是降噪法的不足在于对噪声的估计是基于前几帧估计的,这些噪声的估计不足以表征各个位置所加噪声的准确值.在整段音频中,有些位置的噪声去除的多了,有些位置未完全去除,这会造成原音频的失真,去噪后的识别结果也变的不理想.

6 总结

本文提出了面向语音识别系统的黑盒对抗攻击方法,从实验结果来看,本文提出的基于布谷鸟搜索算法的黑盒攻击方法能够攻击语音识别系统,所产生的对抗样本具有攻击的迁移性.在实际应用中,如果攻击者针对某一车载语音识别系统进行攻击,所产生的对抗样本会影响其他车载语音识别系统,这给车载语音识别系统带来了安全隐患.针对这一问题,提出了两个防御方法,并取得了一定的效果.我们希望本次设计的攻击以及防御方法可以帮助研究者改善这方面的风险,提高车载语音识别系统的安全性.但是我们的攻击方法存在着对抗样本生成时间较长,攻击的精度不够高,对于对抗样本的隐蔽性还有提高的空间等问题.所以在接下来的工作中,我们将测试更多语音识别模型,优化训练方法,提高攻击的效率和精度,进一步提高对抗样本的隐蔽性.我们也希望找到这种

攻击方法的弱点,提出相应的防御方案,提高车载语音识别系统的安全性。

References:

- [1] Rodríguez E, Ruíz B, García-Crespo Á, et al. Speech/speaker recognition using a HMM/GMM hybrid model [C] //International Conference on Audio and Video-Based Biometric Person Authentication, Springer, Berlin, Heidelberg, 1997: 227-234.
- [2] Hannun A, Case C, Casper J, et al. DeepSpeech: scaling up end-to-end speech recognition [J]. Computer Science, 2014, 37(12): 1-42.
- [3] Amodei D, Ananthanarayanan S, Anubhai R, et al. DeepSpeech2: end-to-end speech recognition in english and mandarin [C] //International Conference on Machine Learning, 2016: 173-182.
- [4] Povey D, Ghoshal A, Boulianne G, et al. The Kaldi speech recognition toolkit [C] //IEEE 2011 Workshop on Automatic Speech Recognition and Understanding, IEEE Signal Processing Society, 2011.
- [5] Oord A, Dieleman S, Zen H, et al. WaveNet: a generative model for raw audio [J]. arXiv preprint arXiv: 1609.03499, 2016.
- [6] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples [J]. arXiv preprint arXiv: 1412.6572, 2014.
- [7] Szegedy C, Zaremba W, Sutskever I, et al. Intriguing properties of neural networks [J]. arXiv preprint arXiv: 1312.6199, 2013.
- [8] Carlini N, Wagner D. Audio adversarial examples: targeted attacks on speech-to-text [C] //2018 IEEE Security and Privacy Workshops(SPW), IEEE, 2018: 1-7.
- [9] Cisse M, Adi Y, Neverova N, et al. Houdini: fooling deep structured prediction models [J]. arXiv preprint arXiv: 1707.05373, 2017.
- [10] Iter D, Huang J, Jermann M. Generating adversarial examples for speech recognition [R]. Stanford Technical Report, 2017.
- [11] Baum L E, Petrie T, Soules G, et al. A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains [J]. The Annals of Mathematical Statistics, 1970, 41(1): 164-171.
- [12] Macherey W, Haferkamp L, Schlüter R, et al. Investigations on error minimizing training criteria for discriminative training in automatic speech recognition [C] //Ninth European Conference on Speech Communication and Technology, 2005.
- [13] Zheng J, Stolcke A. Improved discriminative training using phone lattices [C] //Ninth European Conference on Speech Communication and Technology, 2005.
- [14] Wu Y J, Wang R H. Minimum generation error training for HMM-based speech synthesis [C] //2006 IEEE International Conference on Acoustics Speech and Signal Processing Proceedings, IEEE, 2006, 1: 157-168.
- [15] Yu D, Deng L, Dahl G. Roles of pre-training and fine-tuning in context-dependent DBN-HMMs for real-world speech recognition [C] //Proc. NIPS Workshop on Deep Learning and Unsupervised Feature Learning, 2010.
- [16] Dahl G E, Yu D, Deng L, et al. Context-dependent pre-trained deep neural networks for large-vocabulary speech recognition [J]. IEEE Transactions on Audio, Speech, and Language Processing, 2011, 20(1): 30-42.
- [17] Mohamed A, Dahl G E, Hinton G. Acoustic modeling using deep belief networks [J]. IEEE Transactions on Audio, Speech, and Language Processing, 2011, 20(1): 14-22.
- [18] Yao K, Yu D, Seide F, et al. Adaptation of context-dependent deep neural networks for automatic speech recognition [C] //2012 IEEE Spoken Language Technology Workshop(SLT), IEEE, 2012: 366-369.
- [19] Graves A, Jaitly N. Towards end-to-end speech recognition with recurrent neural networks [C] //International Conference on Machine Learning, 2014: 1764-1772.
- [20] Zhang Y, Chan W, Jaitly N. Very deep convolutional networks for end-to-end speech recognition [C] //2017 IEEE International Conference on Acoustics, Speech and Signal Processing(ICASSP), IEEE, 2017: 4845-4849.
- [21] Chan W, Jaitly N, Le Q, et al. Listen, attend and spell: a neural network for large vocabulary conversational speech recognition [C] //2016 IEEE International Conference on Acoustics, Speech and Signal Processing(ICASSP), IEEE, 2016: 4960-4964.
- [22] Gong Y, Poellabauer C. Crafting adversarial examples for speech paralinguistics applications [J]. arXiv preprint arXiv: 1711.03280, 2017.
- [23] Carlini N, Wagner D. Audio adversarial examples: targeted attacks on speech-to-text [C] //2018 IEEE Security and Privacy Workshops(SPW), IEEE, 2018: 1-7.
- [24] Wang X, Sun S, Shan C, et al. Adversarial examples for improving end-to-end attention-based small-footprint keyword spotting [C] //ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing(ICASSP), IEEE, 2019: 6366-6370.
- [25] Schönherr L, Kohls K, Zeiler S, et al. Adversarial attacks against automatic speech recognition systems via psychoacoustic hiding [J]. arXiv preprint arXiv: 1808.05665, 2018.
- [26] Qin Y, Carlini N, Goodfellow I, et al. Imperceptible, robust, and targeted adversarial examples for automatic speech recognition [J]. arXiv preprint arXiv: 1903.10346, 2019.
- [27] Yakura H, Sakuma J. Robust audio adversarial example for a physical attack [J]. arXiv preprint arXiv: 1810.11793, 2018.
- [28] Alzantot M, Balaji B, Srivastava M. Did you hear that? adversarial examples against automatic speech recognition [J]. arXiv preprint arXiv: 1801.00554, 2018.
- [29] Zhang C, Yan C, Ji X, et al. Dolphinattack: inaudible voice commands [C] //Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security, ACM, 2017: 103-117.
- [30] Du T, Ji S, Li J, et al. SirenAttack: generating adversarial audio for end-to-end acoustic systems [J]. arXiv preprint arXiv: 1901.07846, 2019.
- [31] Khare S, Aralikkatte R, Mani S. Adversarial black-box attacks for automatic speech recognition systems using multi-objective genetic optimization [J]. arXiv preprint arXiv: 1811.01312, 2018.
- [32] Gong Y, Li B, Poellabauer C, et al. Real-time adversarial attacks [C] //International Joint Conference on Artificial Intelligence(IJCAI), 2019.
- [33] Abdullah H, Garcia W, Peeters C, et al. Practical hidden voice attacks against speech and speaker recognition systems [J]. arXiv preprint arXiv: 1904.05734, 2019.
- [34] Lei X, Tu G H, Liu A X, et al. The insecurity of home digital voice assistants—amazon alexa as a case study [J]. arXiv preprint arXiv: 1712.03327, 2017.
- [35] Feng H, Fawaz K, Shin K G. Continuous authentication for voice assistants [C] //Proceedings of the 23rd Annual International Conference on Mobile Computing and Networking, ACM, 2017: 343-355.
- [36] Goldberg D E, Korb B, Deb K. Messy genetic algorithms: motivation, analysis, and first results [J]. Complex Systems, 1989, 3(5): 493-530.
- [37] Dorigo M, Bonabeau E, Theraulaz G. Ant algorithms and stigmergy [J]. Future Generation Computer Systems, 2000, 16(8): 851-871.
- [38] Eberhart R, Kennedy J. A new optimizer using particle swarm theory [C] //MHS'95, Proceedings of the Sixth International Symposium on Micro Machine and Human Science, IEEE, 1995: 39-43.
- [39] Yang X S, Deb S. Cuckoo search via Lévy flights [C] //2009 World Congress on Nature & Biologically Inspired Computing(NaBIC), IEEE, 2009: 210-214.
- [40] Reichenbach T, Hudspeth A J. Discrimination of low-frequency tones employs temporal fine structure [J]. PloS one, 2012, 7(9): e45579.
- [41] Graves A, Fernández S, Gomez F, et al. Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks [C] //Proceedings of the 23rd International Conference on Machine Learning, ACM, 2006: 369-376.
- [42] Mantegna R N. Fast, accurate algorithm for numerical simulation of Levy stable stochastic processes [J]. Physical Review E, 1994, 49(5): 4677-4683.
- [43] Taori R, Kamsetty A, Chu B, et al. Targeted adversarial examples for black box audio systems [C] //2019 IEEE Security and Privacy Workshops(SPW), IEEE, 2019: 15-20.
- [44] Boll S. Suppression of acoustic noise in speech using spectral subtraction [J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1979, 27(2): 113-120.